Đề cương Nghiên cứu

Kiến trúc trích xuất đặc trưng tích hợp Cơ chế chú ý và Hàm mất mát bất đối xứng trong Phân loại ảnh đa nhãn

Phan Huỳnh Châu Thịnh
MSSV: 23122019
23122019@student.hcmus.edu.vn

Hoàng Văn Sang
MSSV: 23120350
23120350@student.hcmus.edu.vn

Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên, Đại học Quốc gia TP. Hồ Chí Minh

Tóm tắt (Synopsis)

Đề tài này nghiên cứu bài toán **phân loại ảnh đa nhãn** (Multi-label Image Classification), trong đó mỗi bức ảnh có thể được gán đồng thời nhiều nhãn. Thách thức hiện tại là sự *mất cân bằng nghiêm trọng* giữa số lượng nhãn dương tính (positive) và âm tính (negative) – trên bộ dữ liệu MS COCO [3], một ảnh trung bình chỉ chứa 2–3 nhãn dương tính trong tổng số 80 lớp, khiến các hàm mất mát truyền thống như Binary Cross-Entropy (BCE) hội tụ kém.

Đề tài đề xuất một kiến trúc gồm ba thành phần kết hợp: (i) mạng backbone **EfficientNet-B0** [5] với lightweight có khả năng trích xuất đặc trưng hiệu quả; (ii) module chú ý **CBAM** [6] đóng vai trò neck để tinh chỉnh các đặc trưng từ EfficientNet theo cả chiều kênh lẫn chiều không gian; và (iii) **Hàm mất mát bất đối xứng (ASL)** [4] xử lý riêng biệt nhãn dương và âm để giải quyết tốt vấn đề mất cân bằng nhãn. Mô hình sẽ được đánh giá qua các chỉ số mAP và Macro F1-score trên MS COCO subset và Pascal VOC 2012.

1 Tiêu đề đề tài (Project Title)

Đánh giá Kiến trúc EfficientNet-B0 + CBAM + ASL cho Bài toán phân loại ảnh đa nhãn

2 Người hướng dẫn nghiên cứu (Research Supervisor)

Thông tin	Chi tiết
Họ và tên giảng viên	Võ Hoài Việt
Bộ môn	Thị giác Máy tính
Khoa	Khoa Công nghệ Thông tin
Trường	ĐH Khoa học Tự nhiên – ĐHQG TP.HCM
Email	vhviet@fit.hcmus.edu.vn

3 Phương thức nghiên cứu đề xuất (Proposed Mode of Research)

Đây là nghiên cứu thực nghiệm trong lĩnh vực ứng dụng học sâu. Phương thức triển khai bao gồm:

- **Dữ liệu:** Sử dụng các bộ dữ liệu ảnh chuẩn – MS COCO 2017 (80 lớp, subset 20 000 ảnh) và Pascal VOC 2012 (20 lớp)
- **Phương pháp:** Python/PyTorch, huấn luyện mô hình trên Kaggle GPU (NVIDIA Tesla T4, 16 GB VRAM).
- **So sánh:** Thiết kế các ablation study, thay đổi từng biến số độc lập (backbone, loss function, attention module) để đánh giá đóng góp của từng thành phần.
- **Báo cáo:** Kết quả được trình bày dưới dạng bài báo hội thảo theo định dạng IEEE

4 Mục tiêu và Câu hỏi Nghiên cứu (Aims and Objectives)

Mục tiêu tổng quát (Aim)

Chứng minh rằng sự kết hợp giữa backbone EfficientNet-B0, module chú ý CBAM, và hàm mất mát bất đối xứng ASL có thể tạo ra hiệu ứng cộng hưởng giữa các thuật toán giúp cải thiện đáng kể hiệu năng phân loại đa nhãn so với các phương pháp cơ sở, trong điều kiện phần cứng hạn chế. (GPU T4)

Các mục tiêu cụ thể (Objectives)

Các mục tiêu được sắp xếp theo trình tự logic, mỗi mục tiêu tiên quyết cho mục tiêu tiếp theo:

O1. Công trình liên quan. tài liệu về các kiến trúc trích xuất đặc trưng (ResNet, EfficientNet), cơ chế chú ý (SE, CBAM), và hàm mất mát đa nhãn (BCE, Focal Loss, ASL).

O2. Thực nghiệm. ba biến thể mô hình tương ứng với ba trường hợp ablation study:

- **Exp A:** ResNet50 + BCE (baseline).
- **Exp B:** ResNet50 + ASL (xem xét sự đóng góp của loss ASL).
- **Exp C:** EfficientNet-B0 + CBAM + ASL (mô hình đề xuất).

O3. Dữ liệu. đầy đủ trên MS COCO subset và Pascal VOC 2012, với ít nhất 3 lần chạy độc lập (random seeds khác nhau) để đảm bảo tính thống kê.

O4. Phương pháp đánh giá. mAP và Macro F1-score; thực hiện phân tích per-class AP để so sánh hiệu năng trên các lớp hiếm gặp và phổ biến.

O5. Phân tích và thảo luận. cơ chế cộng hưởng giữa CBAM và ASL: liệu CBAM có làm tăng xác suất dự đoán p cho các đối tượng bị che khuất, từ đó giúp ASL gradient amplification hoạt động hiệu quả hơn?

5 Bối cảnh và Tổng quan Tài liệu (Background)

5.1 Bài toán Phân loại ảnh đa nhãn

Phân loại đa nhãn (Multi-label Classification) yêu cầu hệ thống nhận diện đồng thời nhiều đối tượng trong cùng một bức ảnh [7]. Khác với phân loại đơn nhãn dùng hàm Softmax (tổng xác suất bằng 1), đa nhãn dùng hàm Sigmoid độc lập cho mỗi nhãn $p_i \in [0, 1]$, xác suất không ảnh hưởng lẫn nhau. Đay là vấn đề nền tảng của nhiều ứng dụng quan trọng: truy xuất ngữ nghĩa của ảnh, phân tích ảnh y tế có nhiều bệnh lý, nhận dạng trong xe tự lái, và kiểm duyệt nội dung.

5.2 Vấn đề mất cân bằng nhãn (Label Imbalance)

Trên MS COCO (80 lớp), mỗi ảnh trung bình chỉ có 2–3 nhãn dương tính, tức ≈ 77 nhãn âm tính đi kèm. Binary Cross-Entropy (BCE) không có cơ chế xử lý với lượng gradient khổng lồ từ các easy negative, dẫn đến hiện tượng mô hình hội tụ sớm vào chiến lược dự đoán mọi nhãn là không xuất hiện, không còn dự đoán được các nhãn là positive.

5.3 Tiến hóa của hàm mất mát

Bảng 1: So sánh các hàm mất mát cho bài toán phân loại đa nhãn.

Hàm mất mát	Xử lý nhãn âm/dương	Chống easy negatives	Chống mislabel
BCE [1]	Đối xứng	Không	Không
Focal Loss [2]	Đối xứng	Khá	Thấp
ASL [4]	Bất đối xứng	Tuyệt đối	Cao

Asymmetric Loss (ASL) được giới thiệu tại ICCV 2021 [4] với cấu trúc toán học tách biệt hai nhánh:

$$L_{\text{ASL}} = \begin{cases} (1-p)^{\gamma_+} \log(p) & \text{khi nhãn thực } y = 1 \\ (p_{\text{shift}})^{\gamma_-} \log(1 - p_{\text{shift}}) & \text{khi nhãn thực } y = 0 \end{cases} \tag{1}$$

trong đó $p_{\text{shift}} = \max(p - m,\ 0)$ với biên độ dịch chuyển m (thường $m = 0.05$), và các tham số hội tụ $\gamma_+ = 0$, $\gamma_- = 4$. Cơ chế này triệt tiêu hoàn toàn gradient của các nhãn âm có xác suất dưới ngưỡng m.

5.4 Cơ chế chú ý CBAM

CBAM (Convolutional Block Attention Module) [6] tinh chỉnh feature map qua hai bước tuần tự: *Channel Attention* xác định kênh đặc trưng quan trọng bằng Global Average Pooling và Global Max Pooling qua MLP chia sẻ trọng số, sau đó *Spatial Attention* tạo mặt nạ không gian 2D để định vị đối tượng trong ảnh.

5.5 EfficientNet-B0 và chiến lược Compound Scaling

EfficientNet [5] cân bằng đồng thời chiều sâu, chiều rộng và độ phân giải ảnh đầu vào theo hệ số mở rộng phức hợp (compound scaling). EfficientNet-B0 với số lượng tham số nhẹ (chỉ 5.3M tham số) nhưng có thể đạt hiệu quả ngang với ResNet50 (với 25.6M tham số) với chi phí FLOPs thấp hơn nhiều, phù hợp với giới hạn phần cứng Kaggle T4.

5.6 Khoảng trống nghiên cứu

Mặc dù ASL [4] đã đạt state-of-the-art trên MS COCO với backbone nặng (TResNet-L), nhưng chưa có nghiên cứu nào hệ thống hóa hiệu năng của ASL kết hợp CBAM trên backbone nhẹ EfficientNet-B0, đặc biệt trong điều kiện phần cứng hạn chế.

6 Dự kiến đóng góp của nghiên cứu (Expected Research Contribution)

Nghiên cứu này dự kiến đóng góp vào cộng đồng khoa học ở ba phương diện:

1. **Kết quả thực nghiệm.** Ablation study(Exp A/B/C) với ít nhất 3 seeds độc lập cung cấp bằng chứng định lượng rõ ràng về đóng góp của từng thành phần (backbone, loss, attention).
2. **Luận giải cơ chế cộng hưởng CBAM–ASL.** Giả thuyết trung tâm: CBAM tăng xác suất p của nhãn positive ở vùng bị che khuất, giúp ASL khai thác cơ chế gradient amplification hiệu quả hơn.
3. **Hướng dẫn thực thi.** Toàn bộ code, config và hướng dẫn chạy trên Kaggle T4 sẽ được công bố mã nguồn mở, hỗ trợ các nhóm nghiên cứu khác tái hiện và mở rộng kết quả mà không cần đầu tư nhiều phần cứng.

7 Phương pháp nghiên cứu đề xuất (Proposed Methodology)

7.1 Kiến trúc tổng thể

Pipeline được thiết kế dạng feed-forward gồm 5 giai đoạn:

$$\text{Ảnh} \xrightarrow{\text{Backbone}} F \xrightarrow{\text{CBAM}} \tilde{F} \xrightarrow{\text{GAP}} \mathbf{v} \xrightarrow{\text{FC}} \mathbf{z} \xrightarrow{\text{ASL}} \mathcal{L} \tag{2}$$

trong đó $F \in \mathbb{R}^{B\times C\times H\times W}$ là feature map từ backbone, $\tilde{F}$ là feature map sau CBAM, $\mathbf{v} \in \mathbb{R}^{C}$ là feature vector sau GAP, và $\mathbf{z} \in \mathbb{R}^{N_c}$ là vector logit với N_c là số lớp.

7.2 Thiết kế Ablation Study

Bảng 2: Ba kịch bản thực nghiệm ablation.

Kịch bản	Mô tả	Backbone	CBAM	Loss
Exp A	Baseline	ResNet50	Không	BCE
Exp B	Đóng góp của Loss	ResNet50	Không	ASL
Exp C	Mô hình đầy đủ	EfficientNet-B0	Có	ASL

So sánh A $\rightarrow$ B định lượng đóng góp thuần túy của ASL. So sánh B $\rightarrow$ C định lượng đóng góp của CBAM và backbone EfficientNet-B0.

7.3 Dữ liệu và tiền xử lý

- **MS COCO 2017 subset:** 16 000 ảnh train + 5 000 ảnh val, được lấy mẫu phân tầng (stratified sampling) đảm bảo phân bố nhãn đồng đều. Nguồn: https://www.kaggle.com/datasets/awsaf49/coco-2017-dataset.
- **Pascal VOC 2012:** 20 lớp, dùng để kiểm tra tính tổng quát. Nguồn: https://www.kaggle.com/datasets/gopalbhattrai/pascal-voc-2012-dataset
- **Tiền xử lý:** Resize 224×224, RandomCrop, RandomHorizontalFlip, ColorJitter, chuẩn hoá theo thống kê ImageNet.

7.4 Siêu tham số và môi trường

Bảng 3: Thiết lập siêu tham số thực nghiệm.

Tham số	Giá trị	Lý do lựa chọn
Optimizer	AdamW	Ổn định, phổ biến trong CV
Learning rate	3×10^{-4}	Theo khuyến nghị timm
Scheduler	OneCycleLR	Hội tụ nhanh trên T4
Batch size	64	Tối đa VRAM 16 GB
Epochs	20	Phù hợp giới hạn 30h/tuần Kaggle
γ_+	0	Không suy giảm gradient dương
γ_-	4	Triệt tiêu easy negatives
Margin m	0.05	Lọc mislabeled samples
Seeds	3 lần (42, 123, 2025)	Đảm bảo tính thống kê

7.5 Chỉ số đánh giá

- **mAP** (mean Average Precision): diện tích dưới đường cong Precision-Recall, tính độc lập cho từng lớp rồi lấy trung bình. Đây là chỉ số tiêu chuẩn cho bài toán đa nhãn.

- **Macro F1-score**: tính F1 cho từng nhãn rồi lấy trung bình không trọng số, đối xử công bằng giữa lớp phổ biến và lớp hiếm.
- **Per-class AP analysis**: so sánh AP từng lớp giữa Exp A và Exp C để làm rõ hiệu quả của ASL trên các lớp thiểu số.

7.6 Hạn chế dự kiến và biện pháp xử lý

- *Giới hạn phần cứng:* Chỉ dùng 20 000 ảnh thay vì toàn bộ 118 000 ảnh MS COCO. Biện pháp: stratified sampling đảm bảo tính đại diện; mixed precision training (AMP) tiết kiệm VRAM.
- *Xác nhận tính tổng quát:* Chỉ thử nghiệm trên 2 bộ dữ liệu. Biện pháp: báo cáo rõ phạm vi áp dụng; đề xuất hướng mở rộng sang NUS-WIDE hoặc Open Images cho nghiên cứu tương lai.
- *Ethical considerations:* Dữ liệu hoàn toàn công khai, không có thông tin cá nhân nhạy cảm, không có mối lo ngại đạo đức đặc biệt.

8 Kế hoạch thực hiện (Work Plan)

Bảng 4: Kế hoạch thực hiện theo tuần.

Tuần	Cột mốc	Nội dung công việc
1	Khảo sát & Chuẩn bị dữ liệu	Đọc và tổng hợp tài liệu về ASL, CBAM, EfficientNet; viết phần Background; Download MS COCO, tạo stratified subset 20k; kiểm tra VOC 2012.
2	Xây dựng code base	Implement `losses.py`, `cbam.py`, `models.py`, `dataset.py`.
3-4	Exp A/B/C	Huấn luyện ResNet50 + BCE, 3 seeds; ghi nhận mAP baseline; Huấn luyện ResNet50 + ASL, 3 seeds; so sánh với Exp A; Huấn luyện EfficientNet-B0 + CBAM + ASL, 3 seeds.
5	Phân tích kết quả & Báo cáo	Vẽ biểu đồ, per-class AP analysis, so sánh ablation table

9 Tài nguyên cần thiết (Resources)

- **Phần cứng:** Kaggle Notebook với GPU NVIDIA Tesla T4 (16 GB VRAM).
- **Phần mềm:** Python 3.10+, PyTorch 2.0+, timm, pycocotools, scikit-learn.
- **Dữ liệu:** MS COCO 2017 và Pascal VOC 2012.
- **Thời gian:** 5 tuần, song song giữa hai thành viên nhóm.

Phân công công việc:

Thành viên	MSSV	Trách nhiệm chính
Phan Huỳnh Châu Thịnh	23122019	Backbone, CBAM, training loop, Exp C, viết báo cáo
Hoàng Văn Sang	23120350	Loss functions, evaluation metrics, Exp A & B, viết báo cáo

Tài liệu

[1] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.

[2] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 2980–2988, 2017.

[3] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C. Lawrence Zitnick. Microsoft COCO: Common objects in context. In *European Conference on Computer Vision (ECCV)*, pages 740–755, 2014.

[4] Tal Ridnik, Emanuel Ben-Baruch, Nadav Zamir, Asaf Noy, Itamar Friedman, Matan Protter, and Lihi Zelnik-Manor. Asymmetric loss for multi-label classification. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 82–91, 2021.

[5] Mingxing Tan and Quoc V. Le. EfficientNet: Rethinking model scaling for convolutional neural networks. In *Proceedings of the International Conference on Machine Learning (ICML)*, pages 6105–6114, 2019.

[6] Sanghyun Woo, Jongchan Park, Joon-Young Lee, and In So Kweon. CBAM: Convolutional block attention module. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 3–19, 2018.

[7] Min-Ling Zhang and Zhi-Hua Zhou. A review on multi-label learning algorithms. *IEEE Transactions on Knowledge and Data Engineering*, 26(8):1819–1837, 2014.