

Phân loại ảnh đa nhãn sử dụng EfficientNet-B0, CBAM và Asymmetric Loss

Phan Huỳnh Châu Thịnh
MSSV: 23122019

Khoa CNTT, ĐHKH Tự nhiên, ĐHQG TP.HCM
23122019@student.hcmus.edu.vn

Hoàng Văn Sang
MSSV: 23120350

Khoa CNTT, ĐHKH Tự nhiên, ĐHQG TP.HCM
23120350@student.hcmus.edu.vn

Tóm tắt nội dung—Phân loại ảnh đa nhãn đóng vai trò quan trọng trong nhiều ứng dụng như truy xuất ảnh ngữ nghĩa, phân tích ảnh y tế và nhận dạng cảnh vật, trong đó mỗi ảnh có thể chứa đồng thời nhiều đối tượng. Đồ án này xây dựng hệ thống phân loại ảnh đa nhãn trên tập dữ liệu MS COCO 2017 (80 lớp) [1] và thực hiện ablation study gồm 6 kịch bản đối chứng nhằm phân tích ảnh hưởng của backbone, attention mechanism và loss function.

Hệ thống đề xuất kết hợp EfficientNet-B0 để trích xuất đặc trưng, CBAM để tăng cường attention theo kênh và không gian, và Asymmetric Loss (ASL) để xử lý mất cân bằng nhãn trong bài toán MLIC. Kết quả thực nghiệm cho thấy mô hình đạt Val mAP = 0.6364 và Test mAP = 0.6537. Ngoài ra, ablation study xác nhận ASL cải thiện +2.1% mAP so với Binary Cross-Entropy, trong khi ResNet50 vẫn vượt trội EfficientNet-B0 trên tập MS COCO. Các kết quả này cho thấy loss function và capacity của backbone đóng vai trò quan trọng hơn attention module trong thiết lập dữ liệu của nghiên cứu này.

Index Terms—phân loại đa nhãn, EfficientNet, CBAM, Asymmetric Loss, MS COCO, ablation study, overfitting, attention mechanism

I. GIỚI THIỆU

Phân loại ảnh đa nhãn (Multi-label Image Classification - MLIC [3]) là bài toán gán đồng thời nhiều nhãn cho một ảnh đầu vào. Không giống phân loại đơn nhãn dùng softmax (tổng xác suất = 1), MLIC dùng sigmoid độc lập cho mỗi nhãn $p_i \in [0, 1]$, không phụ thuộc lẫn nhau. MLIC là nền tảng của nhiều ứng dụng quan trọng: truy xuất ngữ nghĩa ảnh, phân tích ảnh y tế đa bệnh lý, nhận dạng đối tượng trong xe tự lái, và kiểm duyệt nội dung.

Thách thức cốt lõi của MLIC trên MS COCO (80 lớp): mỗi ảnh trung bình chỉ chứa 2–3 nhãn dương tính, tức ≈ 77 nhãn âm tính đi kèm (tỉ lệ positive/negative $\approx 1:37$). Hàm mất mát Binary Cross-Entropy (BCE) truyền thống không có cơ chế phân biệt gradient từ easy negatives và hard positives, dẫn đến mô hình thiên lệch về phía âm tính và bỏ sót nhiều nhãn dương.

Đồ án này đề xuất giải quyết hai vấn đề trên bằng:

- 1) **Hàm mất mát bất đối xứng ASL** [4]: xử lý riêng biệt nhãn dương và âm, triệt tiêu gradient từ easy negatives.
- 2) **Module chú ý CBAM** [5]: tinh chỉnh đặc trưng theo kênh (“what”) và không gian (“where”), giúp mô hình định vị vùng chứa đối tượng trước khi phân loại.

Backbone được chọn là EfficientNet-B0 - mô hình nhẹ (3.63M tham số) phù hợp giới hạn phần cứng Kaggle T4.

Các phần tiếp theo được tổ chức như sau: Mục II trình bày công trình liên quan. Mục III mô tả kiến trúc đề xuất. Mục IV trình bày thiết lập thực nghiệm. Mục V phân tích kết quả. Mục VI phân tích sâu nguyên nhân và hạn chế. Mục VII kết luận và thảo luận hướng phát triển.

II. CÔNG TRÌNH LIÊN QUAN

A. Backbone cho phân loại đa nhãn

ResNet [6] với kết nối tắt (skip connections) giải quyết vấn đề gradient bị suy giảm dần khi lan truyền ngược qua nhiều lớp (gradient vanishing), trở thành backbone tiêu chuẩn cho nhiều tác vụ thị giác. ResNet50 (23.67M tham số) là baseline phổ biến trong MLIC.

EfficientNet [2] đề xuất compound scaling: đồng thời tăng chiều sâu (depth), chiều rộng (width), và độ phân giải (resolution) theo hệ số (α, β, γ) thỏa $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$. EfficientNet-B0 (3.63M tham số) đạt độ chính xác ngang ResNet50 với FLOPs thấp hơn $6.5\times$, phù hợp với môi trường tài nguyên hạn chế.

B. Cơ chế chú ý trong CNN

SE-Net [8] giới thiệu Squeeze-and-Excitation: Squeeze bằng Global Average Pooling, Excitation bằng FC + sigmoid để học trọng số kênh. SE-Net chỉ có Channel Attention, bỏ qua Spatial Attention.

CBAM mở rộng SE-Net với hai nhánh tuần tự: Channel Attention (“what to focus”) và Spatial Attention (“where to focus”). CBAM thêm chỉ $\approx 2,000$ tham số nhưng cải thiện đáng kể trên nhiều tác vụ phân loại và phát hiện đối tượng.

C. Hàm mất mát cho phân loại đa nhãn

BCE (Binary Cross-Entropy) [9] là baseline cơ bản, nhưng không xử lý mất cân bằng nhãn.

Focal Loss [7] được đề xuất cho object detection, áp dụng hệ số $(1 - p)^\gamma$ để giảm trọng số easy samples. Tuy nhiên Focal Loss đối xứng vì áp dụng cùng γ cho cả nhãn dương và âm.

ASL (Asymmetric Loss, ICCV 2021) là hàm mất mát bất đối xứng đầu tiên xử lý riêng biệt hai nhánh: hệ số focusing γ_+ (nhỏ, cho dương tính) và γ_- (lớn, cho âm tính), kết hợp sự thay đổi phân phối xác suất (probability shift) để triệt tiêu hoàn toàn gradient từ easy negatives. ASL đạt state-of-the-art trên MS COCO, Pascal VOC, NUS-WIDE và Open Images.

D. Khoảng trống nghiên cứu

Mặc dù ASL đã được kiểm chứng với backbone nặng (TRResNet-L, $\approx 50M$), chưa có nghiên cứu hệ thống hóa hiệu năng của bộ ba ASL + CBAM + EfficientNet-B0 trong điều kiện phần cứng hạn chế (GPU 16 GB VRAM, tập dữ liệu 16,000 ảnh). Đây là khoảng trống mà đồ án này tiến hành nghiên cứu.

III. PHƯƠNG PHÁP ĐỀ XUẤT

A. Tổng quan kiến trúc

Nhóm chúng tôi đề xuất kiến trúc feed-forward 5 giai đoạn (ký hiệu **Exp C** trong ablation study):

$$\mathbf{x} \xrightarrow{\text{EfficientNet-B0}} F \xrightarrow{\text{CBAM}} \tilde{F} \xrightarrow{\text{GAP}} \mathbf{v} \xrightarrow{\text{FC}} \mathbf{z} \xrightarrow{\text{ASL}} \mathcal{L} \quad (1)$$

trong đó $\mathbf{x} \in \mathbb{R}^{3 \times 224 \times 224}$ là ảnh đầu vào, $F \in \mathbb{R}^{1280 \times 7 \times 7}$ là feature map từ backbone (sau MBConv cuối), $\tilde{F}$ là feature map sau CBAM, $\mathbf{v} \in \mathbb{R}^{1280}$ là vector đặc trưng sau Global Average Pooling, $\mathbf{z} \in \mathbb{R}^{80}$ là vector logit trước sigmoid, và $\mathcal{L}$ là giá trị loss ASL.

Hình 1 minh họa kiến trúc tổng thể.

B. Backbone: EfficientNet-B0

EfficientNet-B0 được xây dựng từ Mobile Inverted Bottleneck (MBConv) blocks với Squeeze-and-Excitation tích hợp sẵn, sử dụng compound scaling với hệ số $\phi = 1$:

$$d = \alpha^\phi, \quad w = \beta^\phi, \quad r = \gamma^\phi, \quad \alpha \cdot \beta^2 \cdot \gamma^2 \approx 2 \quad (2)$$

với $(\alpha, \beta, \gamma) = (1.2, 1.1, 1.15)$ được tìm qua NAS.

ResNet50 là baseline phổ biến trong MLIC nhưng lại có 23.67M tham số, vượt ngoài ngưỡng phù hợp với môi trường Kaggle T4 khi kết hợp với CBAM và batch size 64. Vì vậy, việc sử dụng EfficientNet-B0 (3.63M) giúp nhẹ hơn 6.5×, đồng thời thời gian huấn luyện cũng giảm $\approx 40\%$, nhưng vẫn trích xuất được đặc trưng ngữ nghĩa cao nhờ MBConv.

Khởi tạo: Sử dụng trọng số pretrained trên ImageNet-1K (từ thư viện timm). Toàn bộ backbone được fine-tune (không đóng băng bất kỳ layer nào).

Về mặt chức năng, EfficientNet-B0 đóng vai trò backbone trích xuất đặc trưng, biến đổi ảnh đầu vào từ không gian pixel sang không gian đặc trưng ngữ nghĩa cao. Các tầng tích chập đầu học cạnh và texture cơ bản, trong khi các tầng sâu hơn học các mẫu ngữ nghĩa như bộ phận đối tượng, hình dạng và ngữ cảnh. Feature map cuối cùng $F \in \mathbb{R}^{1280 \times 7 \times 7}$ đóng vai trò biểu diễn trung gian của toàn ảnh, làm đầu vào cho attention module và classifier phía sau.

C. Neck: CBAM (Convolutional Block Attention Module)

Trong bài toán phân loại ảnh đa nhân, nhiều nhân thường tương ứng với các vùng không gian khác nhau trong ảnh. Nếu sử dụng Global Average Pooling trực tiếp, mọi vị trí trong feature map sẽ đóng góp như nhau vào vector đặc trưng cuối, khiến tín hiệu của các đối tượng nhỏ hoặc bị che khuất dễ bị suy giảm. CBAM giúp tái phân bố trọng số theo cả chiều kênh và không gian, cho phép mô hình nhấn mạnh các đặc trưng và vùng ảnh mang nhiều thông tin ngữ nghĩa hơn trước khi tổng hợp đặc trưng toàn cục.

CBAM áp dụng tuần tự hai cơ chế chú ý như Hình 2:

1) *Channel Attention*: Học vector trọng số $\mathbf{s}_c \in (0, 1)^C$ xác định kênh nào quan trọng ("what to focus on"):

$$\mathbf{M}_c = \sigma(\text{MLP}(\text{AvgPool}(F)) + \text{MLP}(\text{MaxPool}(F))) \quad (3)$$

MLP chia sẻ trọng số, reduction ratio $r = 16$. Output: $F' = \mathbf{M}_c \otimes F$ (nhân phần tử theo kênh).

2) *Spatial Attention*: Tạo bản đồ chú ý $\mathbf{M}_s \in (0, 1)^{H \times W}$ xác định vùng nào trong ảnh cần chú ý ("where to focus"):

$$\mathbf{M}_s = \sigma(\text{Conv}_{7 \times 7}([\overline{\text{Avg}_c}(F'), \overline{\text{Max}_c}(F')])) \quad (4)$$

trong đó $\overline{\text{Avg}_c}$ và $\overline{\text{Max}_c}$ là pooling theo chiều kênh. Output cuối: $\tilde{F} = \mathbf{M}_s \otimes F'$.

Khi mỗi nhân thường gắn với một vùng không gian cụ thể (người $\rightarrow$ vùng trung tâm, cà vạt $\rightarrow$ vùng ngực-cổ), CBAM Spatial Attention học định vị các vùng này trước khi GAP tổng hợp thành vector đặc trưng $\mathbf{v}$, thay vì GAP lấy trung bình đồng đều trên toàn feature map. CBAM giúp tăng xác suất p của nhân positive ở vùng bị che khuất, từ đó giúp ASL khuếch đại gradient làm mô hình hoạt động hiệu quả hơn.

D. Global Average Pooling

Global Average Pooling (GAP) tổng hợp feature map $\tilde{F} \in \mathbb{R}^{1280 \times 7 \times 7}$ thành vector đặc trưng toàn cục $\mathbf{v} \in \mathbb{R}^{1280}$ bằng cách lấy trung bình trên từng kênh:

$$v_c = \frac{1}{HW} \sum_{i=1}^H \sum_{j=1}^W \tilde{F}_{c,i,j}$$

GAP giúp giảm mạnh số lượng tham số so với fully-connected flattening, đồng thời buộc mô hình học biểu diễn mang tính ngữ nghĩa toàn cục. Tuy nhiên, phép pooling này cũng làm mất thông tin vị trí, đó là lý do CBAM được đặt trước GAP để tăng trọng số cho các vùng quan trọng trước khi tổng hợp.

E. Head: Fully Connected + Dropout


Sau khi CBAM tinh chỉnh feature map theo kênh và không gian, Global Average Pooling (GAP) tổng hợp đặc trưng thành vector $\mathbf{v} \in \mathbb{R}^{1280}$ đại diện ngữ nghĩa toàn ảnh. Tuy nhiên, vector này vẫn nằm trong không gian đặc trưng trung gian, chưa tương ứng trực tiếp với không gian nhân của bài toán MLIC. Do đó, một fully connected layer được sử dụng để ánh xạ đặc trưng $\mathbf{v}$ sang không gian nhân gồm 80 lớp COCO.

$$\mathbf{z} = \mathbf{W}_{fc} \text{Dropout}(\mathbf{v}) + \mathbf{b} \quad (5)$$


với $\mathbf{W}_{fc} \in \mathbb{R}^{80 \times 1280}$, $\mathbf{z} \in \mathbb{R}^{80}$ là vector logit trước sigmoid.

Về mặt hình học, mỗi hàng của ma trận $\mathbf{W}_{fc}$ có thể được xem như prototype vector của một lớp. Quá trình phân loại thực chất là đo mức độ tương đồng giữa đặc trưng ảnh $\mathbf{v}$ và các prototype này trong không gian đặc trưng. Nếu $\mathbf{v}$ gần prototype của lớp nào, logit tương ứng sẽ lớn và xác suất sigmoid của lớp đó tăng lên.

Dropout được sử dụng như một cơ chế regularization nhằm giảm overfitting bằng cách ngẫu nhiên vô hiệu hóa một phần chiều đặc trưng trong quá trình huấn luyện. Điều này buộc mô hình không phụ thuộc quá mạnh vào một số activation cụ thể, từ đó cải thiện khả năng tổng quát hóa trên tập test.



Hình 1: Tổng quan kiến trúc mô hình đề xuất cho bài toán multi-label image classification. EfficientNet-B0 được sử dụng làm backbone để trích xuất đặc trưng thị giác, CBAM tinh chỉnh feature map theo attention kênh và không gian, sau đó Global Average Pooling và fully connected layer tạo xác suất độc lập cho 80 lớp MS COCO. Trong giai đoạn huấn luyện, Asymmetric Loss (ASL) được sử dụng để giảm ảnh hưởng của easy negatives và cải thiện học trên các nhãn dương hiếm.



Hình 2: Kiến trúc CBAM được trích từ [5] được sử dụng làm neck. (Trên) Channel Attention: AvgPool và MaxPool theo chiều không gian được đưa qua Shared MLP, cộng lại và sigmoid tạo trọng số kênh $M_c \in (0, 1)^{1280}$, nhân vào F cho ra F' . (Dưới) Spatial Attention: AvgPool và MaxPool theo chiều kênh của F' được nối lại, qua Conv 7×7 và sigmoid tạo attention map $M_s \in (0, 1)^{7 \times 7}$, nhân vào F' cho ra F . Hai module được áp dụng tuần tự: Channel trước, Spatial sau.

F. Loss: Asymmetric Loss (ASL)

Khác với BCE chỉ tối ưu xác suất dự đoán, ASL trực tiếp thay đổi phân bố gradient trong quá trình học. Bằng cách triệt tiêu gradient từ easy negatives, ASL buộc mô hình tập trung vào các positive samples và hard negatives mang nhiều thông tin hơn, đặc biệt quan trọng trong MLIC khi số lượng negative

Bảng I: So sánh các hàm mất mát cho MLIC.

Loss	Nhãn âm/dương	Easy neg.	Mislabel
BCE	Đối xứng	Không	Không
Focal	Đối xứng	Khá	Thấp
ASL	Bất đối xứng	Tuyệt đối	Cao

labels áp đảo.

$$\mathcal{L}_{ASL} = -\frac{1}{C} \sum_{i=1}^C \begin{cases} (1 - p_i)^{\gamma_+} \log p_i & y_i = 1 \\ (p_{i, \text{shift}})^{\gamma_-} \log(1 - p_{i, \text{shift}}) & y_i = 0 \end{cases} \quad (6)$$

trong đó $p_{i, \text{shift}} = \max(p_i - m, 0)$, $m = 0.05$ (probability margin), $\gamma_+ = 0$ (không làm giảm gradient dương), $\gamma_- = 4$ (giúp triệt tiêu mạnh easy negatives).

Với nhãn âm có $p_i < m = 0.05$: $p_{i, \text{shift}} = 0$ thì gradient = 0. Mô hình hoàn toàn bỏ qua các easy negatives này, dồn toàn bộ gradient vào hard samples ($p_i > m$) và positive samples. So sánh với BCE (Focal Loss): BCE không có cơ chế thresholding; Focal Loss áp dụng đối xứng nên không triệt tiêu hoàn toàn easy negatives.

Sự khác biệt của ba hàm mất mát được tóm tắt trong bảng I.

G. Nhìn từ góc độ đại số tuyến tính

Toàn bộ pipeline (1) là chuỗi phép chiếu tuyến tính + phi tuyến:

Bảng II: Thống kê tập MS COCO subset được sử dụng.

Thống kê	Train	Val	Test
Số ảnh	16,000	1,000	3,952
Số lớp	80	80	80
Avg labels/img	2.70	2.68	2.72
Pos/Neg ratio	1:37	1:37	1:37
Lớp nhiều nhất	<i>person</i> ($\approx 7,000$ train)		
Lớp ít nhất	<i>hair drier</i> (< 150 train)		

- 1) **EfficientNet-B0**: học các ma trận tích chập $\mathbf{W}_\ell^{\text{conv}}$ biến đổi ảnh thô $\mathbf{x}$ thành feature map F trong không gian ngữ nghĩa cao.
- 2) **CBAM Channel**: học MLP $\mathbf{W}_{\text{ch}}$ chiều vector kênh về không gian trọng số $\mathbf{M}_c$.
- 3) **CBAM Spatial**: học kernel $\mathbf{W}_{\text{sp}} \in \mathbb{R}^{1 \times 2 \times 7 \times 7}$ tạo attention map 7×7 .
- 4) **FC Head**: $\mathbf{W}_{\text{fc}} \in \mathbb{R}^{80 \times 1280}$ chiều $\mathbf{v}$ vào không gian nhãn. ASL tối ưu đặc trưng đại diện thông qua khuếch đại gradient trên hard positives.

IV. THIẾT LẬP THỰC NGHIỆM

A. Tập dữ liệu

MS COCO 2017 [1]: 80 lớp đối tượng phổ biến. Do giới hạn phần cứng, dữ liệu được chia bằng phương pháp subset stratified: 16,000 ảnh train / 1,000 ảnh val / 3,952 ảnh test. nhằm đảm bảo phân bố nhãn đồng đều giữa các tập.

Thống kê dữ liệu: Bảng II tóm tắt thống kê cơ bản.

B. Tiền xử lý dữ liệu

Ảnh trong MS COCO có kích thước, góc chụp, điều kiện ánh sáng và bố cục rất đa dạng. Ngoài ra, nhiều lớp xuất hiện ở các vị trí khác nhau hoặc chỉ chiếm một vùng nhỏ trong ảnh. Do đó, các phép augmentation được sử dụng nhằm tăng tính đa dạng dữ liệu và cải thiện khả năng tổng quát hóa.

Train: Ảnh được resize về 256×256 và random crop xuống 224×224 để tạo biến thiên vị trí đối tượng, giúp mô hình giảm phụ thuộc vào bố cục cố định. RandomHorizontalFlip ($p = 0.5$) giúp mô hình học tính bất biến theo hướng trái-phải, đặc biệt hữu ích với các lớp như *person*, *car*, *dog*.

ColorJitter được áp dụng (brightness=0.2, contrast=0.2, saturation=0.2, hue=0.1) nhằm mô phỏng thay đổi điều kiện ánh sáng và màu sắc thực tế, giảm nguy cơ mô hình phụ thuộc quá mạnh vào texture hoặc màu nền.

Cuối cùng, ảnh được chuẩn hóa theo thống kê ImageNet ($\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$) để phù hợp với backbone pretrained trên ImageNet-1K, giúp quá trình fine-tuning ổn định hơn.

Val/Test: Chỉ áp dụng Resize + CenterCrop và chuẩn hóa ImageNet, không sử dụng augmentation, nhằm đảm bảo quá trình đánh giá phản ánh chính xác khả năng tổng quát hóa của mô hình trên dữ liệu chưa thấy.

C. Thiết kế Ablation Study

6 kịch bản ablation được thiết kế để (Bảng III), thay đổi từng biến số độc lập: backbone (ResNet50 vs. EfficientNet-B0),

Bảng III: Thiết kế ablation study: 6 kịch bản thực nghiệm.

Exp	Mô tả	Backbone	CBAM	Loss
A	Baseline	ResNet50	✗	BCE
B	ASL thay BCE	ResNet50	✗	ASL
C	Đề xuất	EffNet-B0	✓	ASL
D	Focal Loss	ResNet50	✗	Focal
E	ResNet + CBAM + ASL	ResNet50	✓	ASL
F	EffNet-B0 + ASL	EffNet-B0	✗	ASL

So sánh A→B: đóng góp thuần túy của ASL (cùng backbone, không CBAM).

So sánh B→E: đóng góp của CBAM trên ResNet50.

So sánh B→C: đóng góp tổng hợp (backbone + CBAM).

So sánh F→C: đóng góp thuần túy của CBAM trên EfficientNet-B0.

Bảng IV: Siêu tham số huấn luyện cho tất cả 6 experiments.

Tham số	Giá trị	Lý do
Optimizer	AdamW	Ổn định, phổ biến CV
Learning rate	3×10^{-4}	Theo khuyến nghị <code>timm</code>
Scheduler	OneCycleLR	Hội tụ nhanh trên T4
Batch size	64	Tối đa VRAM 16 GB
Epochs	20	Giới hạn 30h/tuần Kaggle
Dropout	0.3	Regularization cơ bản
Weight decay	10^{-4}	AdamW regularization
AMP	Bật (fp16)	Tiết kiệm VRAM
γ_+ (ASL)	0	Không suy giảm gradient dương
γ_- (ASL)	4	Triệt tiêu easy negatives
Margin m (ASL)	0.05	Lọc mislabeled samples

attention module (có/không CBAM), và loss function (BCE, Focal, ASL).

D. Siêu tham số và Môi trường

Môi trường: Kaggle Notebook, GPU NVIDIA Tesla T4 (16 GB VRAM), Python 3.10, PyTorch 2.0, thư viện `timm` cho backbone.

Siêu tham số được thiết lập như trong Bảng IV:

E. Metric Đánh giá

Để đánh giá toàn diện hiệu năng của bài toán Multi-Label Image Classification (MLIC), nghiên cứu sử dụng ba nhóm metric: (i) chất lượng xếp hạng xác suất (mAP), (ii) chất lượng dự đoán nhị phân sau threshold (Macro/Micro-F1), và (iii) khả năng tổng quát hóa của mô hình (overfitting gap).

1) **mean Average Precision (mAP)**: Trong MLIC, mỗi ảnh có thể chứa nhiều nhãn đồng thời và phân bố positive/negative rất mất cân bằng. Do đó, việc đánh giá chỉ bằng accuracy hoặc F1 tại một threshold cố định không phản ánh đầy đủ khả năng xếp hạng của mô hình.

Vì vậy, nghiên cứu sử dụng **mean Average Precision (mAP)**: metric chuẩn của MS COCO và các bài toán multi-label, để đo khả năng mô hình ưu tiên nhãn đúng cao hơn nhãn sai trên toàn bộ miền threshold.

Đối với mỗi lớp, Average Precision (AP) được tính từ diện tích dưới đường cong Precision-Recall:

$$AP_i = \int_0^1 P_i(r) dr \quad (7)$$

trong đó $P_i(r)$ là precision tại recall r của lớp thứ i . Sau đó, mAP được tính bằng trung bình AP trên toàn bộ $C = 80$ lớp:

$$\text{mAP} = \frac{1}{C} \sum_{i=1}^C \text{AP}_i \quad (8)$$

mAP càng cao cho thấy mô hình càng phân tách tốt giữa positive labels và negative labels, đặc biệt quan trọng trong bối cảnh dữ liệu mất cân bằng như MS COCO.

2) *Macro-F1 và Micro-F1*: Mặc dù mAP đánh giá khả năng xếp hạng xác suất, trong thực tế hệ thống vẫn cần đưa ra quyết định nhị phân (có/không có đối tượng). Do đó, nghiên cứu bổ sung Macro-F1 và Micro-F1 tại threshold cố định $\theta = 0.5$.

F1-score được định nghĩa bởi:

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (9)$$

Macro-F1 tính F1 riêng cho từng lớp rồi lấy trung bình:

$$\text{Macro-F1} = \frac{1}{C} \sum_{i=1}^C F1_i \quad (10)$$

Metric này xem mọi lớp có tầm quan trọng ngang nhau, do đó phản ánh tốt khả năng nhận diện các lớp hiếm.

Ngược lại, **Micro-F1** gộp toàn bộ TP, FP, FN trên tất cả lớp trước khi tính:

$$\text{Micro-F1} = \frac{2TP}{2TP + FP + FN} \quad (11)$$

Micro-F1 thiên về các lớp phổ biến và phản ánh hiệu năng tổng thể của hệ thống trên toàn bộ dữ liệu.

Việc sử dụng đồng thời Macro-F1 và Micro-F1 giúp phân tích liệu mô hình chỉ hoạt động tốt trên lớp phổ biến hay thực sự cân bằng giữa cả lớp hiếm và lớp thường gặp.

3) *Overfitting Gap*: Ngoài hiệu năng dự đoán, nghiên cứu còn đánh giá khả năng tổng quát hóa của mô hình thông qua khoảng cách giữa Train mAP và Test mAP:

$$\Delta_{\text{gap}} = \text{Train mAP} - \text{Test mAP} \quad (12)$$

Nếu Δ_{gap} lớn, mô hình học quá sát dữ liệu huấn luyện nhưng không tổng quát tốt trên dữ liệu chưa thấy, đây là dấu hiệu của overfitting.

Ngược lại, gap nhỏ cho thấy mô hình học được đặc trưng có tính khái quát hơn. Metric này đặc biệt quan trọng khi đánh giá tác động của các module bổ sung như CBAM, vốn có thể tăng capacity nhưng đồng thời làm tăng nguy cơ overfit.

V. KẾT QUẢ THỰC NGHIỆM

A. Kết quả tổng quan

Bảng V trình bày kết quả toàn diện 6 thực nghiệm, sắp xếp theo Test mAP giảm dần.

B. Phân tích đóng góp từng thành phần

1) *Ảnh hưởng của Loss Function*: Mục tiêu của ASL là xử lý mất cân bằng nhãn nghiêm trọng trong MLIC bằng cách triệt tiêu gradient từ easy negatives. Để đánh giá riêng đóng góp của loss function, nhóm thực hiện so sánh A→B và D→B trong cùng điều kiện backbone ResNet50 và không sử dụng CBAM.

ASL vs. BCE (A → B)

Thay BCE bằng ASL trên ResNet50: Test mAP tăng từ 0.7081 lên 0.7228 (+0.0147, tương đương +2.1%). Gap giảm nhẹ từ 0.1625 xuống 0.1511, trong khi Macro-F1 tăng +0.0091.

Kết quả cho thấy ASL cải thiện đáng kể khả năng nhận diện các nhãn dương hiếm nhờ cơ chế asymmetric focusing và probability shift giúp loại bỏ gradient từ easy negatives. Việc gap giảm cũng cho thấy ASL giúp mô hình tổng quát hóa tốt hơn.

Focal Loss vs. ASL (D → B)

Focal Loss chỉ cải thiện rất nhỏ so với BCE: Test mAP tăng từ 0.7081 lên 0.7100 (+0.0019), nhưng vẫn thấp hơn ASL 0.0128 mAP.

Điều này cho thấy cơ chế focusing đối xứng của Focal Loss không đủ mạnh để xử lý tỉ lệ positive/negative $\approx 1:37$ trên MS COCO, trong khi ASL xử lý riêng biệt positive và negative samples nên hiệu quả hơn cho MLIC.

2) *Ảnh hưởng của Backbone*: Backbone đóng vai trò trích xuất đặc trưng ngữ nghĩa từ ảnh đầu vào. Để đánh giá ảnh hưởng của capacity mô hình, nhóm so sánh ResNet50 và EfficientNet-B0 trong cùng điều kiện loss ASL và không sử dụng CBAM.

ResNet50 vs. EfficientNet-B0 (B → F)

Khi thay ResNet50 bằng EfficientNet-B0: Test mAP giảm mạnh từ 0.7228 xuống 0.6463 (−0.0765).

Khoảng cách này phản ánh hiện tượng under-capacity của EfficientNet-B0 (3.63M tham số) đối với bài toán 80 lớp của MS COCO, so với ResNet50 (23.67M tham số).

Tuy nhiên, EfficientNet-B0 vẫn có ưu điểm về chi phí tính toán thấp hơn đáng kể, phù hợp với môi trường phần cứng hạn chế như Kaggle T4 16 GB.

3) *Ảnh hưởng của CBAM Attention*: CBAM được đưa vào nhằm tinh chỉnh feature map theo kênh và không gian trước bước phân loại. Mục tiêu là giúp mô hình tập trung vào vùng chứa đối tượng quan trọng trong bài toán MLIC.

CBAM trên ResNet50 (B → E)

Khi thêm CBAM vào ResNet50: Val mAP tăng nhẹ từ 0.7107 lên 0.7129, nhưng Test mAP gần như không đổi (0.7228 → 0.7223).

Trong khi đó, gap tăng đáng kể từ 0.1511 lên 0.2087 (+0.0576), cho thấy CBAM làm tăng xu hướng overfitting.

Kết quả này cho thấy ResNet50 đã đủ capacity để học đặc trưng phân biệt trên MS COCO; CBAM bổ sung thêm complexity nhưng không cải thiện khả năng tổng quát hóa.


CBAM trên EfficientNet-B0 (F → C)

Khi thêm CBAM vào EfficientNet-B0: Test mAP tăng nhẹ từ 0.6463 lên 0.6537 (+0.0074), cho thấy attention module vẫn giúp cải thiện khả năng định vị đối tượng.

Bảng V: Kết quả toàn diện 6 experiments trên tập test (3,952 ảnh). Val mAP lấy từ best epoch; Train mAP đánh giá trên 16,000 ảnh với checkpoint best.pth. Macro/Micro-F1 tại $\theta = 0.5$. **In đậm**: giá trị tốt nhất theo từng cột.

Exp	Val mAP	Train mAP	Test mAP	Gap (Δ)	Macro-F1	Micro-F1
B: ResNet50 + ASL	0.7107	0.8739	0.7228	0.1511	0.6927	0.7214
E: ResNet50 + CBAM + ASL	0.7129	0.9310	0.7223	0.2087	0.6961 [†]	0.7216 [†]
D: ResNet50 + Focal	0.7009	0.8665	0.7100	0.1565	0.6858	0.7153
A: ResNet50 + BCE	0.6908	0.8706	0.7081	0.1625	0.6836	0.7184
F: EffNet-B0 + ASL	0.6326	0.8132	0.6463	0.1669	0.6281	0.6615
C: EffNet-B0 + CBAM + ASL	0.6364	0.9168	0.6537	0.2631	0.6407	0.6804

[†] Val mAP của Exp E (0.7129) cao nhất, nhưng Test mAP thấp hơn Exp B — dấu hiệu overfitting. Gap Δ thấp hơn = generalize tốt hơn.



Hình 3: Đường cong Val mAP theo epoch của 6 experiments. Nhóm ResNet50 (Exp A, B, D, E) hội tụ chậm nhưng đạt plateau cao. Exp C (cam) plateau sớm tại epoch 8; Exp E (tím) có Val mAP cao nhưng Train mAP vọt 0.9310, dấu hiệu overfitting.

Tuy nhiên, gap tăng mạnh từ 0.1669 lên 0.2631 (+0.0962), cho thấy CBAM gây overfitting nghiêm trọng trên backbone nhỏ và tập train giới hạn.

Điều này cho thấy attention module có thể cải thiện khả năng tập trung không gian, nhưng đồng thời cũng làm mô hình dễ học các attention pattern đặc thù của training set.

4) **Đánh giá tổng thể kiến trúc đề xuất**: Kiến trúc đề xuất Exp C (EfficientNet-B0 + CBAM + ASL) đạt Test mAP 0.6537.

So với baseline mạnh nhất Exp B (ResNet50 + ASL), Exp C kém hơn 0.0691 mAP, chủ yếu do hai nguyên nhân: (i) backbone nhỏ bị under-capacity, và (ii) CBAM làm tăng overfitting.

Tuy nhiên, Exp C vẫn đạt được một trade-off hợp lý giữa hiệu năng và chi phí tính toán: EfficientNet-B0 nhẹ hơn ResNet50 khoảng $6.5\times$ và huấn luyện nhanh hơn đáng kể trên GPU T4, trong khi ASL vẫn duy trì hiệu quả xử lý imbalance labels.

C. Đường cong huấn luyện

Hình 3 cho thấy các pattern hội tụ khác biệt giữa hai nhóm backbone.

Nhóm ResNet50 (Exp A, B, D, E) hội tụ chậm nhưng ổn định, Val mAP tăng liên tục đến epoch 14–16 trước khi plateau. Exp B (ResNet50+ASL) đạt Val mAP đỉnh 0.7107, xác nhận ASL mang lại cải thiện nhất quán so với BCE (+0.0199) và Focal Loss (+0.0098). Đáng chú ý, Exp E (ResNet50+CBAM+ASL) đạt Val mAP cao nhất trong tất cả experiments (0.7129), song Train mAP đạt 0.9310 - gap 0.2087 lớn hơn Exp B (0.1511) - cho thấy CBAM tăng capacity nhưng cũng tăng nguy cơ overfitting trên tập 16,000 ảnh.

Bảng VI: 10 lớp có AP thấp nhất trên tập test (Exp C).

Lớp	AP	Nguyên nhân chính
hair drier	< 0.12	Rất hiếm (< 150 mẫu), thường bị che khuất
toothbrush	< 0.15	Kích thước nhỏ, màu sắc đa dạng
parking meter	< 0.20	Nền đô thị phức tạp, hình dạng dài mảnh
scissors	< 0.20	Nhỏ, nhiều tư thế, dễ lẫn nền
snowboard	< 0.30	Đồng xuất hiện với <i>person</i> , nền tuyết trắng
cell phone	< 0.40	Bị che bởi tay, góc nhìn đa dạng
mouse	< 0.45	Kích thước nhỏ, phụ thuộc context bàn làm việc
skis	< 0.45	Đồng xuất hiện với <i>snowboard</i>
remote	< 0.47	Hình dạng đơn giản, dễ nhầm lẫn
tie	< 0.47	Thường bị che bởi quần áo hoặc cơ thể

Nhóm EfficientNet-B0 (Exp C, F) hội tụ nhanh hơn nhưng plateau thấp hơn đáng kể. Exp C đạt đỉnh Val mAP 0.6364 tại epoch 8, sau đó dao động trong khoảng 0.616–0.628 trong khi Train loss tiếp tục giảm từ 0.943 (epoch 8) xuống 0.413 (epoch 16) - biểu hiện kinh điển của overfitting. Tốc độ hội tụ nhanh phản ánh capacity nhỏ (3.63M): mô hình bão hòa thông tin có thể trích xuất từ training set sớm hơn so với ResNet50.

D. Phân tích per-class AP

Để hiểu rõ hơn giới hạn của mô hình, nghiên cứu phân tích Average Precision (AP) theo từng lớp trên tập test của Exp C. Bảng VI liệt kê 10 lớp có AP thấp nhất.

Kết quả cho thấy các lớp có AP thấp chủ yếu thuộc ba nhóm khó: (i) vật thể rất nhỏ, (ii) vật thể hiếm trong dữ liệu, và (iii) vật thể phụ thuộc mạnh vào ngữ cảnh hoặc bị che khuất.

Đặc biệt, nhiều lớp như *hair drier*, *toothbrush* và *scissors* có kích thước rất nhỏ so với toàn ảnh. Trong khi đó, feature map cuối của EfficientNet-B0 chỉ còn kích thước 7×7 , tức mỗi ô đặc trưng đại diện cho vùng ảnh khá lớn. Do đó, thông tin chi tiết của vật thể nhỏ dễ bị mất trong quá trình downsampling.

Ngoài ra, Spatial Attention của CBAM được xây dựng trên feature map 7×7 , nên attention map cũng chỉ có độ phân giải thấp. Vì vậy, CBAM khó định vị chính xác các đối tượng nhỏ

hoặc mảnh. Điều này giải thích vì sao CBAM chỉ cải thiện nhẹ mAP tổng thể nhưng không giải quyết tốt các lớp small-object.

Kết quả này cho thấy một hạn chế cấu trúc quan trọng: attention trên feature map độ phân giải thấp không đủ mạnh cho bài toán multi-label chứa nhiều vật thể nhỏ. Trong tương lai, có thể cải thiện bằng: (i) multi-scale feature fusion, (ii) feature pyramid, hoặc (iii) attention ở tầng nông có độ phân giải cao hơn.

E. Phân tích định tính

Phân tích định tính (Hình 4) cho thấy hai pattern lỗi đặc trưng của hai mô hình.

(i) *Exp C thiên về False Negative trên lớp nhỏ và bị che khuất*: Exp C bỏ sót nhiều nhân có đối tượng nhỏ hoặc khó quan sát, điển hình Sample #2 (FN= 6): bỏ sót *bottle, spoon, banana, oven, sink, refrigerator* trong ảnh bếp tối, Sample #1 (FN= 4): bỏ sót *bird, backpack, umbrella, refrigerator* do các đối tượng nhỏ nằm rải rác trong khung cảnh lộn xộn, cho thấy EfficientNet-B0 (3.63M) thiếu capacity để học đặc trưng phân biệt cho các lớp ít mẫu.

(ii) *Exp B thiên về False Positive trên lớp co-occur cao*: Exp B predict thừa nhiều nhân không có mặt, Sample #1 (FP= 14): predict thêm *handbag, cup, fork, knife, spoon, orange, potted plant, cell phone, sink, refrigerator, book, clock, vase* trong ảnh bàn ăn gia đình; Sample #3 (FP= 8): predict thêm nhiều đồ vật bếp không xuất hiện *cup, oven, refrigerator* và một số vật dụng thường ngày *laptop, remote, book, couch, potted plant*, phản ánh bias co-occurrence mạnh trong tập train giữa các lớp đồ vật trong nhà. Như vậy, Exp C thiên về FN nhiều hơn do thiếu capacity, trong khi Exp B thiên về FP do backbone lớn hơn dễ kích hoạt các lớp có co-occurrence cao.

Hình 5 trực quan hóa không gian đặc trưng $\mathbf{v}$ qua t-SNE [11]. Các lớp phổ biến (*person, car, chair*) tạo cụm tách biệt, xác nhận EfficientNet-B0 có khả năng học đặc trưng phân biệt khi đủ mẫu train. Tuy nhiên, các lớp hiếm (*hair drier, toothbrush, scissors*) nằm rải rác hoặc overlap với cụm lân cận, đặc biệt *hair drier* overlap với cụm *person*, cho thấy không gian đặc trưng chưa đủ phân tách ngữ nghĩa khi số mẫu quá ít. Đây là nguyên nhân trực tiếp khiến AP của lớp hiếm ($< 0.12-0.20$) thấp hơn nhiều so với mAP trung bình (0.6537).

Hình 6 định lượng mức độ đồng xuất hiện giữa các lớp. Bias co-occurrence giải thích một phần lỗi FP của Exp C: khi *person* và *tie* đồng xuất hiện $> 30\%$ trong train set, mô hình học association thống kê thay vì nhận diện đặc trưng hình thái, dẫn đến predict *tie* mỗi khi nhận ra *person*. Tương tự, cặp *skis-snowboard* ($> 50\%$) khiến mô hình khó phân biệt ranh giới quyết định giữa hai lớp có bối cảnh và hình dạng tương đồng. Những quan sát này chỉ ra rằng ngưỡng per-class, thay vì ngưỡng toàn cục $\theta=0.5$, có tiềm năng cải thiện độ chính xác chống FP cho các lớp có co-occurrence cao.

VI. PHÂN TÍCH SÂU VÀ HẠN CHẾ

Mục này phân tích các hạn chế của mô hình đề xuất để từ đó có xem xét các hướng cải tiến tiếp theo.

Bảng VII: Phân tích overfitting: CBAM làm tăng gap đáng kể. Δ_{CBAM} = chênh lệch gap khi thêm CBAM.

Exp	Gap	Mức độ	Δ_{CBAM}
B: ResNet50 + ASL (ref.)	0.1511	Nhẹ	—
D: ResNet50 + Focal	0.1565	Nhẹ	—
A: ResNet50 + BCE	0.1625	Nhẹ	—
F: EffNet-B0 + ASL (ref.)	0.1669	Nhẹ	—
E: ResNet50 + CBAM + ASL	0.2087	Trung bình	+0.058
C: EffNet-B0 + CBAM + ASL	0.2631	Nặng	+0.096

A. Hạn chế 1: EfficientNet-B0 thiếu capacity

Khi so sánh cùng điều kiện, chỉ khác backbone:

- Exp F (EffNet-B0 + ASL, không CBAM): Test mAP = 0.6463
- Exp B (ResNet50 + ASL, không CBAM): Test mAP = 0.7228
- Chênh lệch: $\Delta = 0.0765$ - hoàn toàn do backbone

Hai thực nghiệm dùng cùng loss (ASL), cùng data, cùng hyperparameter. Khoảng cách 0.076 mAP xác nhận EfficientNet-B0 (3.63M) bị under-capacity cho bài toán 80 lớp phức tạp của MS COCO, so với ResNet50 (23.67M). Kết quả này gợi ý rằng backbone với capacity lớn hơn có thể cải thiện đáng kể khả năng phân tách đặc trưng trên 80 lớp COCO. Như vậy, ma trận phân loại $\mathbf{W}_{\text{fc}} \in \mathbb{R}^{80 \times 1280}$ cần học 80 prototype vector trong không gian 1280 chiều. Nếu EfficientNet-B0 không đủ khả năng phân tách (separate) các lớp trong không gian đặc trưng (do capacity nhỏ), thì dù CBAM tăng cường attention, $\mathbf{W}_{\text{fc}}$ không thể học prototype tốt. Hình 5 đã xác nhận: các lớp hiếm overlap nhiều trong không gian $\mathbf{v}$.


B. Hạn chế 2: CBAM làm tăng xu hướng overfitting trong thiết lập dữ liệu và backbone này.

Bảng VII phân tích định lượng tác động của CBAM lên overfitting.


Cơ chế overfit của CBAM: CBAM Spatial Attention học kernel $\mathbf{W}_{\text{sp}} \in \mathbb{R}^{1 \times 2 \times 7 \times 7}$, tạo attention map 7×7 . Với chỉ 16,000 ảnh train, mô hình có xu hướng học attention pattern *đặc thù từng ảnh* (vị trí góc, texture nền, ánh sáng đặc trưng) thay vì học semantic region tổng quát. Khi gặp test set có distribution khác, attention map không còn chính xác dẫn đến feature vector $\mathbf{v}$ kém chất lượng làm cho AP giảm.

Bằng chứng bổ sung. CBAM làm tăng xu hướng overfitting trên backbone nhỏ vì EfficientNet-B0 chỉ có 3.63M tham số, tỷ lệ tham số CBAM / tổng tham số cao hơn, khiến attention map dễ overspecialize hơn so với ResNet50. Bằng chứng: Δ_{CBAM} (EffNet) = +0.096 $>$ Δ_{CBAM} (ResNet) = +0.058.

Hướng khắc phục: Các nghiên cứu tương lai nên tập trung vào việc (a) tăng cường regularization (ví dụ: sử dụng dropout hoặc weight decay mạnh hơn) để giảm thiểu hiện tượng overspecialization của các trọng số attention, và (b) áp dụng các kỹ thuật augmentation tiên tiến (như RandAugment hoặc RandomErasing) nhằm đa dạng hóa phân phối dữ liệu huấn luyện, từ đó giúp mô hình học các biểu diễn khái quát hơn.




(a) Exp C (EfficientNet+CBAM+ASL)



(b) Exp B (ResNet50+ASL)

Hình 4: Dự đoán định tính trên test set (xanh = đúng, đỏ = sai). (a) Exp C bỏ sót lớp hiếm (FN) và nhầm lớp co-occur cao (FP); (b) Exp B đồng đều hơn nhờ backbone có đủ capacity.




Hình 5: t-SNE của feature vector v (sau GAP, Exp C, test set). Các lớp phổ biến tạo cụm tách biệt rõ; các lớp hiếm (*hair drier*, *scissors*) phân tán và overlap với các cụm lân cận.

C. Hạn chế 3: Threshold cố định $\theta = 0.5$ không tối ưu với ASL

ASL shift xác suất âm tính: $p_{\text{shift}} = \max(p - m, 0)$ với $m = 0.05$. Điều này kéo xác suất dự đoán xuống thấp hơn so với BCE.

Hệ quả:

- Lớp hiếm (*hair drier*): mô hình dự đoán $p \approx 0.30 - 0.45$, thấp hơn ngưỡng $\theta = 0.5$, nên bị phân loại thành False Negative.
- Lớp phổ biến (*person*): $p \approx 0.70 - 0.90$, cho thấy threshold 0.5 hoạt động tốt.



Hình 6: Ma trận co-occurrence chuẩn hóa giữa các lớp (val set). Cặp *person-tie* (> 30%), *person-handbag* (> 25%) và *baseball glove-person* (> 40%) có bias cao nhất.

Từ đó, có thể nhận định rằng, Macro-F1 của Exp C (0.6407) thấp hơn Exp A BCE (0.6836) dù mAP của ASL cao hơn BCE về nguyên tắc.

mAP là độ đo không phụ thuộc ngưỡng phân loại (dựa trên diện tích dưới đường cong Precision - Recall), nên ASL vẫn đạt mAP tốt hơn.

Tuy nhiên, F1 tại ngưỡng $\theta = 0.5$ bị ảnh hưởng bởi sự dịch chuyển phân phối xác suất.

Hướng khắc phục có thể thử là hiệu chỉnh ngưỡng riêng

Bảng VIII: Các dạng lỗi điển hình của Exp C trên tập test.

Loại lỗi	Ví dụ	Nguyên nhân chính	Hướng cải thiện
FN	<i>hair drier</i> bị bỏ sót	Lớp hiếm, vật thể nhỏ, thường bị che khuất	Re-balancing, adaptive threshold
FP	Predict <i>tie</i> khi không có	Co-occurrence cao với <i>person</i>	Debiasing, hard negative mining
Nhầm lớp	<i>skis</i> ↔ <i>snowboard</i>	Hình dạng và bối cảnh tương tự	Contrastive representation learning
Out-of-dist.	Ảnh ban đêm, góc chụp cực	Khác phân phối train	Strong augmentation

cho từng lớp trên tập validation thay vì dùng ngưỡng toàn cục $\theta=0.5$. Backbone có capacity lớn hơn cũng sẽ cho xác suất dự đoán tập trung hơn, từ đó giảm nhạy cảm với ngưỡng.

D. Phân tích lỗi điển hình

Bảng VIII tổng hợp các dạng lỗi dự đoán tiêu biểu của Exp C trên tập test.

Kết quả cho thấy lỗi của mô hình không chỉ đến từ mất cân bằng nhãn, mà còn liên quan đến hiện tượng đồng xuất hiện nhãn (label co-occurrence), độ nhỏ của vật thể và sự thay đổi phân phối dữ liệu giữa train/test. Đặc biệt, threshold cố định $\theta = 0.5$ có xu hướng gây false negative trên các lớp hiếm và false positive trên các lớp có tương quan ngữ cảnh mạnh. Điều này cho thấy tiềm năng của các phương pháp adaptive threshold hoặc class-wise calibration để cân bằng precision và recall giữa các lớp.

VII. KẾT LUẬN

Đề án này đã nghiên cứu ảnh hưởng của backbone, attention mechanism và loss function đối với bài toán phân loại ảnh đa nhãn trên MS COCO. Kiến trúc kết hợp EfficientNet-B0, CBAM, và ASL được đánh giá thông qua ablation study gồm 6 thực nghiệm đối chứng.

Kết quả cho thấy ASL cải thiện đáng kể khả năng học đa nhãn so với BCE và Focal Loss nhờ giảm ảnh hưởng của easy negatives. Ngược lại, CBAM không luôn cải thiện khả năng tổng quát hóa, đặc biệt khi kết hợp với backbone nhỏ hoặc dữ liệu huấn luyện hạn chế. Ngoài ra, ResNet50 cho hiệu quả vượt trội hơn EfficientNet-B0, cho thấy capacity backbone đóng vai trò quan trọng trong bài toán MLIC trên MS COCO.

Các hướng phát triển tiếp theo bao gồm: (i) sử dụng backbone có capacity lớn hơn, (ii) tăng cường regularization và augmentation để giảm overfitting của attention, và (iii) tối ưu threshold theo từng lớp nhằm cải thiện cân bằng giữa precision và recall.

Mã nguồn được công khai tại <https://github.com/Thinh59/ECAAL>.

TÀI LIỆU

[1] T.-Y. Lin *et al.*, “Microsoft COCO: Common objects in context,” in *Proc. ECCV*, pp. 740–755, 2014.

[2] M. Tan and Q. V. Le, “EfficientNet: Rethinking model scaling for convolutional neural networks,” in *Proc. ICML*, pp. 6105–6114, 2019.

[3] J. Wang, Y. Yang, J. Mao, Z. Huang, C. Huang, and W. Xu, “CNN-RNN: A unified framework for multi-label image classification,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, pp. 2285–2294, 2016.

[4] T. Ridnik, E. Ben-Baruch, N. Zamir, A. Noy, I. Friedman, M. Protter, and L. Zelnik-Manor, “Asymmetric loss for multi-label classification,” in *Proc. IEEE/CVF ICCV*, pp. 82–91, 2021.

[5] S. Woo, J. Park, J.-Y. Lee, and I. S. Kweon, “CBAM: Convolutional block attention module,” in *Proc. ECCV*, pp. 3–19, 2018.

[6] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proc. IEEE CVPR*, pp. 770–778, 2016.

[7] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal loss for dense object detection,” in *Proc. IEEE/CVF ICCV*, pp. 2980–2988, 2017.

[8] J. Hu, L. Shen, and G. Sun, “Squeeze-and-excitation networks,” in *Proc. IEEE CVPR*, pp. 7132–7141, 2018.

[9] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.

[10] M.-L. Zhang and Z.-H. Zhou, “A review on multi-label learning algorithms,” *IEEE Trans. Knowl. Data Eng.*, vol. 26, no. 8, pp. 1819–1837, Aug. 2014.

[11] L. van der Maaten and G. Hinton, “Visualizing data using t-SNE,” *J. Mach. Learn. Res.*, vol. 9, pp. 2579–2605, 2008.