

Phân loại Ảnh Đa nhãn sử dụng kiến trúc EfficientNet-B3, CBAM và Asymmetric Loss với Strong Augmentation

Phan Huỳnh Châu Thịnh

MSSV: 23122019

Khoa CNTT, ĐHKH Tự nhiên, ĐHQG TP.HCM
23122019@student.hcmus.edu.vn

Hoàng Văn Sang

MSSV: 23120350

Khoa CNTT, ĐHKH Tự nhiên, ĐHQG TP.HCM
23120350@student.hcmus.edu.vn

Tóm tắt nội dung—Phân loại ảnh đa nhãn đóng vai trò quan trọng trong nhiều ứng dụng như truy xuất ảnh ngữ nghĩa, phân tích ảnh y tế và nhận dạng cảnh vật, trong đó mỗi ảnh có thể chứa đồng thời nhiều đối tượng. Đồ án này đề xuất kiến trúc EfficientNet-B3, CBAM và Asymmetric Loss kết hợp Strong Augmentation cho bài toán phân loại ảnh đa nhãn trên tập dữ liệu MS COCO 2017 (80 lớp) trong điều kiện phần cứng hạn chế (GPU T4, 16 GB VRAM).

Hệ thống sử dụng EfficientNet-B3 để tăng khả năng trích xuất đặc trưng, CBAM để tăng cường attention theo kênh và không gian, và Asymmetric Loss (ASL) để xử lý mất cân bằng nhãn trong bài toán MLIC. Ngoài ra, RandAugment, RandomErasing và Dropout được kết hợp nhằm giảm overfitting và cải thiện khả năng tổng quát hóa trên tập dữ liệu giới hạn (16,000 ảnh train).

Kết quả thực nghiệm cho thấy mô hình đạt Val mAP = 0.7188, Test mAP = 0.6753 và Macro-F1 = 0.6989, đồng thời giảm overfitting gap 23.6% so với kiến trúc EfficientNet-B0 + CBAM + ASL trước đó. Các kết quả này cho thấy việc tăng capacity của backbone kết hợp strong augmentation mang lại hiệu quả rõ rệt cho bài toán phân loại ảnh đa nhãn trong điều kiện dữ liệu và phần cứng hạn chế.

Index Terms—phân loại đa nhãn, EfficientNet-B3, CBAM, Asymmetric Loss, MS COCO, ablation study, overfitting, RandAugment, strong augmentation

I. GIỚI THIỆU

Phân loại ảnh đa nhãn (Multi-label Image Classification – MLIC [3]) là bài toán gán đồng thời nhiều nhãn cho một ảnh đầu vào. Khác với phân loại đơn nhãn dùng softmax (tổng xác suất = 1), MLIC dự đoán xác suất độc lập $p_i \in [0, 1]$ cho từng nhãn bằng sigmoid cho phép một ảnh chứa đồng thời nhiều đối tượng. Trong thực tế, MLIC là nền tảng của nhiều ứng dụng quan trọng như truy xuất ngữ nghĩa ảnh, phân tích ảnh y tế đa bệnh lý, nhận dạng đối tượng trong xe tự lái, và kiểm duyệt nội dung.

Trên tập dữ liệu MS COCO có tổng cộng 80 lớp, mỗi ảnh trung bình chỉ chứa 2–3 nhãn dương tính, tức ≈ 77 nhãn âm tính đi kèm (tỉ lệ positive/negative $\approx 1:37$), điều này làm cho MLIC gặp nhiều khó khăn khi các mô hình sẽ chỉ dự đoán các nhãn đều âm tính thì vẫn đạt được kết quả cao. Đặc biệt khi hàm mất mát BCE truyền thống không có cơ chế phân biệt gradient từ easy negatives và hard positives, dẫn đến mô hình thiên lệch về phía âm tính và bỏ sót nhiều nhãn dương quan

trọng. Bên cạnh đó, trong điều kiện phần cứng hạn chế (GPU T4, 16 GB VRAM) và dữ liệu hạn chế (16,000 ảnh train), việc chọn backbone đủ capacity và kiểm soát overfitting là thách thức không kém phần quan trọng.

Trong nghiên cứu trước đó (Exp C: EfficientNet-B0, CBAM và ASL), nhóm đã đạt Val mAP = 0.6364, Test mAP = 0.6537 và xác định được ba hạn chế cấu trúc rõ ràng qua các thực nghiệm ablation study. Đó là vấn đề EfficientNet-B0 (3.63M) bị under-capacity so với bài toán 80 lớp; CBAM gây overfit nặng trên dataset nhỏ; và ASL probability shift làm threshold cố định $\theta=0.5$ không tối ưu. Ba hạn chế này có cơ sở định lượng cụ thể và là động lực trực tiếp cho kiến trúc Exp G được đề xuất trong phần này.

Đồ án này đề xuất **Exp G** – kiến trúc EfficientNet-B3, CBAM và ASL kết hợp Strong Augmentation, giải quyết đồng thời ba hạn chế trên và xác nhận hiệu quả thông qua ablation study được thiết kế với 7 kịch bản (Exp A–G).

Đóng góp chính của nghiên cứu:

- Đề xuất kiến trúc EfficientNet-B3, CBAM, ASL và Strong Augmentation (Exp G) cho MLIC trong điều kiện phần cứng hạn chế, mỗi thay đổi so với Exp C được lý giải định lượng rõ ràng từ các thực nghiệm ablation study Exp A–F.
- Phân tích so sánh giữa Exp G và Exp C trên các phương diện: mAP, F1, overfitting gap, không gian đặc trưng (t-SNE), per-class AP, co-occurrence bias và dự đoán định tính.

Các phần tiếp theo: Mục II – công trình liên quan; Mục III – kiến trúc Exp G và động lực thiết kế; Mục IV – thiết lập thực nghiệm; Mục V – kết quả thực nghiệm và phân tích các thành phần, hạn chế của kiến trúc. Mục VI – đối chiếu với nghiên cứu liên quan; Mục VII – kết luận.

II. CÔNG TRÌNH LIÊN QUAN

A. Backbone cho phân loại đa nhãn

ResNet [8] với kết nối tắt (skip connections) giải quyết vấn đề gradient bị suy giảm dần khi lan truyền ngược qua nhiều lớp (gradient vanishing), trở thành backbone tiêu chuẩn cho nhiều tác vụ thị giác. ResNet50 (23.67M tham số) là baseline phổ biến trong MLIC.

EfficientNet [2] đề xuất compound scaling: đồng thời tăng chiều sâu, chiều rộng và độ phân giải theo hệ số (α, β, γ) thỏa $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$. EfficientNet-B0 (3.63M) đạt độ chính xác ngang ResNet50 với FLOPs thấp hơn $6.5\times$, phù hợp môi trường hạn chế. EfficientNet-B3 (12M, $\phi=3$) là bước compound scaling tiếp theo, feature map cuối $\mathbb{R}^{1536 \times 8 \times 8}$, cung cấp capacity cao hơn B0 đáng kể mà vẫn khả thi trong giới hạn VRAM 16 GB.

B. Cơ chế chú ý trong CNN

SE-Net [10] giới thiệu Squeeze-and-Excitation: Squeeze bằng Global Average Pooling, Excitation bằng FC và sigmoid để học trọng số kênh. SE-Net chỉ có Channel Attention, bỏ qua thông tin không gian Spatial Attention.

CBAM [7] mở rộng SE-Net với hai nhánh tuần tự: Channel Attention ("what to focus") và Spatial Attention ("where to focus"). CBAM thêm chỉ $\approx 2,000$ tham số nhưng cải thiện đáng kể trên nhiều tác vụ phân loại và phát hiện đối tượng. Tuy nhiên, trên dataset nhỏ và backbone nhỏ, CBAM Spatial Attention có xu hướng overspecialize vào pattern đặc thù của training set, hạn chế được định lượng rõ trong ablation study của đồ án này ($\Delta_{\text{CBAM}} = +0.096$ trên EffNet-B0).

C. Data Augmentation

RandAugment [14] tự động chọn ngẫu nhiên N phép biến đổi (rotation, color jitter, shear, solarize, ...) với cường độ M từ một không gian K phép biến đổi. So với AutoAugment, RandAugment chỉ cần tìm kiếm 2 siêu tham số (N, M) thay vì toàn bộ chính sách, phù hợp với môi trường phần cứng hạn chế.

RandomErasing [15] ngẫu nhiên che một vùng hình chữ nhật trong ảnh, buộc mô hình học đặc trưng phân tán thay vì phụ thuộc một vùng cục bộ. Trong ngữ cảnh đồ án này, RandomErasing đặc biệt hữu ích để phá vỡ xu hướng overspecialization của CBAM Spatial Attention: khi một vùng bị che ngẫu nhiên, attention map không thể cố định vào vị trí đặc thù của từng ảnh.

D. Hàm mất mát cho phân loại đa nhãn

BCE [11] là baseline cơ bản, không xử lý mất cân bằng. Focal Loss [9] áp dụng hệ số $(1-p)^\gamma$ đối xứng, giảm trọng số easy samples nhưng không phân biệt nhãn dương và âm. ASL [4] xử lý bất đối xứng: γ_+ nhỏ cho dương, γ_- lớn cho âm, kết hợp probability shift m để triệt tiêu hoàn toàn easy negatives. ASL đạt state-of-the-art trên MS COCO, Pascal VOC và Open Images.

E. Các mô hình MLIC hiện đại

ML-Decoder [5] dùng transformer decoder với grouped decoding queries để thay thế global average pooling. Đạt mAP 90.1% trên MS COCO full với TResNet-L backbone.

Query2Label [6] dùng DETR-style cross-attention giữa image feature và label queries, mỗi query đại diện một nhãn. Đạt mAP 84.9% trên MS COCO full với ResNet-101.

Khoảng trống nghiên cứu: Mặc dù ASL đã được kiểm chứng với backbone nặng (TResNet-L, $\approx 50\text{M}$) và các mô hình transformer-based (ML-Decoder, Query2Label) đạt kết quả ấn

tượng trên full dataset, chưa có nghiên cứu hệ thống hóa hiệu năng của bộ ba ASL, CBAM và EfficientNet kết hợp trong augmentation trong điều kiện phần cứng thực sự hạn chế (GPU T4 16 GB, 16,000 ảnh train). Đặc biệt, cả ML-Decoder và Query2Label đều đòi hỏi self-attention $O(L^2)$ trên 80 labels và GPU A100, vượt khả năng Kaggle T4 hoàn toàn. Đồ án này giải quyết vấn đề đó qua kiến trúc và phân tích từ các thực nghiệm ablation study 7 kịch bản (A–G).

III. KIẾN TRÚC ĐỀ XUẤT (EXP G)

A. Động lực thiết kế từ phân tích Exp C

Trước khi mô tả kiến trúc Exp G, cần phân tích rõ các hạn chế của kiến trúc trước đó (EffNet-B0, ASL, CBAM).

Hạn chế 1 – Under-capacity backbone. So sánh Exp F (EffNet-B0, ASL, không CBAM) và Exp B (ResNet50, ASL, không CBAM) trong cùng điều kiện huấn luyện cho thấy Test mAP tăng từ 0.6463 lên 0.7228 ($\Delta = 0.0765$), cho thấy backbone đóng vai trò quan trọng trong chất lượng biểu diễn đặc trưng.

EfficientNet-B0 (3.63M tham số) có thể chưa đủ capacity để học không gian biểu diễn phân biệt cho 80 lớp COCO. Phân tích t-SNE cho thấy các lớp hiếm vẫn còn overlap đáng kể trong không gian đặc trưng của B0. Quan sát này là động lực để chuyển sang EfficientNet-B3 (12M tham số) nhằm tăng khả năng biểu diễn trong khi vẫn phù hợp với giới hạn phần cứng.

Hạn chế 2 – Xu hướng overfitting của CBAM. So sánh cặp F $\rightarrow$ C (EffNet-B0 không CBAM vs. có CBAM) cho thấy Test mAP chỉ tăng $+0.0074$ nhưng train-test gap tăng mạnh $+0.0962$. Tương tự, ở cặp B $\rightarrow$ E (ResNet50 không CBAM vs. có CBAM), Test mAP gần như không đổi (-0.0005) trong khi gap tăng $+0.0576$.

Kết quả này cho thấy CBAM có xu hướng làm tăng nguy cơ overfitting, đặc biệt trên backbone nhỏ nơi tỷ lệ tham số attention so với tổng số tham số cao hơn. Ngoài ra, Spatial Attention có thể trở nên nhạy với các pattern đặc thù ảnh như texture nền, vị trí đối tượng hoặc điều kiện ánh sáng khi dữ liệu huấn luyện còn hạn chế. Quan sát này thúc đẩy việc sử dụng regularization mạnh hơn trong Exp G, bao gồm trong augmentation và tăng dropout.

Hạn chế 3 – Threshold sensitivity với ASL. ASL sử dụng cơ chế dịch xác suất âm:

$$p_{\text{shift}} = \max(p - m, 0), \quad m = 0.05. \quad (1)$$

Mặc dù cơ chế này cải thiện khả năng xếp hạng (ranking) và giúp mAP tốt hơn BCE, xác suất dự đoán của các lớp hiếm thường tập trung trong khoảng trung gian (0.30–0.45). Do đó, nhiều dự đoán đúng về mặt thứ hạng vẫn nằm dưới ngưỡng $\theta = 0.5$ khi tính F1-score.

Hiện tượng này thể hiện qua việc Exp C đạt mAP cao hơn nhưng Macro-F1 thấp hơn so với Exp A dùng BCE. Quan sát này gợi ý cần các cơ chế regularization giúp mô hình học phân bố xác suất phân biệt rõ ràng hơn.

B. Pipeline tổng thể của Exp G

Kiến trúc Exp G gồm pipeline feed-forward qua năm giai đoạn:

$$\mathbf{x} \xrightarrow{\text{StrongAug}} \hat{\mathbf{x}} \xrightarrow{\text{EffNet-B3}} \mathbf{F} \xrightarrow{\text{CBAM}} \tilde{\mathbf{F}} \xrightarrow{\text{GAP}} \mathbf{v} \xrightarrow{\text{FC+Dropout}} \mathbf{z} \xrightarrow{\text{ASL}} \mathcal{L} \quad (2)$$

trong đó $\hat{\mathbf{x}} \in \mathbb{R}^{3 \times 224 \times 224}$ là ảnh sau augmentation, $\mathbf{F} \in \mathbb{R}^{1536 \times 8 \times 8}$ là feature map cuối của EfficientNet-B3, $\tilde{\mathbf{F}} \in \mathbb{R}^{1536 \times 8 \times 8}$ là feature map sau CBAM, $\mathbf{v} \in \mathbb{R}^{1536}$ là vector đặc trưng sau Global Average Pooling (GAP), và $\mathbf{z} \in \mathbb{R}^{80}$ là vector logit đầu ra trước sigmoid. Hình 1 minh họa kiến trúc tổng thể của Exp G.

So với Exp C, Exp G có ba thay đổi chính: (1) thay backbone EfficientNet-B0 bằng EfficientNet-B3, (2) bổ sung strong augmentation gồm RandAugment và RandomErasing, và (3) tăng dropout từ 0.3 lên 0.5. Các thành phần còn lại gồm CBAM, GAP, fully connected head và ASL được giữ nguyên.

C. Backbone: EfficientNet-B3

EfficientNet sử dụng cơ chế compound scaling để đồng thời mở rộng chiều sâu, chiều rộng và độ phân giải đầu vào:

$$d = \alpha^\phi, \quad w = \beta^\phi, \quad r = \gamma^\phi, \quad \alpha \cdot \beta^2 \cdot \gamma^2 \approx 2 \quad (3)$$

trong đó $(\alpha, \beta, \gamma) = (1.2, 1.1, 1.15)$ được xác định bởi NAS từ bài báo gốc, kế thừa trọng số pretrained. EfficientNet-B0 là kiến trúc cơ sở với khoảng 3.63M tham số, trong khi EfficientNet-B3 mở rộng lên khoảng 12M tham số thông qua compound scaling với $\phi = 3$.

EfficientNet-B3 được lựa chọn nhằm tăng khả năng biểu diễn đặc trưng so với EfficientNet-B0 nhưng vẫn đảm bảo phù hợp với giới hạn phần cứng. Kết quả thực nghiệm ở Exp F và Exp B cho thấy EfficientNet-B0 thấp hơn ResNet50 khoảng 0.076 mAP trong cùng điều kiện huấn luyện, gợi ý rằng backbone B0 chưa đủ capacity cho bài toán multi-label classification trên MS COCO.

So với ResNet50, EfficientNet-B3 đạt hiệu quả tham số tốt hơn, đồng thời vẫn duy trì batch size ổn định trên GPU T4 16 GB khi kết hợp với CBAM và OneCycleLR. Các phiên bản lớn hơn như B4 hoặc B5 yêu cầu batch size nhỏ hơn, làm giảm độ ổn định trong quá trình huấn luyện.

Feature map cuối của EfficientNet-B3 có kích thước $\mathbb{R}^{1536 \times 8 \times 8}$, lớn hơn so với $\mathbb{R}^{1280 \times 7 \times 7}$ của EfficientNet-B0. Không gian đặc trưng lớn hơn giúp CBAM Spatial Attention khai thác thông tin không gian hiệu quả hơn trong quá trình tinh chỉnh attention map.

Toàn bộ backbone được khởi tạo từ trọng số pretrained ImageNet-1K (thư viện timm) và được fine-tune end-to-end trong quá trình huấn luyện.

D. Neck: CBAM

CBAM được sử dụng như một attention neck nhằm tinh chỉnh feature map theo cả chiều kênh và không gian. Trong bài toán multi-label image classification, mỗi nhãn thường liên quan đến một vùng không gian cụ thể trong ảnh. Do đó, Spatial Attention giúp mô hình tập trung vào các vùng mang

hiều thông tin ngữ nghĩa trước khi thực hiện Global Average Pooling (GAP).

CBAM gồm hai cơ chế attention áp dụng tuần tự: Channel Attention và Spatial Attention.

Channel Attention:

$$\mathbf{M}_c = \sigma(\text{MLP}(\text{AvgPool}(\mathbf{F})) + \text{MLP}(\text{MaxPool}(\mathbf{F}))) \quad (4)$$

trong đó MLP sử dụng shared weights để xử lý cả AvgPool và MaxPool với reduction ratio $r = 16$ giúp giảm chiều của MLP để tiết kiệm số lượng tham số. Attention map theo kênh được áp dụng lên feature map:

$$\mathbf{F}' = \mathbf{M}_c \otimes \mathbf{F} \quad (5)$$

Spatial Attention:

$$\mathbf{M}_s = \sigma(\text{Conv}_{7 \times 7}([\text{Avg}_c(\mathbf{F}'), \text{Max}_c(\mathbf{F}')])) \quad (6)$$

Spatial Attention tiếp tục tinh chỉnh đặc trưng theo chiều không gian:

$$\tilde{\mathbf{F}} = \mathbf{M}_s \otimes \mathbf{F}' \quad (7)$$

Kết quả thực nghiệm ở Exp C cho thấy CBAM giúp cải thiện nhẹ mAP, nhưng đồng thời làm tăng khoảng cách giữa validation và test performance, gợi ý xu hướng overfitting khi attention học các đặc trưng quá đặc thù. Tuy nhiên, do CBAM vẫn mang lại cải thiện về khả năng biểu diễn đặc trưng, module này được giữ lại trong Exp G và được kết hợp với strong augmentation cùng dropout mạnh hơn nhằm tăng khả năng regularization.

E. Strong Augmentation

Strong augmentation được sử dụng như cơ chế regularization chính trong Exp G nhằm giảm xu hướng overfitting của attention module và tăng khả năng tổng quát hóa của mô hình. Hai kỹ thuật augmentation được sử dụng gồm RandAugment và RandomErasing.

RandAugment ($N = 2, M = 9$): Mỗi ảnh đầu vào được áp dụng ngẫu nhiên $N = 2$ phép biến đổi từ tập augmentation gồm rotation, color jitter, shear, solarize, equalize, posterize, ... với cường độ biến đổi $M = 9$ (thang 0–30).


Về mặt hình thức, nếu $\mathcal{T} = \{t_1, \dots, t_K\}$ là tập các phép biến đổi, RandAugment chọn ngẫu nhiên hai phép biến đổi (t_i, t_j) và tạo ảnh augment:

$$\hat{\mathbf{x}} = t_j(t_i(\mathbf{x})) \quad (8)$$


Việc thay đổi liên tục màu sắc, góc xoay và cấu trúc ảnh làm giảm khả năng attention module phụ thuộc vào các đặc trưng cục bộ hoặc vị trí cố định trong tập huấn luyện. Nhờ đó, mô hình được khuyến khích học các đặc trưng mang tính ngữ nghĩa tổng quát hơn.

RandomErasing ($p = 0.3, \text{scale} = [0.02, 0.2]$): Với xác suất $p = 0.3$, một vùng hình chữ nhật ngẫu nhiên chiếm khoảng 2%–20% diện tích ảnh sẽ bị che bằng giá trị ngẫu nhiên. Kỹ thuật này mô phỏng các trường hợp đối tượng bị che khuất một phần, từ đó tăng khả năng robust của mô hình trước occlusion.

Việc kết hợp RandAugment và RandomErasing giúp attention module khó học các pattern quá đặc thù từ tập huấn luyện,



Hình 1: Tổng quan kiến trúc Exp G cho bài toán multi-label image classification. Ảnh đầu vào trước hết được áp dụng trong augmentation gồm RandAugment và RandomErasing. EfficientNet-B3 được sử dụng làm backbone để trích xuất đặc trưng thị giác, sau đó CBAM tinh chỉnh feature map theo attention kênh và không gian. Feature map được tổng hợp bằng Global Average Pooling và regularize bằng Dropout ($p = 0.5$) trước khi đưa qua fully connected layer để dự đoán logits cho 80 lớp của MS COCO. Trong quá trình huấn luyện, Asymmetric Loss (ASL) được sử dụng nhằm giảm ảnh hưởng của easy negatives và cải thiện khả năng học trên các nhãn dương hiếm.



Hình 2: Kiến trúc CBAM [7] sử dụng trong Exp G. Module gồm hai thành phần tuần tự: Channel Attention và Spatial Attention.

đồng thời cải thiện khả năng regularization khi kết hợp với CBAM.

Ngoài ra, trong augmentation cũng làm tăng độ khó của bài toán huấn luyện, buộc mô hình học các biểu diễn đặc trưng ổn định hơn. Trong thực nghiệm, điều này giúp phân bố xác suất dự đoán ít tập trung ở vùng trung gian hơn, đặc biệt với các lớp hiếm, qua đó cải thiện hiệu quả của ngưỡng phân loại cố định $\theta = 0.5$.

F. Head: Fully Connected + Dropout

Sau khi feature map được tinh chỉnh bởi CBAM, Global Average Pooling (GAP) được sử dụng để tổng hợp đặc trưng thành vector toàn cục $\mathbf{v} \in \mathbb{R}^{1536}$. Vector này sau đó được ánh xạ sang không gian nhãn gồm 80 lớp của MS COCO thông qua fully connected layer:

$$\mathbf{z} = \mathbf{W}_{fc} \text{Dropout}(\mathbf{v}) + \mathbf{b} \quad (9)$$

trong đó $\mathbf{W}_{fc} \in \mathbb{R}^{80 \times 1536}$ là ma trận trọng số phân loại, và $\mathbf{z} \in \mathbb{R}^{80}$ là vector logit trước sigmoid.

Về mặt hình học, mỗi hàng của ma trận $\mathbf{W}_{fc}$ có thể được xem như một vector đại diện cho một lớp trong không gian đặc trưng. Quá trình phân loại tương ứng với việc đo mức độ tương quan giữa đặc trưng ảnh $\mathbf{v}$ và các vector lớp này.

Dropout được sử dụng như một cơ chế regularization nhằm giảm overfitting trong quá trình huấn luyện. Ở mỗi iteration, một phần chiều đặc trưng của $\mathbf{v}$ được vô hiệu hóa ngẫu nhiên, giúp mô hình giảm phụ thuộc vào một số activation cụ thể và cải thiện khả năng tổng quát hóa.

So với Exp C, tỷ lệ dropout được tăng từ 0.3 lên 0.5 để phù hợp với backbone EfficientNet-B3 có capacity lớn hơn. Cơ chế này đóng vai trò bổ sung cho trong augmentation: augmentation regularize ở mức dữ liệu đầu vào, trong khi dropout regularize ở không gian đặc trưng.

Bảng I: So sánh các hàm mất mát cho MLIC.

Loss	Nhân âm/dương	Easy neg.	Mislabel
BCE	Đối xứng	Không	Không
Focal	Đối xứng	Khá	Thấp
ASL	Bất đối xứng	Tuyệt đối	Cao

G. Loss: Asymmetric Loss (ASL)

Khác với Binary Cross-Entropy (BCE) chỉ tối ưu xác suất dự đoán, ASL điều chỉnh phân bố gradient giữa positive và negative samples. Bằng cách giảm ảnh hưởng của easy negatives, ASL giúp mô hình tập trung nhiều hơn vào positive samples và hard negatives, đặc biệt phù hợp với bài toán multi-label image classification khi số lượng negative labels áp đảo.

$$\mathcal{L}_{ASL} = -\frac{1}{C} \sum_{i=1}^C \begin{cases} (1 - p_i)^{\gamma_+} \log p_i & y_i = 1 \\ (p_{i, \text{shift}})^{\gamma_-} \log(1 - p_{i, \text{shift}}) & y_i = 0 \end{cases} \quad (10)$$

trong đó $p_{i, \text{shift}} = \max(p_i - m, 0)$, $m = 0.05$ là probability margin, $\gamma_+ = 0$ và $\gamma_- = 4$.

Đối với negative samples có $p_i < m$, ta có $p_{i, \text{shift}} = 0$, khiến đóng góp gradient của các mẫu này trở nên không đáng kể. Nhờ đó, quá trình tối ưu tập trung chủ yếu vào hard negatives ($p_i > m$) và positive samples.

So với BCE, ASL bổ sung cơ chế margin cho negative samples nhằm giảm ảnh hưởng của easy negatives. Trong khi đó, Focal Loss áp dụng cơ chế re-weighting - nhân thêm một hệ số vào loss - đối xứng cho cả positive và negative samples, nên không triệt tiêu hoàn toàn ảnh hưởng của easy negatives.

Sự khác biệt giữa các hàm mất mát được tóm tắt trong Bảng I.

IV. THIẾT LẬP THỰC NGHIỆM

A. Tập dữ liệu

MS COCO 2017 [1] gồm 80 lớp đối tượng phổ biến cho bài toán multi-label image classification. Do giới hạn tài nguyên tính toán, nghiên cứu sử dụng một tập con của MS COCO được xây dựng bằng stratified sampling với tiêu chí số lượng nhãn của các ảnh nhằm bảo toàn phân phối nhãn giữa các tập train, validation và test.

Cụ thể, dữ liệu được chia thành 16,000 ảnh train, 1,000 ảnh validation và 3,952 ảnh test. Tập train được ưu tiên lớn hơn nhằm đảm bảo đủ dữ liệu cho quá trình fine-tuning các backbone sâu, trong khi tập validation được giữ ở kích thước vừa đủ để lựa chọn siêu tham số và kiểm soát overfitting. Phần dữ liệu còn lại được sử dụng làm tập test độc lập để đánh giá khả năng tổng quát hóa của mô hình.

B. Tiền xử lý và Augmentation

Thiết lập chuẩn (Exp A-F): Trong giai đoạn huấn luyện, ảnh đầu vào được resize về 256×256 , sau đó áp dụng RandomCrop 224×224 , RandomHorizontalFlip ($p=0.5$), và ColorJitter (brightness = contrast = saturation = 0.2, hue = 0.1). Cuối cùng, ảnh được chuẩn hóa theo thống kê ImageNet: $\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$.

Bảng II: Thống kê tập MS COCO subset.

Thống kê	Train	Val	Test
Số ảnh	16,000	1,000	3,952
Số lớp	80	80	80
Avg labels/img	2.70	2.68	2.72
Pos/Neg ratio	1:37	1:37	1:37
Lớp nhiều nhất	person ($\approx 7,000$ train)		
Lớp ít nhất	hair drier (< 150 train)		

Bảng III: Thiết kế ablation study: 7 kịch bản thực nghiệm.

Exp	Mô tả	Backbone	CBAM	Loss
A	Baseline	ResNet50	✗	BCE
B	ASL thay BCE	ResNet50	✗	ASL
C	Mô hình tiền nhiệm	EffNet-B0	✓	ASL
D	Focal Loss	ResNet50	✗	Focal
E	ResNet, CBAM và ASL	ResNet50	✓	ASL
F	EffNet-B0 và ASL	EffNet-B0	✗	ASL
G	Đề xuất	EffNet-B3	✓	ASL

Exp G bổ sung so với Exp C: backbone B3, RandAugment ($N=2, M=9$), RandomErasing ($p=0.3$), Dropout 0.5, LR 2×10^{-4} , batch 32.

Thiết lập Strong Augmentation (Exp G): Exp G kế thừa toàn bộ pipeline của Exp C và bổ sung thêm hai phép tăng cường dữ liệu: RandAugment ($N=2, M=9$) được áp dụng trước ColorJitter, và RandomErasing ($p=0.3$, scale $[0.02, 0.2]$) được áp dụng sau bước chuẩn hóa.

Đối với tập validation và test, tất cả các thực nghiệm đều sử dụng cùng một pipeline: Resize 256×256 , CenterCrop 224×224 , và chuẩn hóa theo thống kê ImageNet.

C. Thiết kế Ablation Study

7 kịch bản ablation (Bảng III) thay đổi từng biến số độc lập: backbone (ResNet50, EfficientNet-B0, EfficientNet-B3), attention module (có/không CBAM), loss function (BCE, Focal, ASL) và augmentation (standard, strong). Exp C là variant so sánh chính với Exp G; các Exp A, B, D, E, F phục vụ định lượng đóng góp từng thành phần.

D. Siêu tham số

Môi trường: Kaggle Notebook, GPU NVIDIA Tesla T4 (16 GB VRAM), Python 3.10, PyTorch 2.0, thư viện `timm` cho backbone.

Siêu tham số được thiết lập như trong Bảng IV.

Tất cả các mô hình được huấn luyện từ đầu với cùng giao thức đánh giá, sử dụng cùng tập train/validation/test để đảm bảo tính công bằng giữa các thực nghiệm.

E. Metric Đánh giá

Để đánh giá toàn diện hiệu năng của bài toán Multi-Label Image Classification (MLIC), nghiên cứu sử dụng ba nhóm metric: (i) chất lượng xếp hạng xác suất (mAP), (ii) chất lượng dự đoán nhị phân sau threshold (Macro/Micro-F1), và (iii) khả năng tổng quát hóa của mô hình (overfitting gap).

Bảng IV: So sánh siêu tham số Exp C (tiền nhiệm) vs. Exp G (đề xuất).

Tham số	Exp C	Exp G	Lý do thay đổi
Optimizer	AdamW	AdamW	Giữ nguyên
Learning rate	3×10^{-4}	2×10^{-4}	B3 lớn hơn, ổn định hơn
Scheduler	OneCycleLR	OneCycleLR	Giữ nguyên
Batch size	64	32	VRAM B3 gấp đôi B0
Epochs	20	20	Giới hạn Kaggle
Dropout	0.3	0.5	Tăng regularization cho B3 và StrongAug
Weight decay	10^{-4}	10^{-4}	Giữ nguyên
AMP	fp16	fp16	Giữ nguyên
γ_+ (ASL)	0	0	Giữ nguyên
γ_- (ASL)	4	4	Giữ nguyên
Margin m (ASL)	0.05	0.05	Giữ nguyên
RandAugment	$\times$	($N=2, M=9$)	Kiểm soát CBAM overfit
RandomErasing	$\times$	$p=0.3$	Kiểm soát CBAM overfit

1) *mean Average Precision (mAP)*: Trong MLIC, mỗi ảnh có thể chứa nhiều nhãn đồng thời và phân bố positive/negative rất mất cân bằng. Do đó, việc đánh giá chỉ bằng accuracy hoặc F1 tại một threshold cố định không phản ánh đầy đủ khả năng xếp hạng của mô hình.

Vì vậy, nghiên cứu sử dụng **mean Average Precision (mAP)**: metric chuẩn của MS COCO và các bài toán multi-label, để đo khả năng mô hình ưu tiên nhãn đúng cao hơn nhãn sai trên toàn bộ miền threshold.

Đối với mỗi lớp, Average Precision (AP) được tính từ diện tích dưới đường cong Precision-Recall:

$$AP_i = \int_0^1 P_i(r) dr \quad (11)$$

trong đó $P_i(r)$ là precision tại recall r của lớp thứ i . Sau đó, mAP được tính bằng trung bình AP trên toàn bộ $C = 80$ lớp:

$$mAP = \frac{1}{C} \sum_{i=1}^C AP_i \quad (12)$$

mAP càng cao cho thấy mô hình càng phân tách tốt giữa positive labels và negative labels, đặc biệt quan trọng trong bối cảnh dữ liệu mất cân bằng như MS COCO.

2) *Macro-F1 và Micro-F1*: Mặc dù mAP đánh giá khả năng xếp hạng xác suất, trong thực tế hệ thống vẫn cần đưa ra quyết định nhị phân (có/không có đối tượng). Do đó, nghiên cứu bổ sung Macro-F1 và Micro-F1 tại threshold cố định $\theta = 0.5$.

F1-score được định nghĩa bởi:

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (13)$$

Macro-F1 tính F1 riêng cho từng lớp rồi lấy trung bình:

$$\text{Macro-F1} = \frac{1}{C} \sum_{i=1}^C F1_i \quad (14)$$

Metric này xem mọi lớp có tầm quan trọng ngang nhau, do đó phản ánh tốt khả năng nhận diện các lớp hiếm.

Ngược lại, **Micro-F1** gộp toàn bộ TP, FP, FN trên tất cả lớp trước khi tính:

$$\text{Micro-F1} = \frac{2TP}{2TP + FP + FN} \quad (15)$$

Micro-F1 thiên về các lớp phổ biến và phản ánh hiệu năng tổng thể của hệ thống trên toàn bộ dữ liệu.

Việc sử dụng đồng thời Macro-F1 và Micro-F1 giúp phân tích liệu mô hình chỉ hoạt động tốt trên lớp phổ biến hay thực sự cân bằng giữa cả lớp hiếm và lớp thường gặp.

3) *Overfitting Gap*: Ngoài hiệu năng dự đoán, nghiên cứu còn đánh giá khả năng tổng quát hóa của mô hình thông qua khoảng cách giữa Train mAP và Test mAP:

$$\Delta_{\text{gap}} = \text{Train mAP} - \text{Test mAP} \quad (16)$$

Nếu Δ_{gap} lớn, mô hình học quá sát dữ liệu huấn luyện nhưng không tổng quát tốt trên dữ liệu chưa thấy, đây là dấu hiệu của overfitting.

Ngược lại, gap nhỏ cho thấy mô hình học được đặc trưng có tính khái quát hơn. Metric này đặc biệt quan trọng khi đánh giá tác động của các module bổ sung như CBAM, vốn có thể tăng capacity nhưng đồng thời làm tăng nguy cơ overfit.

V. KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN

A. Kết quả tổng quan

Bảng V trình bày kết quả đầy đủ của 7 kịch bản thực nghiệm. Nhìn tổng thể, các experiment được thiết kế theo nguyên tắc ablation: mỗi bước thay thế đúng một thành phần, cho phép định lượng đóng góp độc lập của từng yếu tố.

Exp G (EfficientNet-B3, CBAM, ASL, Strong Augmentation) đạt Val mAP 0.7188 và Macro-F1 0.6989 - cao nhất toàn bộ study. Trong khi đó, Exp B (ResNet50, ASL) đạt Test mAP cao nhất (0.7228) và overfitting gap nhỏ nhất (0.1511), cho thấy ResNet50 tổng quát hóa rất tốt trong điều kiện huấn luyện giới hạn 20 epoch.

Hai experiment cuối bảng, Exp C và Exp F (đều dùng EfficientNet-B0), đạt kết quả thấp nhất trên hầu hết metric. Điều này xác nhận EfficientNet-B0 bị under-capacity cho bài toán multi-label classification trên MS COCO.

Một điểm đáng chú ý là Exp C đạt Train mAP rất cao (0.9168) nhưng Test mAP chỉ đạt 0.6537, dẫn đến overfitting gap lớn nhất toàn bộ study (0.2631). Ngược lại, Exp G có

Bảng V: Kết quả toàn diện của 7 experiments. Val mAP tại best epoch; Train/Test mAP tại checkpoint tốt nhất; Macro/Micro-F1 tại ngưỡng $\theta=0.5$. **In đậm:** tốt nhất theo từng cột.

Exp	Val mAP	Train mAP	Test mAP	Gap (Δ)	Macro-F1	Micro-F1
G: EffNet-B3, CBAM, ASL, StrongAug	0.7188	0.8764	0.6753	0.2011	0.6989	0.6923
E: ResNet50, CBAM và ASL	0.7129	0.9310	0.7223	0.2087	0.6961	0.7216
B: ResNet50 và ASL	0.7107	0.8739	0.7228	0.1511	0.6927	0.7214
D: ResNet50 và Focal	0.7009	0.8665	0.7100	0.1565	0.6858	0.7153
A: ResNet50 và BCE	0.6908	0.8706	0.7081	0.1625	0.6836	0.7184
C: EffNet-B0, CBAM và ASL	0.6364	0.9168	0.6537	0.2631	0.6407	0.6804
F: EffNet-B0 và ASL	0.6326	0.8132	0.6463	0.1669	0.6281	0.6615

Gap nhỏ hơn tương ứng khả năng tổng quát hóa tốt hơn. Train mAP giảm từ Exp C xuống Exp G là dấu hiệu tích cực, cho thấy mô hình ít ghi nhớ training data hơn.

Train mAP thấp hơn nhưng Val/Test mAP cao hơn đáng kể, cho thấy strong augmentation và dropout cao đã cải thiện khả năng tổng quát hóa.

B. Phân tích đóng góp từng thành phần

1) *Đóng góp của loss function:* Ba experiments A, D và B được so sánh trong cùng điều kiện (ResNet50, không CBAM, cùng siêu tham số) để cô lập tác động của hàm mất mát.

BCE vs. Focal Loss. So với BCE của Exp A, Focal Loss trong Exp D chỉ cải thiện nhỏ: Test mAP tăng từ 0.7081 (Exp A) lên 0.7100 (Exp D), Macro-F1 tăng từ 0.6836 (Exp A) lên 0.6858 (Exp D). Nguyên nhân là Focal Loss áp dụng cơ chế focusing đối xứng cho cả nhân dương và âm với cùng hệ số $\gamma=2$, chưa giải quyết triệt để sự mất cân bằng nghiêm trọng trong bài toán MLIC (~ 37 nhân âm trên mỗi nhân dương).

Focal Loss vs. ASL. ASL trong Exp B vượt trội rõ ràng: Test mAP tăng lên 0.7228 (+0.0128 so với Exp D và +0.0147 so với Exp A), Macro-F1 đạt 0.6927, đồng thời overfitting gap giảm từ 0.1625 (Exp A) xuống 0.1511 (Exp B). Cơ chế bất đối xứng $\gamma_-=4$ và margin $m=0.05$ triệt tiêu gần như hoàn toàn gradient của easy negatives, phù hợp hơn với đặc thù MLIC mất cân bằng mạnh.

ASL cũng thể hiện hiệu quả nhất quán khi kết hợp với CBAM trên ResNet50 (Exp E: Test mAP 0.7223, Macro-F1 0.6961) và khi kết hợp với backbone lớn hơn trong Exp G (Val mAP 0.7188, Macro-F1 0.6989).

2) *Đóng góp của CBAM:* CBAM được đánh giá trên hai backbone khác nhau, cho kết quả trái chiều nhau.

CBAM trên ResNet50 (Exp B $\rightarrow$ Exp E). Khi thêm CBAM vào ResNet50, Val mAP tăng nhẹ từ 0.7107 (Exp B) lên 0.7129 (Exp E), nhưng Test mAP gần như không đổi (0.7228 ở Exp B so với 0.7223 ở Exp E). Overfitting gap tăng từ 0.1511 (Exp B) lên 0.2087 (Exp E), cho thấy CBAM giúp mô hình khớp tốt hơn với validation set nhưng không cải thiện khả năng tổng quát hóa.

Mặc dù vậy, Micro-F1 của Exp E đạt 0.7216 - cao nhất toàn bộ study, cho thấy CBAM vẫn có giá trị khi backbone đủ mạnh.

CBAM trên EfficientNet-B0 (Exp F $\rightarrow$ Exp C). Tác động của CBAM nghiêm trọng hơn trên backbone nhỏ. Khi thêm CBAM, Test mAP chỉ tăng nhẹ từ 0.6463 (Exp F) lên 0.6537 (Exp C), nhưng overfitting gap tăng mạnh từ 0.1669 (Exp F) lên 0.2631 (Exp C) - cao nhất toàn bộ study.

Đáng chú ý, Train mAP của Exp C đạt 0.9168, gần bằng Exp E (0.9310) dù EfficientNet-B0 nhỏ hơn ResNet50 đáng kể. Điều này cho thấy CBAM đang giúp B0 ghi nhớ training data thay vì học biểu diễn tổng quát.

Spatial Attention kernel 7×7 có xu hướng học pattern đặc thù (vị trí đối tượng, texture nền) hơn là semantic region tổng quát. Hiện tượng này nghiêm trọng hơn trên backbone nhỏ với dữ liệu huấn luyện chỉ gồm 16,000 ảnh.

CBAM trên EfficientNet-B3 kết hợp Strong Augmentation (Exp G). Exp G cho thấy CBAM vẫn có thể hoạt động hiệu quả khi được regularize đúng cách. So với Exp C, overfitting gap giảm từ 0.2631 xuống 0.2011, trong khi Val mAP tăng mạnh lên 0.7188 và Macro-F1 đạt 0.6989 - cao nhất toàn bộ study.

Kết quả này cho thấy vấn đề của Exp C không nằm ở bản thân CBAM, mà đến từ sự kết hợp giữa backbone under-capacity và thiếu regularization đủ mạnh.

3) *Đóng góp của backbone và chiến lược augmentation:*
ResNet50 vs. EfficientNet-B0 (Exp B vs. Exp F). Trong cùng điều kiện (ASL, không CBAM, cùng chiến lược huấn luyện), Exp B (ResNet50 và ASL) đạt Test mAP 0.7228, trong khi Exp F (EfficientNet-B0 và ASL) chỉ đạt 0.6463, chênh lệch tới 0.0765. Val mAP cũng giảm mạnh từ 0.7107 xuống 0.6326. Kết quả này cho thấy EfficientNet-B0 bị under-capacity cho bài toán MLIC trên COCO. Feature map cuối của B0 ($\mathbb{R}^{1280 \times 7 \times 7}$) không đủ khả năng phân tách đồng thời 80 lớp đối tượng đa dạng.

EfficientNet-B0 vs. B3 kết hợp Strong Augmentation (Exp C vs. Exp G). So với Exp C (EfficientNet-B0, CBAM và ASL), Exp G (EfficientNet-B3, CBAM, ASL và StrongAug) mang lại cải thiện toàn diện: Val mAP tăng từ 0.6364 lên 0.7188 (+0.0824), Test mAP tăng từ 0.6537 lên 0.6753 (+0.0216), Macro-F1 tăng từ 0.6407 lên 0.6989 (+0.0582), trong khi overfitting gap giảm từ 0.2631 xuống 0.2011 (-0.0620). Feature map lớn hơn của B3 ($1536 \times 8 \times 8$) giúp CBAM hoạt động hiệu quả hơn nhờ nhiều kênh và vùng không gian để học attention. Đồng thời, RandAugment, RandomErasing và Dropout 0.5 giúp kiểm soát hiện tượng overfitting mạnh của Exp C.

EfficientNet-B3 vs. ResNet50 (Exp G vs. Exp B và Exp E). Exp G đạt Val mAP cao nhất toàn bộ study (0.7188), vượt cả Exp B (0.7107) và Exp E (0.7129). Macro-F1 của Exp G

Bảng VI: So sánh định lượng Exp G (đề xuất) và Exp C (tiền nhiệm). ↓(tốt): giảm là tốt hơn.

Metric	Exp C	Exp G	Δ	Chiều
Val mAP	0.6364	0.7188	+0.0824	↑
Test mAP	0.6537	0.6753	+0.0216	↑
Train mAP	0.9168	0.8764	-0.0404	↓(tốt)
Macro-F1	0.6407	0.6989	+0.0582	↑
Micro-F1	0.6804	0.6923	+0.0119	↑
Gap (Δ)	0.2631	0.2011	-0.0620	↓(tốt)

(0.6989) cũng cao nhất trong toàn bộ 7 experiments, cho thấy Strong Augmentation giúp xác suất dự đoán cân bằng hơn dưới threshold $\theta=0.5$.

Tuy nhiên, Test mAP của Exp G (0.6753) vẫn thấp hơn Exp B (0.7228) và Exp E (0.7223). Một nguyên nhân quan trọng là số epoch còn hạn chế: Train mAP của Exp G (0.8764) và Exp B (0.8739) gần tương đương, cho thấy EfficientNet-B3 chưa khai thác hết capacity sau 20 epoch với Strong Augmentation. Điều này cũng thể hiện qua đường cong hội tụ: Exp G vẫn tiếp tục tăng ổn định ở các epoch cuối, trong khi nhóm ResNet50 đã gần plateau. Với quá trình huấn luyện dài hơn (40 - 60 epoch), EfficientNet-B3 có tiềm năng vượt nhóm ResNet50 về Test mAP.

C. Đánh giá toàn diện mô hình đề xuất Exp G

Bảng VI định lượng cải thiện của Exp G so với Exp C - hai experiment cùng sử dụng EfficientNet, CBAM và ASL, nhưng khác nhau ở backbone size, chiến lược augmentation và mức regularization.

Val mAP tăng mạnh từ 0.6364 lên 0.7188 (+0.0824, tương đương +12.9%), đồng thời là kết quả cao nhất toàn bộ study. So với Exp C, EfficientNet-B3 trong Exp G có feature map lớn hơn ($1536 \times 8 \times 8$ so với $1280 \times 7 \times 7$), giúp mô hình giữ được nhiều thông tin không gian hơn, đặc biệt với các đối tượng nhỏ và lớp hiếm.


Test mAP tăng từ 0.6537 lên 0.6753 (+0.0216, tương đương +3.3%), xác nhận cải thiện không chỉ xảy ra trên validation set mà còn tổng quát hóa tốt hơn trên dữ liệu unseen. Tuy nhiên, Test mAP của Exp G vẫn thấp hơn Exp B (0.7228) và Exp E (0.7223), cho thấy EfficientNet-B3 chưa khai thác hết capacity sau 20 epoch với Strong Augmentation.

Train mAP giảm từ 0.9168 xuống 0.8764 không phải dấu hiệu tiêu cực. Exp C đạt Train mAP rất cao nhưng đi kèm overfitting gap lớn nhất toàn bộ study (0.2631), cho thấy mô hình có xu hướng ghi nhớ training data. Ngược lại, Strong Augmentation trong Exp G (RandAugment và RandomErasing) làm bài toán huấn luyện khó hơn, buộc mô hình học biểu diễn tổng quát hơn thay vì ghi nhớ mẫu cụ thể.

Macro-F1 tăng mạnh từ 0.6407 lên 0.6989 (+0.0582, tương đương +9.1%), cũng là kết quả cao nhất toàn bộ study. Mức cải thiện này lớn hơn đáng kể so với Test mAP (+3.3%), cho thấy Strong Augmentation không chỉ cải thiện khả năng xếp hạng (mAP) mà còn cải thiện hiệu chỉnh xác suất (probability calibration). Xác suất dự đoán tập trung hơn về hai phía 0 và 1, giúp threshold toàn cục $\theta=0.5$ hoạt động hiệu quả hơn.

Bảng VII: So sánh phân loại lỗi giữa Exp G và Exp C.

Loại lỗi	Exp C	Exp G	Cải tiến
FN (bỏ sót)	Nhiều (<i>hair drier, bottle</i>)	Ít hơn nhờ B3 capacity	Test mAP +0.022
FP (nhầm)	<i>tiếng</i> khi không có	Giảm nhờ Dropout 0.5	Macro-F1 +0.058
Overfit	Train 0.9168, Gap 0.2631	Train 0.8764, Gap 0.2011	Gap giảm 23.6%
Hội tụ	Plateau sớm epoch 8	Tăng đều đến epoch 10	Val mAP +0.082



Hình 3: Đường cong Val mAP theo epoch của 7 experiments.

Overfitting gap giảm mạnh từ 0.2631 xuống 0.2011 (-23.6%). Quan trọng hơn, gap của Exp G (0.2011) thấp hơn cả Exp E (0.2087) - experiment dùng ResNet50 với CBAM và ASL. Điều này cho thấy chiến lược regularization của Exp G (Dropout 0.5, RandAugment và RandomErasing) hiệu quả hơn việc chỉ tăng backbone capacity đơn thuần.

D. Phân tích đường cong huấn luyện

Hình 3 cho thấy ba pattern hội tụ đặc trưng giữa các nhóm backbone và cấu hình huấn luyện.

Nhóm ResNet50 (Exp A, B, D, E) hội tụ chậm nhưng ổn định. Val mAP tăng đều đến khoảng epoch 14-16 trước khi plateau. Trong nhóm này, Exp A (BCE) đạt plateau thấp nhất (0.6908), Exp D (Focal Loss) cải thiện nhẹ lên 0.7009, trong khi Exp B (ASL) tăng rõ rệt lên 0.7107, xác nhận hiệu quả của ASL trên bài toán MLIC mất cân bằng mạnh.

Exp E (ResNet50, CBAM và ASL) đạt Val mAP cao nhất trong nhóm ResNet50 (0.7129), nhưng đồng thời cũng có Train mAP cao nhất toàn bộ study (0.9310) và gap lớn hơn Exp B (0.2087 so với 0.1511). Điều này cho thấy CBAM giúp mô hình học mạnh hơn trên validation set, nhưng cũng làm tăng xu hướng overfitting.

Ngược lại, Exp B tuy có Val mAP thấp hơn nhẹ nhưng đạt Test mAP cao nhất toàn bộ study (0.7228) và gap nhỏ nhất, cho thấy khả năng tổng quát hóa tốt nhất trong điều kiện huấn luyện 20 epoch.

Nhóm EfficientNet-B0 (Exp C, F) hội tụ nhanh hơn nhưng plateau thấp hơn đáng kể. Exp F (EfficientNet-B0 và ASL) ổn định hơn với gap 0.1669, nhưng Val mAP chỉ đạt 0.6326, cho thấy backbone B0 bị under-capacity cho bài toán multi-label trên COCO.

Exp C (EfficientNet-B0, CBAM và ASL) đạt peak Val mAP tại khoảng epoch 8, sau đó dao động trong khi Train mAP tiếp

tục tăng lên 0.9168. Kết hợp với gap lớn nhất toàn bộ study (0.2631), đây là biểu hiện overfitting điển hình. Kết quả này cho thấy CBAM trên backbone nhỏ dễ học các pattern đặc thù của training set thay vì semantic region tổng quát.

Exp G (EfficientNet-B3, CBAM, ASL và StrongAug) thể hiện pattern hội tụ khác biệt. Do backbone lớn hơn và chiến lược augmentation mạnh hơn, Exp G hội tụ chậm hơn Exp C nhưng tăng ổn định đến khoảng epoch 10 và duy trì plateau cao sau đó. Không xuất hiện hiện tượng giảm mạnh sau peak như Exp C, đồng thời gap giảm xuống còn 0.2011. Điều này cho thấy RandAugment, RandomErasing và Dropout 0.5 đã kiểm soát hiệu quả hiện tượng overfitting của CBAM, giúp EfficientNet-B3 học biểu diễn tổng quát hơn dù capacity lớn hơn đáng kể so với B0.

E. Phân tích không gian đặc trưng và định tính

Phân tích không gian đặc trưng (t-SNE). Hình 4 trực quan hóa feature vector $\mathbf{v}$ sau bước GAP của Exp C và Exp G trên val set. Exp G tạo không gian đặc trưng có cấu trúc rõ ràng hơn: cụm lớp phổ biến (*person*, *car*, *chair*) tách biệt tốt hơn với khoảng cách inter-class lớn hơn và intra-class nhỏ hơn. Lớp hiếm (*hair drier*, *scissors*) vẫn phân tán, nhưng mức độ overlap giảm đáng kể so với Exp C. Điều này xác nhận EfficientNet-B3 học biểu diễn phân biệt tốt hơn B0 nhờ capacity lớn hơn và regularization phù hợp.

Phân tích định tính.

Phân tích định tính trong Hình 5 cho thấy sự khác biệt rõ rệt giữa Exp C và Exp G trong các ảnh chứa nhiều đối tượng đồng xuất hiện.

Ở sample #1, Exp G nhận diện đúng phần lớn nhân chính như *person*, *cup*, *fork*, *knife*, *cake*, *dining table* và *cell phone*. Tuy nhiên, mô hình vẫn tạo một số false positive như *pizza*, *orange* và *chair*, cho thấy bias co-occurrence vẫn còn tồn tại trong các cảnh ăn uống phức tạp. Các false negative còn lại chủ yếu là *sandwich*, *vase* và *clock*, những đối tượng nhỏ hoặc bị che khuất một phần.

Ở sample #2, Exp G tiếp tục dự đoán đúng các đối tượng phổ biến như *person*, *cup*, *spoon*, *bowl* và *dining table*. So với Exp C, số lượng false negative giảm đáng kể: mô hình vẫn nhận ra được nhiều vật thể nhỏ trong bối cảnh cluttered. Tuy nhiên, một số false positive như *wine glass*, *pizza*, *chair* và *cell phone* vẫn xuất hiện, phản ánh việc mô hình còn học association thống kê giữa các lớp thường đồng xuất hiện trong ảnh bàn ăn.

So sánh tổng thể cho thấy Exp C thiên về false negative: mô hình thường bỏ sót các vật thể nhỏ, lớp hiếm hoặc đối tượng nằm xa trung tâm ảnh. Ngược lại, Exp G giảm đáng kể false negative nhờ backbone B3 có capacity lớn hơn, đồng thời Strong Augmentation và Dropout 0.5 giúp hạn chế overfitting context. Kết quả này phù hợp với cải thiện định lượng: Test mAP tăng +0.0216 và Macro-F1 tăng +0.0582 so với Exp C.

F. Phân tích co-occurrence bias

Hình 6 định lượng mức độ đồng xuất hiện giữa các lớp thông qua hệ số Phi coefficient. Nhiều cặp lớp có mức đồng

xuất hiện rất cao, đặc biệt trong các bối cảnh cố định như bàn ăn hoặc giao thông.

Ví dụ, *chair-dining table* đạt hệ số 0.42, *cup-dining table* đạt 0.45, *bottle-cup* đạt 0.36, trong khi nhóm giao thông như *car-truck* đạt 0.42 và *car-traffic light* đạt 0.36. Các lớp dụng cụ ăn uống cũng có association mạnh: *knife-spoon* đạt 0.42 và *knife-dining table* đạt 0.40.

Bias co-occurrence giải thích một phần lớn false positive trong các experiment dùng CBAM. Khi các đối tượng thường xuyên xuất hiện cùng nhau, attention module dễ học shortcut thống kê (“thấy dining table $\rightarrow$ dự đoán cup hoặc knife”) thay vì học đặc trưng hình thái độc lập của từng lớp.

Hiện tượng này rõ nhất ở Exp C (EfficientNet-B0 + CBAM + ASL), nơi gap đạt tới 0.2631 – cao nhất toàn bộ study. Backbone nhỏ khiến CBAM có xu hướng tập trung vào context cố định (vị trí đối tượng, texture nền, bố cục ảnh) thay vì semantic region tổng quát. Exp E (ResNet50 + CBAM + ASL) cũng bị ảnh hưởng tương tự: Val mAP tăng nhẹ lên 0.7129, nhưng gap tăng lên 0.2087 so với 0.1511 của Exp B.

Ngược lại, nhóm không dùng CBAM (Exp A, B, D, F) ít bị co-occurrence bias hơn do không có attention module có khả năng ghi nhớ spatial context mạnh. Đặc biệt, Exp B đạt gap thấp nhất toàn bộ study (0.1511) và Test mAP cao nhất (0.7228), cho thấy ResNet50 + ASL học đặc trưng ổn định hơn mà không phụ thuộc quá nhiều vào association thống kê.

Exp G cho thấy co-occurrence bias có thể được kiểm soát khi CBAM được kết hợp với regularization đủ mạnh. RandAugment, ColorJitter và RandomErasing liên tục phá vỡ context cố định của ảnh: đối tượng bị xoay, che khuất hoặc thay đổi màu sắc, khiến attention không thể chỉ dựa vào background hoặc bố cục quen thuộc. Do đó, mô hình buộc phải học đặc trưng hình thái thực sự của từng đối tượng.

Kết quả là Exp G giảm đáng kể false positive trên các lớp có association cao, đồng thời cải thiện Macro-F1 thêm +0.0582 so với Exp C. Điều này xác nhận rằng vấn đề của Exp C không nằm ở bản thân CBAM, mà ở việc attention module được dùng trên backbone under-capacity và thiếu regularization phù hợp.


G. Hạn chế còn lại

Mặc dù Exp G vượt Exp C trên toàn bộ metric và đạt Val mAP, Macro-F1 cao nhất study, vẫn còn ba hạn chế cần ghi nhận.

Thứ nhất, Test mAP của Exp G (0.6753) chưa vượt nhóm ResNet50 (Exp B: 0.7228, Exp E: 0.7223). Nguyên nhân nhiều khả năng là 20 epoch chưa đủ cho B3 hội tụ hoàn toàn với Strong Augmentation. Train mAP của Exp G (0.8764) và Exp B (0.8739) gần bằng nhau, cho thấy B3 có tiềm năng đạt kết quả tương đương nếu được huấn luyện thêm 40–60 epoch.

Thứ hai, các lớp cực hiếm như *hair drier* và *toothbrush* vẫn có AP thấp dù Exp G cải thiện so với Exp C. Số lượng mẫu train quá ít (< 150 ảnh) là bottleneck thực sự, không chỉ đến từ kiến trúc mô hình. Cần giải pháp chuyên biệt: oversampling, class-aware augmentation, hoặc contrastive loss.

Thứ ba, nghiên cứu hiện mới đánh giá trên MS COCO 2014, chưa kiểm chứng khả năng tổng quát hóa liên miền dữ liệu. Các dataset như Pascal VOC hoặc NUS-WIDE có phân



(a) Exp C (EfficientNet-B0): lớp hiếm overlap nhiều



(b) Exp G (EfficientNet-B3): cụm tách biệt rõ hơn

Hình 4: So sánh t-SNE của feature vector v sau GAP (val set). B3 tạo không gian đặc trưng có cấu trúc rõ ràng hơn B0: cụm lớp phổ biến (*person*, *car*, *chair*) tách biệt tốt hơn; khoảng cách intra-class giảm, inter-class tăng. Lớp hiếm (*hair drier*, *scissors*) vẫn phân tán nhưng ít overlap hơn so với Exp C.



(c) Exp C – rank 2

(d) Exp G – rank 2


Hình 5: So sánh dự đoán định tính giữa Exp C và Exp G (xanh dương: True Positive, cam: False Positive, đỏ: False Negative).

phối nhãn và mức độ co-occurrence khác nhau, do đó cần được sử dụng trong các nghiên cứu tiếp theo để xác nhận tính ổn định của kiến trúc Exp G ngoài phạm vi COCO.

VI. ĐỐI CHIẾU VỚI NGHIÊN CỨU LIÊN QUAN

Do khác biệt lớn về quy mô dữ liệu, backbone và điều kiện huấn luyện, việc so sánh trực tiếp với các phương pháp state-of-the-art chỉ mang tính tham khảo. Các nghiên cứu như ASL [4], ML-Decoder [5] và Query2Label [6] đều sử dụng full MS COCO 2014 (118,000 ảnh train), backbone lớn hơn đáng kể, và lịch huấn luyện dài trên phần cứng cao cấp. Trong khi đó, đồ án này chỉ sử dụng subset khoảng 16,000 ảnh train, backbone lớn nhất là EfficientNet-B3 (12M tham số), và huấn luyện trong 20 epoch trên T4 16 GB.

So với ASL gốc [4]. Exp G sử dụng cùng hàm mất mát ASL nhưng với backbone nhẹ hơn nhiều (EfficientNet-B3 12M vs. TRResNet-L 53M) và lượng dữ liệu nhỏ hơn khoảng 7×



Hình 6: Ma trận co-occurrence chuẩn hóa giữa 30 lớp xuất hiện nhiều nhất trong train set. Các cặp có hệ số đồng xuất hiện cao gồm *chair–dining table* (0.42), *cup–dining table* (0.45), *bottle–cup* (0.36), *car–truck* (0.42), *knife–spoon* (0.42) và *knife–dining table* (0.40). Các association mạnh này dễ khiến mô hình học context thông kê thay vì đặc trưng hình thái thực sự của đối tượng.

Khoảng cách hiệu năng chủ yếu đến từ: (i) quy mô dữ liệu huấn luyện, (ii) capacity backbone, và (iii) lịch huấn luyện ngắn hơn đáng kể. Tuy nhiên, kết quả ablation trong đồ án vẫn tái hiện đúng xu hướng quan trọng được báo cáo trong nghiên cứu ASL: ASL vượt BCE và Focal Loss rõ rệt trong bài toán multi-label mất cân bằng mạnh.

So với ML-Decoder [5]. ML-Decoder sử dụng transformer decoder với grouped decoding queries để mô hình hóa quan hệ giữa các nhân. Kiến trúc này mạnh hơn global average pooling truyền thống, nhưng cũng yêu cầu compute và VRAM lớn hơn đáng kể. Trong điều kiện phần cứng giới hạn, CBAM là lựa chọn attention hiệu quả hơn: module rất nhẹ nhưng vẫn cải thiện biểu diễn đặc trưng, đặc biệt khi kết hợp backbone lớn hơn và regularization mạnh như Exp G. Kết quả của Exp G cho thấy attention lightweight vẫn có hiệu quả thực tiễn mà không cần kiến trúc transformer quy mô lớn.

So với Query2Label [6]. Query2Label sử dụng cross-attention giữa image feature và label-specific queries, cho phép mô hình học attention riêng cho từng nhân. Ý tưởng này gần với mục tiêu của CBAM, nhưng explicit hơn: mỗi label query tương ứng với một semantic concept cụ thể. Kết quả phân tích co-occurrence trong đồ án cho thấy CBAM với spatial attention chung vẫn dễ học association thống kê giữa các lớp. Do đó, label-specific attention kiểu Query2Label là hướng phát triển tự nhiên cho Exp G trong các nghiên cứu tiếp theo.

Ý nghĩa của Exp G trong điều kiện hạn chế tài nguyên. Mặc dù không cạnh tranh trực tiếp với các hệ thống SOTA quy mô lớn, Exp G vẫn cho thấy ba điểm quan trọng.

- **Hiệu quả phần cứng:** EfficientNet-B3 kết hợp CBAM và ASL có thể huấn luyện trên T4 16 GB với batch size 32 trong khoảng vài giờ mỗi lần chạy.
- **Thiết kế có cơ sở định lượng:** Mỗi thay đổi từ Exp C đến Exp G đều được xác nhận bằng ablation study A–G, thay vì chỉ dựa trên engineering heuristics.
- **Khả năng tổng quát hóa thực tiễn:** Strong Augmentation và regularization mạnh giúp Exp G đạt Val mAP và Macro-F1 cao nhất study, đồng thời giảm đáng kể overfitting gap so với kiến trúc tiền nhiệm.

VII. KẾT LUẬN

A. Tổng kết kết quả

Nghiên cứu này đề xuất **Exp G** – kiến trúc kết hợp EfficientNet-B3, CBAM và Asymmetric Loss (ASL) cùng Strong Augmentation cho bài toán multi-label image classification trên MS COCO. Mô hình được xây dựng dựa trên phân tích định lượng ba hạn chế chính của kiến trúc tiền nhiệm Exp C, bao gồm: under-capacity backbone, overfitting của CBAM, và hiện tượng threshold bias khi sử dụng ASL.

Kết quả ablation study trên 7 kịch bản thực nghiệm (A–G) xác nhận đóng góp của từng thành phần trong kiến trúc đề xuất. So với Exp C, Exp G cải thiện nhất quán trên toàn bộ metric đánh giá:

- **Val mAP:** tăng từ 0.6364 lên 0.7188 (+12.9%), cho thấy EfficientNet-B3 học biểu diễn đặc trưng hiệu quả hơn trên bài toán 80 lớp COCO.
- **Test mAP:** tăng từ 0.6537 lên 0.6753 (+3.3%), xác nhận khả năng tổng quát hóa tốt hơn trên tập test.
- **Macro-F1:** tăng từ 0.6407 lên 0.6989 (+9.1%), cho thấy Strong Augmentation giúp cải thiện hiệu quả dự đoán trên các lớp hiếm và giảm ảnh hưởng của threshold bias.

- **Overfitting gap:** giảm từ 0.2631 xuống 0.2011 (−23.6%), xác nhận hiệu quả regularization của RandAugment, RandomErasing và Dropout 0.5.

Nhìn chung, kết quả thực nghiệm cho thấy Exp G đạt sự cân bằng tốt hơn giữa capacity và generalization so với kiến trúc tiền nhiệm, đồng thời duy trì khả năng huấn luyện hiệu quả trong điều kiện phần cứng giới hạn.

B. Hạn chế và Hướng phát triển

Mặc dù đạt cải thiện đáng kể, Exp G vẫn còn một số hạn chế cần tiếp tục nghiên cứu:

- 1) **Số epoch huấn luyện còn hạn chế:** Strong Augmentation làm quá trình hội tụ chậm hơn, trong khi điều kiện phần cứng chỉ cho phép huấn luyện 20 epoch. Việc mở rộng số epoch có thể tiếp tục cải thiện Test mAP.
- 2) **Threshold toàn cục chưa tối ưu:** Việc sử dụng ngưỡng cố định $\theta=0.5$ chưa phù hợp cho tất cả lớp, đặc biệt với các lớp hiếm hoặc có phân bố mất cân bằng mạnh. Per-class threshold calibration là hướng cải thiện tiềm năng.
- 3) **Hiệu suất trên lớp hiếm còn thấp:** Các lớp như *hair drier* hoặc *toothbrush* vẫn có AP thấp do số lượng mẫu huấn luyện quá ít. Các kỹ thuật như oversampling, class-aware augmentation hoặc contrastive learning có thể giúp cải thiện vấn đề này.
- 4) **Attention chưa theo từng nhân:** CBAM sử dụng spatial attention chung cho toàn bộ feature map, chưa mô hình hóa attention riêng biệt cho từng lớp. Các hướng tiếp cận dạng label-query như Query2Label có tiềm năng cải thiện khả năng phân biệt giữa các nhân co-occurrence cao.
- 5) **Chưa đánh giá cross-dataset:** Nghiên cứu hiện chỉ thực nghiệm trên MS COCO subset. Việc đánh giá thêm trên Pascal VOC hoặc NUS-WIDE sẽ giúp xác nhận khả năng tổng quát hóa của mô hình.

Mã nguồn đầy đủ công khai tại <https://github.com/Thinh59/ECAAL>.

TÀI LIỆU

- [1] T.-Y. Lin *et al.*, “Microsoft COCO: Common objects in context,” in *Proc. ECCV*, pp. 740–755, 2014.
- [2] M. Tan and Q. V. Le, “EfficientNet: Rethinking model scaling for convolutional neural networks,” in *Proc. ICML*, pp. 6105–6114, 2019.
- [3] J. Wang, Y. Yang, J. Mao, Z. Huang, C. Huang, and W. Xu, “CNN-RNN: A unified framework for multi-label image classification,” in *Proc. IEEE CVPR*, pp. 2285–2294, 2016.
- [4] T. Ridnik, E. Ben-Baruch, N. Zamir, A. Noy, I. Friedman, M. Protter, and L. Zelnik-Manor, “Asymmetric loss for multi-label classification,” in *Proc. IEEE/CVF ICCV*, pp. 82–91, 2021.
- [5] T. Ridnik, G. Sharir, A. Ben-Cohen, E. Ben-Baruch, and A. Noy, “ML-Decoder: Scalable and versatile classification head,” in *Proc. WACV*, pp. 32–41, 2023.
- [6] S. Liu, L. Zhang, X. Yang, H. Su, and J. Zhu, “Query2Label: A simple transformer way to multi-label classification,” *arXiv:2107.10834*, 2021.
- [7] S. Woo, J. Park, J.-Y. Lee, and I. S. Kweon, “CBAM: Convolutional block attention module,” in *Proc. ECCV*, pp. 3–19, 2018.
- [8] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proc. IEEE CVPR*, pp. 770–778, 2016.
- [9] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal loss for dense object detection,” in *Proc. IEEE/CVF ICCV*, pp. 2980–2988, 2017.
- [10] J. Hu, L. Shen, and G. Sun, “Squeeze-and-excitation networks,” in *Proc. IEEE CVPR*, pp. 7132–7141, 2018.
- [11] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.

- [12] M.-L. Zhang and Z.-H. Zhou, "A review on multi-label learning algorithms," *IEEE Trans. Knowl. Data Eng.*, vol. 26, no. 8, pp. 1819–1837, 2014.
- [13] L. van der Maaten and G. Hinton, "Visualizing data using t-SNE," *J. Mach. Learn. Res.*, vol. 9, pp. 2579–2605, 2008.
- [14] E. D. Cubuk, B. Zoph, J. Shlens, and Q. V. Le, "Randaugment: Practical automated data augmentation with a reduced search space," in *Proc. IEEE/CVF CVPR Workshops*, pp. 702–703, 2020.
- [15] Z. Zhong, L. Zheng, G. Kang, S. Li, and Y. Yang, "Random erasing data augmentation," in *Proc. AAAI*, vol. 34, pp. 13001–13008, 2020.