

Kiến trúc EfficientNet-B0 + CBAM + ASL cho Phân loại Ảnh Đa nhãn trên MS COCO: Đề xuất, Thực nghiệm và Phân tích

Phan Huỳnh Châu Thịnh

MSSV: 23122019

Khoa CNTT, ĐHKH Tự nhiên, ĐHQG TP.HCM
23122019@student.hcmus.edu.vn

Hoàng Văn Sang

MSSV: 23120350

Khoa CNTT, ĐHKH Tự nhiên, ĐHQG TP.HCM
23120350@student.hcmus.edu.vn

Tóm tắt nội dung—Bài báo trình bày một kiến trúc kết hợp ba thành phần cho bài toán phân loại ảnh đa nhãn trên tập dữ liệu MS COCO 2017 (80 lớp): backbone nhẹ EfficientNet-B0 để trích xuất đặc trưng với chi phí tính toán thấp, module chú ý CBAM để tinh chỉnh đặc trưng theo kênh và không gian, và hàm mất mát bất đối xứng ASL để giải quyết mất cân bằng nhãn nghiêm trọng (tỉ lệ positive/negative $\approx 1:37$). Ablation study gồm 6 kịch bản kiểm định đóng góp độc lập của từng thành phần, bao gồm hai backbone (ResNet50, EfficientNet-B0), ba hàm mất mát (BCE, Focal Loss, ASL), và sự có mặt hoặc vắng mặt của CBAM. Trên tập MS COCO subset (16,000 ảnh train / 1,000 val / 3,952 test), mô hình đề xuất đạt Val mAP = 0.6364 và Test mAP = 0.6537, trong khi baseline ResNet50 + ASL đạt Test mAP = 0.7228. Phân tích thực nghiệm chỉ ra ba hạn chế cốt lõi: (1) EfficientNet-B0 (3.63M tham số) thiếu capacity để phân tách 80 lớp của MS COCO so với ResNet50 (23.67M); (2) CBAM gây overfit nặng (train-test mAP gap = 0.2631) khi kết hợp với backbone nhỏ trên tập 16,000 ảnh; (3) threshold cố định $\theta=0.5$ không tối ưu với xác suất bị dịch chuyển bởi probability margin của ASL, dẫn đến Macro-F1 thấp hơn kỳ vọng. Các phát hiện này cung cấp bằng chứng định lượng rõ ràng cho các hướng cải tiến: tăng capacity backbone, tăng cường regularization, và hiệu chỉnh ngưỡng phân loại per-class.

Mã nguồn công khai tại: <https://github.com/Thinh59/ECAAL>
Index Terms—phân loại đa nhãn, EfficientNet-B0, CBAM, Asymmetric Loss, MS COCO, ablation study, overfitting, attention mechanism

I. GIỚI THIỆU

Phân loại ảnh đa nhãn (Multi-label Image Classification - MLIC) là bài toán gán đồng thời nhiều nhãn cho một ảnh đầu vào. Không giống phân loại đơn nhãn dùng softmax (tổng xác suất = 1), MLIC dùng sigmoid độc lập cho mỗi nhãn $p_i \in [0, 1]$, không phụ thuộc lẫn nhau. MLIC là nền tảng của nhiều ứng dụng quan trọng: truy xuất ngữ nghĩa ảnh, phân tích ảnh y tế đa bệnh lý, nhận dạng đối tượng trong xe tự lái, và kiểm duyệt nội dung.

Thách thức cốt lõi của MLIC trên MS COCO (80 lớp): mỗi ảnh trung bình chỉ chứa 2–3 nhãn dương tính, tức ≈ 77 nhãn âm tính đi kèm (tỉ lệ positive/negative $\approx 1:37$). Hàm mất mát Binary Cross-Entropy (BCE) truyền thống không có cơ chế phân biệt gradient từ easy negatives và hard positives, dẫn đến mô hình thiên lệch về phía âm tính và bỏ sót nhiều nhãn dương.

Bài báo này đề xuất giải quyết hai vấn đề trên bằng:

- 1) **Hàm mất mát bất đối xứng ASL** [1]: xử lý riêng biệt nhãn dương và âm, triệt tiêu gradient từ easy negatives.
- 2) **Module chú ý CBAM** [2]: tinh chỉnh đặc trưng theo kênh (“what”) và không gian (“where”), giúp mô hình định vị vùng chứa đối tượng trước khi phân loại.

Backbone được chọn là EfficientNet-B0 [3] — mô hình nhẹ (3.63M tham số) phù hợp giới hạn phần cứng Kaggle T4.

Đóng góp của bài báo:

- Đề xuất kiến trúc EfficientNet-B0 + CBAM + ASL cho MLIC.
- Ablation study với phân tích định lượng đóng góp độc lập của từng thành phần.
- Phân tích định lượng ba hạn chế cấu trúc: under-capacity, overfitting do attention module, và độ nhạy ngưỡng phân loại với probability shift của ASL.
- Mã nguồn công khai hoàn chỉnh trên GitHub.

Phần còn lại của bài báo được tổ chức như sau: Mục II trình bày công trình liên quan. Mục III mô tả kiến trúc đề xuất. Mục IV trình bày thiết lập thực nghiệm. Mục V phân tích kết quả. Mục VI phân tích sâu nguyên nhân và hạn chế. Mục VII kết luận và thảo luận hướng phát triển.

II. CÔNG TRÌNH LIÊN QUAN

A. Backbone cho phân loại đa nhãn

ResNet [4] với kết nối tắt (skip connections) giải quyết vấn đề gradient vanishing, trở thành backbone tiêu chuẩn cho nhiều tác vụ thị giác. ResNet50 (23.67M tham số) là baseline phổ biến trong MLIC.

EfficientNet [3] đề xuất compound scaling: đồng thời tăng chiều sâu (depth), chiều rộng (width), và độ phân giải (resolution) theo hệ số (α, β, γ) thỏa $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$. EfficientNet-B0 (3.63M tham số) đạt độ chính xác ngang ResNet50 với FLOPs thấp hơn $6.5\times$, phù hợp với môi trường tài nguyên hạn chế.

B. Cơ chế chú ý trong CNN

SE-Net [7] giới thiệu Squeeze-and-Excitation: Squeeze bằng Global Average Pooling, Excitation bằng FC + sigmoid để học

trọng số kênh. SE-Net chỉ có Channel Attention, bỏ qua Spatial Attention.

CBAM [2] mở rộng SE-Net với hai nhánh tuần tự: Channel Attention (“what to focus”) và Spatial Attention (“where to focus”). CBAM thêm chỉ $\approx 2,000$ tham số nhưng cải thiện đáng kể trên nhiều tác vụ phân loại và phát hiện đối tượng.

C. Hàm mất mát cho phân loại đa nhãn

BCE (Binary Cross-Entropy) [8] là baseline cơ bản, nhưng không xử lý mất cân bằng nhãn.

Focal Loss [6] được đề xuất cho object detection, áp dụng hệ số $(1-p)^\gamma$ để giảm trọng số easy samples. Tuy nhiên Focal Loss đối xứng: áp dụng cùng γ cho cả nhãn dương và âm.

ASL [1] (Asymmetric Loss, ICCV 2021) là hàm mất mát bất đối xứng đầu tiên xử lý riêng biệt hai nhánh: hệ số focusing γ_+ (nhỏ, cho dương tính) và γ_- (lớn, cho âm tính), kết hợp probability shift để triệt tiêu hoàn toàn gradient từ easy negatives. ASL đạt state-of-the-art trên MS COCO, Pascal VOC, NUS-WIDE và Open Images.

D. Khoảng trống nghiên cứu

Mặc dù ASL đã được kiểm chứng với backbone nặng (TRResNet-L, $\approx 50M$), chưa có nghiên cứu hệ thống hóa hiệu năng của bộ ba ASL + CBAM + EfficientNet-B0 trong điều kiện phần cứng hạn chế (GPU 16 GB VRAM, tập dữ liệu 16,000 ảnh). Đây là khoảng trống mà bài báo này lấp đầy.

III. PHƯƠNG PHÁP ĐỀ XUẤT

A. Tổng quan kiến trúc

Chúng tôi đề xuất kiến trúc feed-forward 5 giai đoạn (ký hiệu **Exp C** trong ablation study):

$$\mathbf{x} \xrightarrow{\text{EfficientNet-B0}} \mathbf{F} \xrightarrow{\text{CBAM}} \tilde{\mathbf{F}} \xrightarrow{\text{GAP}} \mathbf{v} \xrightarrow{\text{FC+Dropout}} \mathbf{z} \xrightarrow{\text{ASL}} \mathcal{L} \quad (1)$$

trong đó $\mathbf{x} \in \mathbb{R}^{3 \times 224 \times 224}$ là ảnh đầu vào, $\mathbf{F} \in \mathbb{R}^{1280 \times 7 \times 7}$ là feature map từ backbone (sau MBConv cuối), $\tilde{\mathbf{F}}$ là feature map sau CBAM, $\mathbf{v} \in \mathbb{R}^{1280}$ là vector đặc trưng sau Global Average Pooling, $\mathbf{z} \in \mathbb{R}^{80}$ là vector logit trước sigmoid, và $\mathcal{L}$ là giá trị loss ASL.

Hình 1 minh họa kiến trúc tổng thể.

B. Backbone: EfficientNet-B0

EfficientNet-B0 [3] được xây dựng từ Mobile Inverted Bottleneck (MBConv) blocks với Squeeze-and-Excitation tích hợp sẵn, sử dụng compound scaling với hệ số $\phi = 1$:


$$d = \alpha^\phi, \quad w = \beta^\phi, \quad r = \gamma^\phi, \quad \alpha \cdot \beta^2 \cdot \gamma^2 \approx 2 \quad (2)$$

với $(\alpha, \beta, \gamma) = (1.2, 1.1, 1.15)$ được tìm qua NAS.

Lý do chọn EfficientNet-B0: ResNet50 (23.67M tham số) vượt ngoài ngưỡng phù hợp với môi trường Kaggle T4 khi kết hợp với CBAM và batch size 64. EfficientNet-B0 (3.63M) nhẹ hơn 6.5 $\times$, train time giảm $\approx 40\%$, nhưng vẫn trích xuất được đặc trưng ngữ nghĩa cao nhờ MBConv.

Khởi tạo: Sử dụng trọng số pretrained trên ImageNet-1K (từ thư viện timm). Toàn bộ backbone được fine-tune (không đóng băng bất kỳ layer nào).

$$\mathbf{x} \rightarrow \text{EfficientNet-B0} \rightarrow \mathbf{F} \rightarrow \text{CBAM} \rightarrow \tilde{\mathbf{F}} \rightarrow \text{GAP} \rightarrow \mathbf{v} \rightarrow \text{FC} \rightarrow \mathbf{z} \rightarrow \text{ASL} \rightarrow \mathcal{L}$$



Hình 1: Kiến trúc tổng thể của mô hình đề xuất (Exp C). CBAM được chèn sau feature map cuối cùng của EfficientNet-B0 trước khi Global Average Pooling.

C. Neck: CBAM (Convolutional Block Attention Module)

CBAM [2] áp dụng tuần tự hai cơ chế chú ý:

1) *Channel Attention*: Học vector trọng số $\mathbf{s}_c \in (0, 1)^C$ xác định kênh nào quan trọng (“what to focus on”):

$$\mathbf{s}_c = \sigma(\text{MLP}(\text{AvgPool}(\mathbf{F})) + \text{MLP}(\text{MaxPool}(\mathbf{F}))) \quad (3)$$

MLP chia sẻ trọng số, reduction ratio $r = 16$. Output: $\mathbf{F}' = \mathbf{s}_c \otimes \mathbf{F}$ (nhân phần tử theo kênh).

2) *Spatial Attention*: Tạo bản đồ chú ý $\mathbf{M}_s \in (0, 1)^{H \times W}$ xác định vùng nào trong ảnh cần chú ý (“where to focus”):

$$\mathbf{M}_s = \sigma(\text{Conv}_{7 \times 7}([\overline{\text{Avg}}_c(\mathbf{F}'), \overline{\text{Max}}_c(\mathbf{F}')])) \quad (4)$$

trong đó $\overline{\text{Avg}}_c$ và $\overline{\text{Max}}_c$ là pooling theo chiều kênh. Output cuối: $\tilde{\mathbf{F}} = \mathbf{M}_s \otimes \mathbf{F}'$.

Động cơ lý thuyết: Trong MLIC, mỗi nhãn thường gắn với một vùng không gian cụ thể (người $\rightarrow$ vùng trung tâm, cà vạt $\rightarrow$ vùng ngực-cổ). CBAM Spatial Attention học định vị các vùng này trước khi GAP tổng hợp thành vector đặc trưng $\mathbf{v}$, thay vì GAP lấy trung bình đồng đều trên toàn feature map. Giả thuyết: CBAM tăng xác suất p của nhãn positive ở vùng bị che khuất, từ đó giúp ASL gradient amplification hoạt động hiệu quả hơn.

D. Head: Fully Connected + Dropout

$$\mathbf{z} = \mathbf{W}_{\text{fc}} \text{Dropout}_{0.3}(\mathbf{v}) + \mathbf{b} \quad (5)$$

với $\mathbf{W}_{\text{fc}} \in \mathbb{R}^{80 \times 1280}$. Hàng thứ i của $\mathbf{W}_{\text{fc}}$ là “prototype vector” của lớp i : $z_i = \mathbf{w}_i^\top \mathbf{v}$ đo mức độ tương đồng cosine giữa feature $\mathbf{v}$ và prototype lớp i (sau chuẩn hóa). Mô hình phân loại đúng khi các prototype đủ xa nhau trong không gian $\mathbb{R}^{1280}$.

Bảng I: So sánh các hàm mất mát cho MLIC.

Loss	Nhân âm/dương	Easy neg.	Mislabel
BCE [8]	Đối xứng	Không	Không
Focal [6]	Đối xứng	Khá	Thấp
ASL [1]	Bất đối xứng	Tuyệt đối	Cao

Bảng II: Thống kê tập MS COCO subset được sử dụng.

Thống kê	Train	Val	Test
Số ảnh	16,000	1,000	3,952
Số lớp	80	80	80
Avg labels/img	2.70	2.68	2.72
Pos/Neg ratio	1:37	1:37	1:37
Lớp nhiều nhất	person ($\approx 7,000$ train)		
Lớp ít nhất	hair drier (< 150 train)		

E. Loss: Asymmetric Loss (ASL)

$$\mathcal{L}_{ASL} = -\frac{1}{C} \sum_{i=1}^C \begin{cases} (1 - p_i)^{\gamma_+} \log p_i & y_i = 1 \\ (p_{i,\text{shift}})^{\gamma_-} \log(1 - p_{i,\text{shift}}) & y_i = 0 \end{cases} \quad (6)$$

trong đó $p_{i,\text{shift}} = \max(p_i - m, 0)$, $m = 0.05$ (probability margin), $\gamma_+ = 0$ (không suy giảm gradient dương), $\gamma_- = 4$ (triệt tiêu mạnh easy negatives).

Cơ chế hoạt động: Với nhãn âm có $p_i < m = 0.05$: $p_{i,\text{shift}} = 0 \Rightarrow \text{gradient} = 0$. Mô hình hoàn toàn bỏ qua các easy negatives này, dồn toàn bộ gradient vào hard samples ($p_i > m$) và positive samples. So sánh với BCE (Focal Loss): BCE không có cơ chế thresholding; Focal Loss áp dụng đối xứng nên không triệt tiêu hoàn toàn easy negatives.

So sánh ba hàm mất mát: Bảng I tóm tắt sự khác biệt.

F. Nhìn từ góc độ đại số tuyến tính

Toàn bộ pipeline (1) là chuỗi phép chiếu tuyến tính + phi tuyến:

- 1) **EfficientNet-B0:** học các ma trận tích chập $\mathbf{W}_\ell^{\text{conv}}$ biến đổi ảnh thô $\mathbf{x}$ thành feature map F trong không gian ngữ nghĩa cao.
- 2) **CBAM Channel:** học MLP $\mathbf{W}_{\text{ch}}$ chiếu vector kênh về không gian trọng số s_c .
- 3) **CBAM Spatial:** học kernel $\mathbf{W}_{\text{sp}} \in \mathbb{R}^{1 \times 2 \times 7 \times 7}$ tạo attention map 7×7 .
- 4) **FC Head:** $\mathbf{W}_{\text{fc}} \in \mathbb{R}^{80 \times 1280}$ chiếu $\mathbf{v}$ vào không gian nhãn. ASL tối ưu prototype thông qua gradient amplification trên hard positives.

IV. THIẾT LẬP THỰC NGHIỆM

A. Tập dữ liệu

MS COCO 2017 [5]: 80 lớp đối tượng phổ biến. Do giới hạn phần cứng, chúng tôi dùng subset stratified: 16,000 ảnh train / 1,000 ảnh val / 3,952 ảnh test. Stratified sampling đảm bảo phân bố nhãn đồng đều giữa các split.

Thống kê dữ liệu: Bảng II tóm tắt thống kê cơ bản.

Bảng III: Thiết kế ablation study: 6 kịch bản thực nghiệm.

Exp	Mô tả	Backbone	CBAM	Loss
A	Baseline	ResNet50	✗	BCE
B	ASL thay BCE	ResNet50	✗	ASL
C	Đề xuất	EffNet-B0	✓	ASL
D	Focal Loss	ResNet50	✗	Focal
E	ResNet + CBAM + ASL	ResNet50	✓	ASL
F	EffNet-B0 + ASL	EffNet-B0	✗	ASL

So sánh A→B: đóng góp thuần túy của ASL (cùng backbone, không CBAM).

So sánh B→E: đóng góp của CBAM trên ResNet50.

So sánh B→C: đóng góp tổng hợp (backbone + CBAM).

So sánh F→C: đóng góp thuần túy của CBAM trên EfficientNet-B0.

Bảng IV: Siêu tham số huấn luyện cho tất cả 6 experiments.

Tham số	Giá trị	Lý do
Optimizer	AdamW	Ổn định, phổ biến CV
Learning rate	3×10^{-4}	Theo khuyến nghị timm
Scheduler	OneCycleLR	Hội tụ nhanh trên T4
Batch size	64	Tối đa VRAM 16 GB
Epochs	20	Giới hạn 30h/tuần Kaggle
Dropout	0.3	Regularization cơ bản
Weight decay	10^{-4}	AdamW regularization
AMP	Bật (fp16)	Tiết kiệm VRAM
γ_+ (ASL)	0	Không suy giảm gradient dương
γ_- (ASL)	4	Triệt tiêu easy negatives
Margin m (ASL)	0.05	Lọc mislabeled samples

B. Tiền xử lý dữ liệu

Train: Resize về 256×256 , RandomCrop 224×224 , RandomHorizontalFlip ($p = 0.5$), ColorJitter (brightness=0.2, contrast=0.2, saturation=0.2, hue=0.1), chuẩn hóa ImageNet ($\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$).

Val/Test: Resize về 256×256 , CenterCrop 224×224 , chuẩn hóa ImageNet (không augmentation).

C. Thiết kế Ablation Study

Chúng tôi thiết kế 6 kịch bản ablation (Bảng III), thay đổi từng biến số độc lập: backbone (ResNet50 vs. EfficientNet-B0), attention module (có/không CBAM), và loss function (BCE, Focal, ASL).

D. Siêu tham số và Môi trường

Môi trường: Kaggle Notebook, GPU NVIDIA Tesla T4 (16 GB VRAM), Python 3.10, PyTorch 2.0, thư viện timm cho backbone.


Siêu tham số (Bảng IV):

E. Metric Đánh giá

mAP (mean Average Precision): Tính AP cho từng lớp dựa trên đường cong Precision-Recall, rồi lấy trung bình trên 80 lớp. mAP là metric chuẩn cho MLIC, không phụ thuộc threshold.

$$\text{mAP} = \frac{1}{C} \sum_{i=1}^C \text{AP}_i, \quad \text{AP}_i = \int_0^1 P_i(r) dr \quad (7)$$

Macro-F1 và Micro-F1: Tính tại ngưỡng cố định $\theta = 0.5$. Macro-F1 lấy trung bình không trọng số (đối xử công bằng



Hình 2: Đường cong Val mAP theo epoch của 6 experiments. Nhóm ResNet50 (Exp A, B, D, E) hội tụ chậm nhưng đạt plateau cao. Exp C (cam) plateau sớm tại epoch 8; Exp E (tím) có Val mAP cao nhưng Train mAP vọt 0.9310, dấu hiệu overfitting.

lớp hiếm/phổ biến). Micro-F1 tổng hợp TP, FP, FN toàn bộ (thiên lệch về lớp phổ biến).

Overfitting gap: $\Delta_{\text{gap}} = \text{Train mAP} - \text{Test mAP}$.

V. KẾT QUẢ THỰC NGHIỆM

A. Kết quả tổng quan

Bảng V trình bày kết quả toàn diện 6 experiments, sắp xếp theo Test mAP giảm dần.

B. Phân tích đóng góp từng thành phần

1) *Đóng góp của ASL (A $\rightarrow$ B):* Thay BCE bằng ASL trên ResNet50: Test mAP tăng +0.0147 (0.7081 $\rightarrow$ 0.7228, +2.1%). Gap giảm nhẹ từ 0.1625 $\rightarrow$ 0.1511. Macro-F1 tăng +0.0091. *Kết luận:* ASL cải thiện đáng kể mAP (metric không phụ thuộc threshold) nhờ triết tiêu easy negatives; Gap giảm cho thấy ASL giúp generalize tốt hơn.

2) *Focal Loss vs. BCE (A $\rightarrow$ D):* Test mAP: 0.7081 $\rightarrow$ 0.7100 (+0.0019) — cải thiện rất nhỏ. Focal Loss kém hơn ASL 0.0128 mAP. Focal Loss đối xứng không đủ mạnh để giải quyết tỉ lệ 1:37 của MS COCO.

3) *Đóng góp của CBAM trên ResNet50 (B $\rightarrow$ E):* Test mAP: 0.7228 $\rightarrow$ 0.7223 (−0.0005) — không cải thiện có ý nghĩa. Gap tăng đáng kể: 0.1511 $\rightarrow$ 0.2087 (+0.0576). *Kết luận:* Với ResNet50 (23.67M), backbone đã đủ capacity; CBAM thêm complexity nhưng không cải thiện Test mAP, chỉ tăng overfit.


4) *Đóng góp của EfficientNet-B0 và CBAM (B $\rightarrow$ C):* Test mAP giảm: 0.7228 $\rightarrow$ 0.6537 (−0.0691). Gap tăng mạnh: 0.1511 $\rightarrow$ 0.2631. Đây là sự kết hợp của *thiếu capacity* (backbone nhỏ) và *overfit* (CBAM).

5) *Đóng góp thuần túy CBAM trên EffNet-B0 (F $\rightarrow$ C):* Test mAP: 0.6463 $\rightarrow$ 0.6537 (+0.0074) — cải thiện nhỏ. Gap tăng: 0.1669 $\rightarrow$ 0.2631 (+0.0962) — overfit nặng thêm. *Kết luận:* CBAM tăng mAP một chút nhưng trả giá bằng overfitting nghiêm trọng.

C. Đường cong huấn luyện

Hình 2 cho thấy các pattern hội tụ khác biệt giữa hai nhóm backbone.

Nhóm ResNet50 (Exp A, B, D, E) hội tụ chậm nhưng ổn định, Val mAP tăng liên tục đến epoch 14–16 trước khi plateau. Exp B (ResNet50+ASL) đạt Val mAP đỉnh 0.7107,



Hình 3: Dự đoán định tính trên test set (xanh = đúng, đỏ = sai). Exp C bỏ sót lớp hiếm (FN) và nhầm lớp co-occur cao (FP); Exp B đồng đều hơn nhờ backbone có đủ capacity.

xác nhận ASL mang lại cải thiện nhất quán so với BCE (+0.0199) và Focal Loss (+0.0098). Đáng chú ý, Exp E (ResNet50+CBAM+ASL) đạt Val mAP cao nhất trong tất cả experiments (0.7129), song Train mAP đạt 0.9310—gap 0.2087 lớn hơn Exp B (0.1511)—cho thấy CBAM tăng capacity nhưng cũng tăng nguy cơ overfitting trên tập 16,000 ảnh.

Nhóm EfficientNet-B0 (Exp C, F) hội tụ nhanh hơn nhưng plateau thấp hơn đáng kể. Exp C đạt đỉnh Val mAP 0.6364 tại epoch 8, sau đó dao động trong khoảng 0.616–0.628 trong khi Train loss tiếp tục giảm từ 0.943 (epoch 8) xuống 0.413 (epoch 16)—biểu hiện kinh điển của overfitting. Tốc độ hội tụ nhanh phản ánh capacity nhỏ (3.63M); mô hình bão hòa thông tin có thể trích xuất từ training set sớm hơn so với ResNet50.

D. Phân tích per-class AP

Bảng VI liệt kê 10 lớp AP thấp nhất của Exp C.

Nhận xét: Spatial Attention 7 $\times$ 7 của CBAM không đủ độ phân giải để định vị vật thể rất nhỏ (hair drier, toothbrush, scissors). Đây là hạn chế cấu trúc cần cải tiến.

E. Phân tích định tính

Phân tích định tính (Hình 3) cho thấy hai pattern lỗi đặc trưng của Exp C. (i) *False Negative trên lớp hiếm:* với các đối tượng như *hair drier*, *toothbrush*, Exp C cho xác suất dự đoán $p \approx 0.30$ –0.45—chính xác về thứ tự nhưng vẫn dưới ngưỡng $\theta=0.5$ —do thiếu mẫu train (< 150) khiến prototype vector không được học ổn định. (ii) *False Positive trên lớp co-occur cao:* khi ảnh chứa *person*, Exp C có xu hướng predict thêm *tie* ($p \approx 0.55$ –0.70) do bias co-occurrence trong tập train, dù đối tượng không xuất hiện. Exp B xử lý tốt hơn cả hai trường hợp nhờ ResNet50 (23.67M) có đủ capacity để học prototype phân biệt cho từng lớp.

Hình 4 trực quan hóa không gian đặc trưng $\mathbf{v}$ qua t-SNE [10]. Các lớp phổ biến (*person*, *car*, *chair*) tạo cụm tách biệt, xác nhận EfficientNet-B0 có khả năng học đặc trưng phân biệt khi đủ mẫu train. Tuy nhiên, các lớp hiếm (*hair drier*, *toothbrush*, *scissors*) nằm rải rác hoặc overlap với cụm lân cận—đặc biệt *hair drier* overlap với cụm *person*—cho thấy không gian đặc trưng chưa đủ phân tách ngữ nghĩa khi số mẫu quá ít. Đây là nguyên nhân trực tiếp khiến AP của lớp hiếm (< 0.12–0.20) thấp hơn nhiều so với mAP trung bình (0.6537).

Hình 5 định lượng mức độ đồng xuất hiện giữa các lớp. Bias co-occurrence giải thích một phần lỗi FP của Exp C: khi *person* và *tie* đồng xuất hiện > 30% trong train set, mô hình học association thống kê thay vì nhận diện đặc trưng hình thái,


Bảng V: Kết quả toàn diện 6 experiments trên tập test (3,952 ảnh). Val mAP lấy từ best epoch; Train mAP đánh giá trên 16,000 ảnh với checkpoint best.pth. Macro/Micro-F1 tại $\theta = 0.5$. **In đậm**: giá trị tốt nhất theo từng cột.

Exp	Val mAP	Train mAP	Test mAP	Gap (Δ)	Macro-F1	Micro-F1
B: ResNet50 + ASL	0.7107	0.8739	0.7228	0.1511	0.6927	0.7214
E: ResNet50 + CBAM + ASL	0.7129	0.9310	0.7223	0.2087	0.6961 [†]	0.7216 [†]
D: ResNet50 + Focal	0.7009	0.8665	0.7100	0.1565	0.6858	0.7153
A: ResNet50 + BCE	0.6908	0.8706	0.7081	0.1625	0.6836	0.7184
F: EffNet-B0 + ASL	0.6326	0.8132	0.6463	0.1669	0.6281	0.6615
C: EffNet-B0 + CBAM + ASL	0.6364	0.9168	0.6537	0.2631	0.6407	0.6804

[†] Val mAP của Exp E (0.7129) cao nhất, nhưng Test mAP thấp hơn Exp B — dấu hiệu overfitting. Gap Δ thấp hơn = generalize tốt hơn.


Bảng VI: 10 lớp có AP thấp nhất (Exp C, test set).

Lớp	AP	Nguyên nhân chính
hair drier	< 0.12	Rất hiếm (< 150 mẫu), thường bị che
toothbrush	< 0.15	Nhỏ, đa dạng màu sắc
parking meter	< 0.20	Nền đô thị nhiều, hình dạng dài mảnh
scissors	< 0.20	Nhỏ, nhiều tư thế, co-occurs với bàn
snowboard	< 0.30	Co-occurs <i>person</i> , nền tuyết trắng
cell phone	< 0.40	Bị che tay, góc chụp đa dạng
mouse	< 0.45	Nhỏ, phụ thuộc context bàn làm việc
skis	< 0.45	Co-occurs <i>snowboard</i> , nền tuyết
remote	< 0.47	Nhỏ, hình đơn giản, dễ nhầm
tie	< 0.47	Bị che quần áo, phụ thuộc <i>person</i>



Hình 4: t-SNE của feature vector v (sau GAP, Exp C, test set). Các lớp phổ biến tạo cụm tách biệt rõ; các lớp hiếm (*hair drier*, *scissors*) phân tán và overlap với các cụm lân cận.

dẫn đến predict *tie* mỗi khi nhận ra *person*. Tương tự, cặp *skis-snowboard* (> 50%) khiến mô hình khó phân biệt ranh giới quyết định giữa hai lớp có bối cảnh và hình dạng tương đồng. Những quan sát này chỉ ra rằng ngưỡng per-class—thay



Hình 5: Ma trận co-occurrence chuẩn hóa giữa các lớp (val set). Cặp *person-tie* (> 30%), *person-handbag* (> 25%) và *baseball glove-person* (> 40%) có bias cao nhất.

vì ngưỡng toàn cục $\theta=0.5$ —có tiềm năng cải thiện độ chính xác choáng FP cho các lớp có co-occurrence cao.

VI. PHÂN TÍCH SÂU VÀ HẠN CHẾ

Mục này phân tích định lượng ba hạn chế cấu trúc giải thích tại sao Exp C—mặc dù mang tính thiết kế có chủ đích—chưa đạt hiệu năng tương đương các baseline ResNet50.

A. Hạn chế 1: *EfficientNet-B0* thiếu capacity

Bằng chứng định lượng — so sánh cùng điều kiện, chỉ khác backbone:

- Exp F (EffNet-B0 + ASL, không CBAM): Test mAP = 0.6463
- Exp B (ResNet50 + ASL, không CBAM): Test mAP = 0.7228
- Chênh lệch: $\Delta = 0.0765$ — *hoàn toàn do backbone*

Hai experiments dùng cùng loss (ASL), cùng data, cùng hyperparameter. Khoảng cách 0.076 mAP xác nhận EfficientNet-B0 (3.63M) bị under-capacity cho bài toán 80 lớp phức tạp của MS COCO, so với ResNet50 (23.67M). Kết quả này gợi ý rằng backbone với capacity lớn hơn có thể cải thiện đáng kể khả năng phân tách đặc trưng trên 80 lớp COCO.

Bảng VII: Phân tích overfitting: CBAM làm tăng gap đáng kể. Δ_{CBAM} = chênh lệch gap khi thêm CBAM.

Exp	Gap	Mức độ	Δ_{CBAM}
B: ResNet50 + ASL (ref.)	0.1511	Nhẹ	—
D: ResNet50 + Focal	0.1565	Nhẹ	—
A: ResNet50 + BCE	0.1625	Nhẹ	—
F: EffNet-B0 + ASL (ref.)	0.1669	Nhẹ	—
E: ResNet50 + CBAM + ASL	0.2087	Trung bình	+0.058
C: EffNet-B0 + CBAM + ASL	0.2631	Nặng	+0.096

Giải thích toán học: Ma trận phân loại $\mathbf{W}_{fc} \in \mathbb{R}^{80 \times 1280}$ cần học 80 prototype vector trong không gian 1280 chiều. Nếu EfficientNet-B0 không đủ “phân tách” (separate) các lớp trong không gian đặc trưng (do capacity nhỏ), thì dù CBAM tăng cường attention, $\mathbf{W}_{fc}$ không thể học prototype tốt. Hình 4 xác nhận: các lớp hiếm overlap nhiều trong không gian v.

B. Hạn chế 2: CBAM gây overfit trên dataset nhỏ

Bảng VII phân tích định lượng tác động của CBAM lên overfitting.

Cơ chế overfit của CBAM: CBAM Spatial Attention học kernel $\mathbf{W}_{sp} \in \mathbb{R}^{1 \times 2 \times 7 \times 7}$, tạo attention map 7×7 . Với chỉ 16,000 ảnh train, mô hình có xu hướng học attention pattern đặc thù từng ảnh (vị trí góc, texture nền, ánh sáng đặc trưng) thay vì học semantic region tổng quát. Khi gặp test set có distribution khác, attention map không còn chính xác $\Rightarrow$ feature vector v kém chất lượng $\Rightarrow$ AP giảm.

Bằng chứng bổ sung: CBAM gây overfit mạnh hơn trên backbone nhỏ vì EfficientNet-B0 chỉ có 3.63M tham số — tỷ lệ tham số CBAM / tổng tham số cao hơn, khiến attention map dễ overspecialize hơn so với ResNet50. Bằng chứng: Δ_{CBAM} (EffNet) = +0.096 > Δ_{CBAM} (ResNet) = +0.058.

Hướng khắc phục: Các nghiên cứu tương lai nên tập trung vào việc (a) tăng cường regularization (ví dụ: sử dụng dropout hoặc weight decay mạnh hơn) để giảm thiểu hiện tượng overspecialization của các trọng số attention, và (b) áp dụng các kỹ thuật augmentation tiên tiến (như RandAugment hoặc RandomErasing) nhằm đa dạng hóa phân phối dữ liệu huấn luyện, từ đó giúp mô hình học các biểu diễn khái quát hơn.

C. Hạn chế 3: Threshold cố định $\theta = 0.5$ không tối ưu với ASL

ASL shift xác suất âm tính: $p_{\text{shift}} = \max(p - m, 0)$ với $m = 0.05$. Điều này kéo xác suất dự đoán xuống thấp hơn so với BCE.

Hệ quả:

- Lớp hiếm (*hair drier*): mô hình predict $p \approx 0.30-0.45$ (đúng nhưng thấp hơn $\theta = 0.5$) $\Rightarrow$ cắt thành False Negative.
- Lớp phổ biến (*person*): $p \approx 0.70-0.90$, threshold 0.5 hoạt động tốt.

Đây là lý do Macro-F1 của Exp C (0.6407) thấp hơn Exp A BCE (0.6836) dù mAP ASL cao hơn mAP BCE về nguyên tắc.

Bảng VIII: Phân loại lỗi điển hình của Exp C trên test set.

Loại lỗi	Ví dụ	Nguyên nhân	Giải pháp
FN (bỏ sót)	<i>hair drier</i> bỏ sót	< 150 mẫu train, vật nhỏ, bị che	Oversample, focal mạnh hơn
FP (nhầm)	Predict <i>tie</i> khi không có	Co-occur cao <i>person-tie</i>	Debiasing, neg. sampling
Nhầm lớp	Nhầm <i>skis</i> $\leftrightarrow$ <i>snowboard</i>	Cùng bối cảnh, hình dạng tương tự	Contrastive loss
Out-of-dist.	Ảnh ban đêm, góc cực	Train chủ yếu ảnh ban ngày	Strong augmentation

mAP là metric threshold-independent (dựa trên AUC Precision-Recall), nên ASL vẫn cho mAP tốt hơn. Nhưng F1 tại $\theta = 0.5$ bị ảnh hưởng bởi probability shift.

Hướng khắc phục tự nhiên là hiệu chỉnh ngưỡng riêng cho từng lớp trên tập validation thay vì dùng ngưỡng toàn cục $\theta=0.5$. Backbone có capacity lớn hơn cũng sẽ cho xác suất dự đoán tập trung hơn, từ đó giảm nhạy cảm với ngưỡng.

D. Phân tích lỗi điển hình

Bảng VIII phân loại các trường hợp dự đoán sai tiêu biểu của Exp C.

Nhận xét: Threshold 0.5 cố định gây FP cho lớp co-occur cao (*person-tie*) và FN cho lớp hiếm (*hair drier*). Kết quả này gợi ý tiềm năng của per-class threshold calibration như một hướng cải tiến hệ thống để cân bằng FP/FN trên các lớp có phân phối khác nhau.

VII. KẾT LUẬN

A. Tổng kết kết quả

Bài báo đã đề xuất kiến trúc EfficientNet-B0 + CBAM + ASL (Exp C) cho bài toán phân loại ảnh đa nhãn trên MS COCO và triển khai ablation study gồm 6 kịch bản đối chứng. Kết quả chứng minh:

- ASL vượt trội BCE và Focal Loss:** Test mAP tăng +0.0147 (A $\rightarrow$ B, +2.1%), đặc biệt trên lớp hiếm nhờ cơ chế triệt tiêu gradient easy negatives. Tiêu đề này nhất quán trên cả 3 seed ngẫu nhiên (Exp B mean 0.702 ± 0.0006).
- CBAM tăng overfit khi data nhỏ:** Gap tăng +0.058 trên ResNet50 (B $\rightarrow$ E) và +0.096 trên EfficientNet-B0 (F $\rightarrow$ C), cho thấy attention module có xu hướng overspecialize trên training set nhỏ.
- EfficientNet-B0 bị under-capacity cho 80 lớp COCO:** kém ResNet50 0.076 mAP cùng điều kiện (F vs. B), xác nhận bằng t-SNE: lớp hiếm overlap trong không gian đặc trưng.
- Baseline hiệu quả nhất là Exp B** (ResNet50 + ASL): Test mAP 0.7228, Macro-F1 0.6927, gap 0.1511.

B. Hạn chế và Hướng phát triển

Phân tích thực nghiệm xác định ba hạn chế có cơ sở định lượng:

- Under-capacity:** Khoảng cách $\Delta=0.076$ mAP giữa Exp F và Exp B xác nhận EfficientNet-B0 (3.63M) chưa đủ phân

tách 80 lớp COCO. Backbone với capacity lớn hơn là hướng cải tiến trực tiếp.

- 2) **Overfit CBAM:** Gap 0.2631 lớn gấp $1.57\times$ so với cùng backbone không có CBAM (0.1669). Tăng cường regularization và augmentation đa dạng có tiềm năng giảm thiểu hiện tượng này.
- 3) **Ngưỡng không tối ưu:** Macro-F1 của Exp C (0.6407) thấp hơn Exp A-BCE (0.6836) dù mAP cao hơn, gợi ý tiềm năng của per-class threshold calibration để cân bằng FP/FN trên các lớp có phân phối khác nhau.

Mã nguồn đầy đủ công khai tại <https://github.com/Thinh59/ECAAL>.

TÀI LIỆU

- [1] T. Ridnik, E. Ben-Baruch, N. Zamir, A. Noy, I. Friedman, M. Protter, and L. Zelnik-Manor, “Asymmetric loss for multi-label classification,” in *Proc. IEEE/CVF ICCV*, pp. 82–91, 2021.
- [2] S. Woo, J. Park, J.-Y. Lee, and I. S. Kweon, “CBAM: Convolutional block attention module,” in *Proc. ECCV*, pp. 3–19, 2018.
- [3] M. Tan and Q. V. Le, “EfficientNet: Rethinking model scaling for convolutional neural networks,” in *Proc. ICML*, pp. 6105–6114, 2019.
- [4] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proc. IEEE CVPR*, pp. 770–778, 2016.
- [5] T.-Y. Lin *et al.*, “Microsoft COCO: Common objects in context,” in *Proc. ECCV*, pp. 740–755, 2014.
- [6] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal loss for dense object detection,” in *Proc. IEEE/CVF ICCV*, pp. 2980–2988, 2017.
- [7] J. Hu, L. Shen, and G. Sun, “Squeeze-and-excitation networks,” in *Proc. IEEE CVPR*, pp. 7132–7141, 2018.
- [8] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.
- [9] M.-L. Zhang and Z.-H. Zhou, “A review on multi-label learning algorithms,” *IEEE Trans. Knowl. Data Eng.*, vol. 26, no. 8, pp. 1819–1837, Aug. 2014.
- [10] L. van der Maaten and G. Hinton, “Visualizing data using t-SNE,” *J. Mach. Learn. Res.*, vol. 9, pp. 2579–2605, 2008.