

# Kiến trúc EfficientNet + CBAM + ASL cho Phân loại Ảnh Đa nhãn trên MS COCO: Đề xuất, Thực nghiệm và Phân tích

Phan Huỳnh Châu Thịnh

MSSV: 23122019

Khoa CNTT, ĐHKH Tự nhiên, ĐHQG TP.HCM  
23122019@student.hcmus.edu.vn

Hoàng Văn Sang

MSSV: 23120350

Khoa CNTT, ĐHKH Tự nhiên, ĐHQG TP.HCM  
23120350@student.hcmus.edu.vn

**Tóm tắt nội dung**—Bài báo này, trình bày một kiến trúc kết hợp ba thành phần cho bài toán phân loại ảnh đa nhãn trên tập dữ liệu MS COCO 2017 (80 lớp) [1]: backbone nhẹ EfficientNet [2] để trích xuất đặc trưng với chi phí tính toán thấp, module chú ý CBAM để tinh chỉnh đặc trưng theo kênh và không gian, và hàm mất mát bất đối xứng ASL để giải quyết vấn đề mất cân bằng nhãn nghiêm trọng.

**Index Terms**—phân loại đa nhãn, EfficientNet, CBAM, Asymmetric Loss, MS COCO, ablation study, overfitting, attention mechanism

## I. GIỚI THIỆU

Phân loại ảnh đa nhãn (Multi-label Image Classification - MLIC [3]) là bài toán gán đồng thời nhiều nhãn cho một ảnh đầu vào. Không giống phân loại đơn nhãn dùng softmax (tổng xác suất = 1), MLIC dùng sigmoid độc lập cho mỗi nhãn  $p_i \in [0, 1]$ , không phụ thuộc lẫn nhau. MLIC là nền tảng của nhiều ứng dụng quan trọng: truy xuất ngữ nghĩa ảnh, phân tích ảnh y tế đa bệnh lý, nhận dạng đối tượng trong xe tự lái, và kiểm duyệt nội dung.

Thách thức cốt lõi của MLIC trên MS COCO (80 lớp): mỗi ảnh trung bình chỉ chứa 2–3 nhãn dương tính, tức  $\approx 77$  nhãn âm tính đi kèm (tỉ lệ positive/negative  $\approx 1:37$ ). Hàm mất mát Binary Cross-Entropy (BCE) truyền thống không có cơ chế phân biệt gradient từ easy negatives và hard positives, dẫn đến mô hình thiên lệch về phía âm tính và bỏ sót nhiều nhãn dương.

Bài báo này đề xuất giải quyết hai vấn đề trên bằng:

- 1) **Hàm mất mát bất đối xứng ASL** [4]: xử lý riêng biệt nhãn dương và âm, triệt tiêu gradient từ easy negatives.
- 2) **Module chú ý CBAM** [5]: tinh chỉnh đặc trưng theo kênh (“what”) và không gian (“where”), giúp mô hình định vị vùng chứa đối tượng trước khi phân loại.

Backbone được chọn là EfficientNet-B0 - mô hình nhẹ (3.63M tham số) phù hợp giới hạn phần cứng Kaggle T4.

Các phần tiếp theo được tổ chức như sau: Mục II trình bày công trình liên quan. Mục III mô tả kiến trúc đề xuất. Mục IV trình bày thiết lập thực nghiệm. Mục V phân tích kết quả. Mục VI phân tích sâu nguyên nhân và hạn chế. Mục VII kết luận và thảo luận hướng phát triển.

## II. CÔNG TRÌNH LIÊN QUAN

### A. Backbone cho phân loại đa nhãn

ResNet [6] với kết nối tắt (skip connections) giải quyết vấn đề gradient bị suy giảm dần khi lan truyền ngược qua nhiều lớp (gradient vanishing), trở thành backbone tiêu chuẩn cho nhiều tác vụ thị giác. ResNet50 (23.67M tham số) là baseline phổ biến trong MLIC.

EfficientNet đề xuất compound scaling: đồng thời tăng chiều sâu (depth), chiều rộng (width), và độ phân giải (resolution) theo hệ số  $(\alpha, \beta, \gamma)$  thỏa  $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$ . EfficientNet-B0 (3.63M tham số) đạt độ chính xác ngang ResNet50 với FLOPs thấp hơn  $6.5\times$ , phù hợp với môi trường tài nguyên hạn chế.

### B. Cơ chế chú ý trong CNN

SE-Net [8] giới thiệu Squeeze-and-Excitation: Squeeze bằng Global Average Pooling, Excitation bằng FC + sigmoid để học trọng số kênh. SE-Net chỉ có Channel Attention, bỏ qua Spatial Attention.

CBAM mở rộng SE-Net với hai nhánh tuần tự: Channel Attention (“what to focus”) và Spatial Attention (“where to focus”). CBAM thêm chỉ  $\approx 2,000$  tham số nhưng cải thiện đáng kể trên nhiều tác vụ phân loại và phát hiện đối tượng.

### C. Hàm mất mát cho phân loại đa nhãn


BCE (Binary Cross-Entropy) [9] là baseline cơ bản, nhưng không xử lý mất cân bằng nhãn.

Focal Loss [7] được đề xuất cho object detection, áp dụng hệ số  $(1-p)^\gamma$  để giảm trọng số easy samples. Tuy nhiên Focal Loss đối xứng vì áp dụng cùng  $\gamma$  cho cả nhãn dương và âm.

ASL (Asymmetric Loss, ICCV 2021) là hàm mất mát bất đối xứng đầu tiên xử lý riêng biệt hai nhánh: hệ số focusing  $\gamma_+$  (nhỏ, cho dương tính) và  $\gamma_-$  (lớn, cho âm tính), kết hợp sự thay đổi phân phối xác suất (probability shift) để triệt tiêu hoàn toàn gradient từ easy negatives. ASL đạt state-of-the-art trên MS COCO, Pascal VOC, NUS-WIDE và Open Images.

### D. Khoảng trống nghiên cứu

Mặc dù ASL đã được kiểm chứng với backbone nặng (TRResNet-L,  $\approx 50M$ ), chưa có nghiên cứu hệ thống hóa hiệu năng của bộ ba ASL + CBAM + EfficientNet-B0 trong điều



Hình 1: Kiến trúc tổng thể của mô hình đề xuất (Exp C). CBAM được chèn sau feature map cuối cùng của EfficientNet-B0 trước khi Global Average Pooling.

kiện phần cứng hạn chế (GPU 16 GB VRAM, tập dữ liệu 16,000 ảnh). Đây là khoảng trống mà bài báo này tiến hành nghiên cứu.

### III. PHƯƠNG PHÁP ĐỀ XUẤT

#### A. Tổng quan kiến trúc

Nhóm chúng tôi đề xuất kiến trúc feed-forward 5 giai đoạn (ký hiệu **Exp C** trong ablation study):

$$\mathbf{x} \xrightarrow{\text{EfficientNet-B0}} \mathbf{F} \xrightarrow{\text{CBAM}} \tilde{\mathbf{F}} \xrightarrow{\text{GAP}} \mathbf{v} \xrightarrow{\text{FC+Dropout}} \mathbf{z} \xrightarrow{\text{ASL}} \mathcal{L} \quad (1)$$

trong đó  $\mathbf{x} \in \mathbb{R}^{3 \times 224 \times 224}$  là ảnh đầu vào,  $\mathbf{F} \in \mathbb{R}^{1280 \times 7 \times 7}$  là feature map từ backbone (sau MBConv cuối),  $\tilde{\mathbf{F}}$  là feature map sau CBAM,  $\mathbf{v} \in \mathbb{R}^{1280}$  là vector đặc trưng sau Global Average Pooling,  $\mathbf{z} \in \mathbb{R}^{80}$  là vector logit trước sigmoid, và  $\mathcal{L}$  là giá trị loss ASL.

Hình 1 minh họa kiến trúc tổng thể.

#### B. Backbone: EfficientNet-B0


EfficientNet-B0 được xây dựng từ Mobile Inverted Bottleneck (MBConv) blocks với Squeeze-and-Excitation tích hợp sẵn, sử dụng compound scaling với hệ số  $\phi = 1$ :

$$d = \alpha^\phi, \quad w = \beta^\phi, \quad r = \gamma^\phi, \quad \alpha \cdot \beta^2 \cdot \gamma^2 \approx 2 \quad (2)$$

với  $(\alpha, \beta, \gamma) = (1.2, 1.1, 1.15)$  được tìm qua NAS.

ResNet50 là baseline phổ biến trong MLIC nhưng lại có 23.67M tham số, vượt ngoài ngưỡng phù hợp với môi trường Kaggle T4 khi kết hợp với CBAM và batch size 64. Vì vậy, việc sử dụng EfficientNet-B0 (3.63M) giúp nhẹ hơn 6.5×, đồng thời thời gian huấn luyện cũng giảm  $\approx 40\%$ , nhưng vẫn trích xuất được đặc trưng ngữ nghĩa cao nhờ MBConv.

**Khởi tạo:** Sử dụng trọng số pretrained trên ImageNet-1K (từ thư viện timm). Toàn bộ backbone được fine-tune (không đóng băng bất kỳ layer nào).



Hình 2: Kiến trúc CBAM được trích từ [5] được sử dụng làm neck. (Trên) Channel Attention: AvgPool và MaxPool theo chiều không gian được đưa qua Shared MLP, cộng lại và sigmoid tạo trọng số kênh  $\mathbf{M}_c \in (0, 1)^{1280}$ , nhân vào  $\mathbf{F}$  cho ra  $\mathbf{F}'$ . (Dưới) Spatial Attention: AvgPool và MaxPool theo chiều kênh của  $\mathbf{F}'$  được nối lại, qua Conv  $7 \times 7$  và sigmoid tạo attention map  $\mathbf{M}_s \in (0, 1)^{7 \times 7}$ , nhân vào  $\mathbf{F}'$  cho ra  $\tilde{\mathbf{F}}$ . Hai module được áp dụng tuần tự: Channel trước, Spatial sau.

#### C. Neck: CBAM (Convolutional Block Attention Module)

CBAM áp dụng tuần tự hai cơ chế chú ý như Hình 2:

1) *Channel Attention*: Học vector trọng số  $\mathbf{s}_c \in (0, 1)^C$  xác định kênh nào quan trọng ("what to focus on"):

$$\mathbf{M}_c = \sigma(\text{MLP}(\text{AvgPool}(\mathbf{F})) + \text{MLP}(\text{MaxPool}(\mathbf{F}))) \quad (3)$$

MLP chia sẻ trọng số, reduction ratio  $r = 16$ . Output:  $\mathbf{F}' = \mathbf{M}_c \otimes \mathbf{F}$  (nhân phần tử theo kênh).

2) *Spatial Attention*: Tạo bản đồ chú ý  $\mathbf{M}_s \in (0, 1)^{H \times W}$  xác định vùng nào trong ảnh cần chú ý ("where to focus"):

$$\mathbf{M}_s = \sigma(\text{Conv}_{7 \times 7}([\overline{\text{Avg}}_c(\mathbf{F}'), \overline{\text{Max}}_c(\mathbf{F}')])) \quad (4)$$

trong đó  $\overline{\text{Avg}}_c$  và  $\overline{\text{Max}}_c$  là pooling theo chiều kênh. Output cuối:  $\tilde{\mathbf{F}} = \mathbf{M}_s \otimes \mathbf{F}'$ .

Trong MLIC, mỗi nhãn thường gắn với một vùng không gian cụ thể (người → vùng trung tâm, cà vạt → vùng ngực-cổ). CBAM Spatial Attention học định vị các vùng này trước khi GAP tổng hợp thành vector đặc trưng  $\mathbf{v}$ , thay vì GAP lấy trung bình đồng đều trên toàn feature map. CBAM giúp tăng xác suất  $p$  của nhãn positive ở vùng bị che khuất, từ đó giúp ASL khuếch đại gradient làm mô hình hoạt động hiệu quả hơn.

#### D. Head: Fully Connected + Dropout

$$\mathbf{z} = \mathbf{W}_{\text{fc}} \text{Dropout}_{0.3}(\mathbf{v}) + \mathbf{b} \quad (5)$$

với  $\mathbf{W}_{\text{fc}} \in \mathbb{R}^{80 \times 1280}$ . Trong đó, hàng thứ  $i$  của  $\mathbf{W}_{\text{fc}}$  là vector đại diện đặc trưng (prototype vector) của lớp  $i$ :  $z_i = \mathbf{w}_i^\top \mathbf{v}$  đo mức độ tương đồng cosine giữa feature  $\mathbf{v}$  và đại diện đặc trưng lớp  $i$  (sau chuẩn hóa). Mô hình phân loại đúng khi các đại diện đặc trưng đủ xa nhau trong không gian  $\mathbb{R}^{1280}$ .

Bảng I: So sánh các hàm mất mát cho MLIC.

| Loss  | Nhân âm/dương | Easy neg. | Mislabel |
|-------|---------------|-----------|----------|
| BCE   | Đối xứng      | Không     | Không    |
| Focal | Đối xứng      | Khá       | Thấp     |
| ASL   | Bất đối xứng  | Tuyệt đối | Cao      |

Bảng II: Thống kê tập MS COCO subset được sử dụng.

| Thống kê       | Train                           | Val   | Test  |
|----------------|---------------------------------|-------|-------|
| Số ảnh         | 16,000                          | 1,000 | 3,952 |
| Số lớp         | 80                              | 80    | 80    |
| Avg labels/img | 2.70                            | 2.68  | 2.72  |
| Pos/Neg ratio  | 1:37                            | 1:37  | 1:37  |
| Lớp nhiều nhất | person ( $\approx 7,000$ train) |       |       |
| Lớp ít nhất    | hair drier ( $< 150$ train)     |       |       |

## E. Loss: Asymmetric Loss (ASL)

$$\mathcal{L}_{ASL} = -\frac{1}{C} \sum_{i=1}^C \begin{cases} (1 - p_i)^{\gamma_+} \log p_i & y_i = 1 \\ (p_{i,\text{shift}})^{\gamma_-} \log(1 - p_{i,\text{shift}}) & y_i = 0 \end{cases} \quad (6)$$

trong đó  $p_{i,\text{shift}} = \max(p_i - m, 0)$ ,  $m = 0.05$  (probability margin),  $\gamma_+ = 0$  (không làm giảm gradient dương),  $\gamma_- = 4$  (giúp triệt tiêu mạnh easy negatives).

Với nhân âm có  $p_i < m = 0.05$ :  $p_{i,\text{shift}} = 0$  thì gradient = 0. Mô hình hoàn toàn bỏ qua các easy negatives này, dồn toàn bộ gradient vào hard samples ( $p_i > m$ ) và positive samples. So sánh với BCE (Focal Loss): BCE không có cơ chế thresholding; Focal Loss áp dụng đối xứng nên không triệt tiêu hoàn toàn easy negatives.

Sự khác biệt của ba hàm mất mát được tóm tắt trong bảng I.

## F. Nhìn từ góc độ đại số tuyến tính

Toàn bộ pipeline (1) là chuỗi phép chiếu tuyến tính + phi tuyến:

- 1) **EfficientNet-B0**: học các ma trận tích chập  $\mathbf{W}_\ell^{\text{conv}}$  biến đổi ảnh thô  $\mathbf{x}$  thành feature map  $F$  trong không gian ngữ nghĩa cao.
- 2) **CBAM Channel**: học MLP  $\mathbf{W}_{\text{ch}}$  chiếu vector kênh về không gian trọng số  $\mathbf{M}_c$ .
- 3) **CBAM Spatial**: học kernel  $\mathbf{W}_{\text{sp}} \in \mathbb{R}^{1 \times 2 \times 7 \times 7}$  tạo attention map  $7 \times 7$ .
- 4) **FC Head**:  $\mathbf{W}_{\text{fc}} \in \mathbb{R}^{80 \times 1280}$  chiếu  $\mathbf{v}$  vào không gian nhãn. ASL tối ưu đặc trưng đại diện thông qua khuếch đại gradient trên hard positives.

## IV. THIẾT LẬP THỰC NGHIỆM

## A. Tập dữ liệu

**MS COCO 2017 [1]**: 80 lớp đối tượng phổ biến. Do giới hạn phần cứng, dữ liệu được chia bằng phương pháp subset stratified: 16,000 ảnh train / 1,000 ảnh val / 3,952 ảnh test. nhằm đảm bảo phân bố nhãn đồng đều giữa các tập.

**Thống kê dữ liệu**: Bảng II tóm tắt thống kê cơ bản.

Bảng III: Thiết kế ablation study: 6 kịch bản thực nghiệm.

| Exp | Mô tả               | Backbone         | CBAM | Loss       |
|-----|---------------------|------------------|------|------------|
| A   | Baseline            | ResNet50         | ✗    | BCE        |
| B   | ASL thay BCE        | ResNet50         | ✗    | ASL        |
| C   | <b>Đề xuất</b>      | <b>EffNet-B0</b> | ✓    | <b>ASL</b> |
| D   | Focal Loss          | ResNet50         | ✗    | Focal      |
| E   | ResNet + CBAM + ASL | ResNet50         | ✓    | ASL        |
| F   | EffNet-B0 + ASL     | EffNet-B0        | ✗    | ASL        |

So sánh A→B: đóng góp thuần túy của ASL (cùng backbone, không CBAM).

So sánh B→E: đóng góp của CBAM trên ResNet50.

So sánh B→C: đóng góp tổng hợp (backbone + CBAM).

So sánh F→C: đóng góp thuần túy của CBAM trên EfficientNet-B0.

Bảng IV: Siêu tham số huấn luyện cho tất cả 6 experiments.

| Tham số          | Giá trị            | Lý do                         |
|------------------|--------------------|-------------------------------|
| Optimizer        | AdamW              | Ổn định, phổ biến CV          |
| Learning rate    | $3 \times 10^{-4}$ | Theo khuyến nghị timm         |
| Scheduler        | OneCycleLR         | Hội tụ nhanh trên T4          |
| Batch size       | 64                 | Tối đa VRAM 16 GB             |
| Epochs           | 20                 | Giới hạn 30h/tuần Kaggle      |
| Dropout          | 0.3                | Regularization cơ bản         |
| Weight decay     | $10^{-4}$          | AdamW regularization          |
| AMP              | Bật (fp16)         | Tiết kiệm VRAM                |
| $\gamma_+$ (ASL) | 0                  | Không suy giảm gradient dương |
| $\gamma_-$ (ASL) | 4                  | Triệt tiêu easy negatives     |
| Margin $m$ (ASL) | 0.05               | Lọc mislabeled samples        |

## B. Tiền xử lý dữ liệu

**Train**: Resize về  $256 \times 256$ , RandomCrop  $224 \times 224$ , RandomHorizontalFlip ( $p = 0.5$ ), ColorJitter (brightness=0.2, contrast=0.2, saturation=0.2, hue=0.1), chuẩn hóa ImageNet ( $\mu = [0.485, 0.456, 0.406]$ ,  $\sigma = [0.229, 0.224, 0.225]$ ).

**Val/Test**: Resize về  $256 \times 256$ , CenterCrop  $224 \times 224$ , chuẩn hóa ImageNet (không augmentation).

## C. Thiết kế Ablation Study

6 kịch bản ablation được thiết kế để (Bảng III), thay đổi từng biến số độc lập: backbone (ResNet50 vs. EfficientNet-B0), attention module (có/không CBAM), và loss function (BCE, Focal, ASL).

## D. Siêu tham số và Môi trường

**Môi trường**: Kaggle Notebook, GPU NVIDIA Tesla T4 (16 GB VRAM), Python 3.10, PyTorch 2.0, thư viện timm cho backbone.


**Siêu tham số** được thiết lập như trong Bảng IV:

## E. Metric Đánh giá

**mAP (mean Average Precision)**: Tính AP cho từng lớp dựa trên đường cong Precision-Recall, rồi lấy trung bình trên 80 lớp. mAP là metric chuẩn cho MLIC, *không phụ thuộc threshold*.

$$\text{mAP} = \frac{1}{C} \sum_{i=1}^C \text{AP}_i, \quad \text{AP}_i = \int_0^1 P_i(r) dr \quad (7)$$

**Macro-F1 và Micro-F1**: Tính tại ngưỡng cố định  $\theta = 0.5$ . Macro-F1 lấy trung bình không trọng số (giúp cân bằng ảnh



Hình 3: Đường cong Val mAP theo epoch của 6 experiments. Nhóm ResNet50 (Exp A, B, D, E) hội tụ chậm nhưng đạt plateau cao. Exp C (cam) plateau sớm tại epoch 8; Exp E (tím) có Val mAP cao nhưng Train mAP vọt 0.9310, dấu hiệu overfitting.

hưởng giữa lớp hiếm và lớp phổ biến). Micro-F1 tổng hợp TP, FP, FN toàn bộ (thiên lệch về lớp phổ biến).

**Overfitting gap:**  $\Delta_{\text{gap}} = \text{Train mAP} - \text{Test mAP}$ .

## V. KẾT QUẢ THỰC NGHIỆM

### A. Kết quả tổng quan

Bảng V trình bày kết quả toàn diện 6 thực nghiệm, sắp xếp theo Test mAP giảm dần.

### B. Phân tích đóng góp từng thành phần

1) *Đóng góp của ASL (A  $\rightarrow$  B):* Thay BCE bằng ASL trên ResNet50: Test mAP tăng +0.0147 (0.7081  $\rightarrow$  0.7228, +2.1%). Gap giảm nhẹ từ 0.1625  $\rightarrow$  0.1511. Macro-F1 tăng +0.0091. Từ đó thấy rằng ASL cải thiện đáng kể mAP (metric không phụ thuộc threshold) nhờ triết tiêu easy negatives, đồng thời Gap giảm cũng cho thấy ASL giúp tổng quát hóa tốt hơn.

2) *Focal Loss vs. BCE (A  $\rightarrow$  D):* Test mAP: 0.7081  $\rightarrow$  0.7100 (+0.0019) - cải thiện rất nhỏ, Focal Loss kém hơn ASL 0.0128 mAP. Nghĩa là Focal Loss đối xứng không đủ mạnh để giải quyết tỉ lệ 1:37 của MS COCO.

3) *Đóng góp của CBAM trên ResNet50 (B  $\rightarrow$  E):* Test mAP: 0.7228  $\rightarrow$  0.7223 (-0.0005) - không cải thiện có ý nghĩa. Gap tăng đáng kể: 0.1511  $\rightarrow$  0.2087 (+0.0576). Như vậy, với ResNet50 (23.67M), backbone đã đủ capacity; CBAM thêm complexity nhưng không cải thiện Test mAP, chỉ tăng overfit.

4) *Đóng góp của EfficientNet-B0 và CBAM (B  $\rightarrow$  C):* Test mAP giảm: 0.7228  $\rightarrow$  0.6537 (-0.0691). Gap tăng mạnh: 0.1511  $\rightarrow$  0.2631. Đây là sự kết hợp của *thiếu capacity* (backbone nhỏ) và *overfit* (CBAM).

5) *Đóng góp thuần túy CBAM trên EffNet-B0 (F  $\rightarrow$  C):* Test mAP: 0.6463  $\rightarrow$  0.6537 (+0.0074) - cải thiện nhỏ. Gap tăng: 0.1669  $\rightarrow$  0.2631 (+0.0962) - overfit nặng thêm. CBAM tăng mAP một lượng nhỏ nhưng trả giá bằng overfitting nghiêm trọng.

### C. Đường cong huấn luyện

Hình 3 cho thấy các pattern hội tụ khác biệt giữa hai nhóm backbone.

**Nhóm ResNet50 (Exp A, B, D, E)** hội tụ chậm nhưng ổn định, Val mAP tăng liên tục đến epoch 14–16 trước khi

plateau. Exp B (ResNet50+ASL) đạt Val mAP đỉnh 0.7107, xác nhận ASL mang lại cải thiện nhất quán so với BCE (+0.0199) và Focal Loss (+0.0098). Đáng chú ý, Exp E (ResNet50+CBAM+ASL) đạt Val mAP cao nhất trong tất cả experiments (0.7129), song Train mAP đạt 0.9310 - gap 0.2087 lớn hơn Exp B (0.1511) - cho thấy CBAM tăng capacity nhưng cũng tăng nguy cơ overfitting trên tập 16,000 ảnh.

**Nhóm EfficientNet-B0 (Exp C, F)** hội tụ nhanh hơn nhưng plateau thấp hơn đáng kể. Exp C đạt đỉnh Val mAP 0.6364 tại epoch 8, sau đó dao động trong khoảng 0.616–0.628 trong khi Train loss tiếp tục giảm từ 0.943 (epoch 8) xuống 0.413 (epoch 16) - biểu hiện kinh điển của overfitting. Tốc độ hội tụ nhanh phản ánh capacity nhỏ (3.63M): mô hình bão hòa thông tin có thể trích xuất từ training set sớm hơn so với ResNet50.

### D. Phân tích per-class AP

Bảng VI liệt kê 10 lớp AP thấp nhất của Exp C.

Từ kết quả, có thể thấy Spatial Attention  $7 \times 7$  của CBAM không đủ độ phân giải để định vị vật thể rất nhỏ (hair drier, toothbrush, scissors). Đây là hạn chế cấu trúc cần cải tiến.

### E. Phân tích định tính

Phân tích định tính (Hình 4) cho thấy hai pattern lỗi đặc trưng của hai mô hình.

(i) *Exp C thiên về False Negative trên lớp nhỏ và bị che khuất:* Exp C bỏ sót nhiều nhân có đối tượng nhỏ hoặc khó quan sát, điển hình Sample #2 (FN= 6): bỏ sót *bottle, spoon, banana, oven, sink, refrigerator* trong ảnh bếp tối, Sample #1 (FN= 4): bỏ sót *bird, backpack, umbrella, refrigerator* do các đối tượng nhỏ nằm rải rác trong khung cảnh lộn xộn, cho thấy EfficientNet-B0 (3.63M) thiếu capacity để học đặc trưng phân biệt cho các lớp ít mẫu.

(ii) *Exp B thiên về False Positive trên lớp co-occur cao:* Exp B predict thừa nhiều nhân không có mặt, Sample #1 (FP= 14): predict thêm *handbag, cup, fork, knife, spoon, orange, potted plant, cell phone, sink, refrigerator, book, clock, vase* trong ảnh bàn ăn gia đình; Sample #3 (FP= 8): predict thêm nhiều đồ vật bếp không xuất hiện *cup, oven, refrigerator* và một số vật dụng thường ngày *laptop, remote, book, couch, potted plant* - phản ánh bias co-occurrence mạnh trong tập train giữa các lớp đồ vật trong nhà. Như vậy, Exp C thiên về FN nhiều hơn do thiếu capacity, trong khi Exp B thiên về FP do backbone lớn hơn để kích hoạt các lớp có co-occurrence cao.

Hình 5 trực quan hóa không gian đặc trưng  $\mathbf{v}$  qua t-SNE [11]. Các lớp phổ biến (*person, car, chair*) tạo cụm tách biệt, xác nhận EfficientNet-B0 có khả năng học đặc trưng phân biệt khi đủ mẫu train. Tuy nhiên, các lớp hiếm (*hair drier, toothbrush, scissors*) nằm rải rác hoặc overlap với cụm lân cận, đặc biệt *hair drier* overlap với cụm *person*, cho thấy không gian đặc trưng chưa đủ phân tách ngữ nghĩa khi số mẫu quá ít. Đây là nguyên nhân trực tiếp khiến AP của lớp hiếm ( $< 0.12$ –0.20) thấp hơn nhiều so với mAP trung bình (0.6537).


Hình 6 định lượng mức độ đồng xuất hiện giữa các lớp. Bias co-occurrence giải thích một phần lỗi FP của Exp C: khi *person* và *tie* đồng xuất hiện  $> 30\%$  trong train set, mô hình học association thống kê thay vì nhận diện đặc trưng hình thái,



Bảng V: Kết quả toàn diện 6 experiments trên tập test (3,952 ảnh). Val mAP lấy từ best epoch; Train mAP đánh giá trên 16,000 ảnh với checkpoint best.pth. Macro/Micro-F1 tại  $\theta = 0.5$ . **In đậm**: giá trị tốt nhất theo từng cột.

| Exp                              | Val mAP | Train mAP | Test mAP      | Gap ( $\Delta$ ) | Macro-F1            | Micro-F1            |
|----------------------------------|---------|-----------|---------------|------------------|---------------------|---------------------|
| B: ResNet50 + ASL                | 0.7107  | 0.8739    | <b>0.7228</b> | 0.1511           | <b>0.6927</b>       | <b>0.7214</b>       |
| E: ResNet50 + CBAM + ASL         | 0.7129  | 0.9310    | 0.7223        | 0.2087           | 0.6961 <sup>†</sup> | 0.7216 <sup>†</sup> |
| D: ResNet50 + Focal              | 0.7009  | 0.8665    | 0.7100        | 0.1565           | 0.6858              | 0.7153              |
| A: ResNet50 + BCE                | 0.6908  | 0.8706    | 0.7081        | 0.1625           | 0.6836              | 0.7184              |
| F: EffNet-B0 + ASL               | 0.6326  | 0.8132    | 0.6463        | 0.1669           | 0.6281              | 0.6615              |
| <b>C: EffNet-B0 + CBAM + ASL</b> | 0.6364  | 0.9168    | 0.6537        | <b>0.2631</b>    | 0.6407              | 0.6804              |

<sup>†</sup> Val mAP của Exp E (0.7129) cao nhất, nhưng Test mAP thấp hơn Exp B — dấu hiệu overfitting. Gap  $\Delta$  thấp hơn = generalize tốt hơn.



(a) Exp C (EfficientNet+CBAM+ASL)




(b) Exp B (ResNet50+ASL)

Hình 4: Dự đoán định tính trên test set (xanh = đúng, đỏ = sai). (a) Exp C bỏ sót lớp hiếm (FN) và nhầm lớp co-occur cao (FP); (b) Exp B đồng đều hơn nhờ backbone có đủ capacity.

Bảng VI: 10 lớp có AP thấp nhất (Exp C, test set).

| Lớp           | AP     | Nguyên nhân chính                         |
|---------------|--------|-------------------------------------------|
| hair drier    | < 0.12 | Rất hiếm (< 150 mẫu), thường bị che       |
| toothbrush    | < 0.15 | Nhỏ, đa dạng màu sắc                      |
| parking meter | < 0.20 | Nền đô thị nhiều, hình dạng dài mảnh      |
| scissors      | < 0.20 | Nhỏ, nhiều tư thế, co-occurs với bàn      |
| snowboard     | < 0.30 | Co-occurs <i>person</i> , nền tuyết trắng |
| cell phone    | < 0.40 | Bị che tay, góc chụp đa dạng              |
| mouse         | < 0.45 | Nhỏ, phụ thuộc context bàn làm việc       |
| skis          | < 0.45 | Co-occurs <i>snowboard</i> , nền tuyết    |
| remote        | < 0.47 | Nhỏ, hình đơn giản, dễ nhầm               |
| tie           | < 0.47 | Bị che quần áo, phụ thuộc <i>person</i>   |


dẫn đến predict tie mỗi khi nhận ra person. Tương tự, cặp skis-snowboard (> 50%) khiến mô hình khó phân biệt ranh giới quyết định giữa hai lớp có bối cảnh và hình dạng tương đồng. Những quan sát này chỉ ra rằng ngưỡng per-class—thay vì ngưỡng toàn cục  $\theta=0.5$ , có tiềm năng cải thiện độ chính xác chống FP cho các lớp có co-occurrence cao.



Hình 5: t-SNE của feature vector  $v$  (sau GAP, Exp C, test set). Các lớp phổ biến tạo cụm tách biệt rõ; các lớp hiếm (hair drier, scissors) phân tán và overlap với các cụm lân cận.

## VI. PHÂN TÍCH SÂU VÀ HẠN CHẾ

Mục này phân tích định lượng ba hạn chế cấu trúc giải thích tại sao Exp C, mặc dù mang tính thiết kế có mục tiêu đặc biệt nhưng chưa đạt hiệu năng tương đương các baseline ResNet50.



Hình 6: Ma trận co-occurrence chuẩn hóa giữa các lớp (val set). Cặp *person–tie* ( $> 30\%$ ), *person–handbag* ( $> 25\%$ ) và *baseball glove–person* ( $> 40\%$ ) có bias cao nhất.

#### A. Hạn chế 1: *EfficientNet-B0* thiếu capacity

**Bảng chứng định lượng** - so sánh cùng điều kiện, chỉ khác backbone:

- Exp F (EffNet-B0 + ASL, không CBAM): Test mAP = 0.6463
- Exp B (ResNet50 + ASL, không CBAM): Test mAP = 0.7228
- Chênh lệch:  $\Delta = 0.0765$  - hoàn toàn do backbone

Hai thực nghiệm dùng cùng loss (ASL), cùng data, cùng hyperparameter. Khoảng cách 0.076 mAP xác nhận EfficientNet-B0 (3.63M) bị under-capacity cho bài toán 80 lớp phức tạp của MS COCO, so với ResNet50 (23.67M). Kết quả này gợi ý rằng backbone với capacity lớn hơn có thể cải thiện đáng kể khả năng phân tách đặc trưng trên 80 lớp COCO.

**Lập luận.** Ma trận phân loại  $\mathbf{W}_{fc} \in \mathbb{R}^{80 \times 1280}$  cần học 80 prototype vector trong không gian 1280 chiều. Nếu EfficientNet-B0 không đủ khả năng phân tách (separate) các lớp trong không gian đặc trưng (do capacity nhỏ), thì dù CBAM tăng cường attention,  $\mathbf{W}_{fc}$  không thể học prototype tốt. Hình 5 đã xác nhận: các lớp hiếm overlap nhiều trong không gian v.

#### B. Hạn chế 2: CBAM làm tăng xu hướng overfitting trong thiết lập dữ liệu và backbone này.

Bảng VII phân tích định lượng tác động của CBAM lên overfitting.

**Cơ chế overfit của CBAM:** CBAM Spatial Attention học kernel  $\mathbf{W}_{sp} \in \mathbb{R}^{1 \times 2 \times 7 \times 7}$ , tạo attention map  $7 \times 7$ . Với chỉ 16,000 ảnh train, mô hình có xu hướng học attention pattern đặc thù từng ảnh (vị trí góc, texture nền, ánh sáng đặc trưng) thay vì học semantic region tổng quát. Khi gặp test set có distribution khác, attention map không còn chính xác dẫn đến feature vector  $\mathbf{v}$  kém chất lượng làm cho AP giảm.

Bảng VII: Phân tích overfitting: CBAM làm tăng gap đáng kể.  $\Delta_{CBAM}$  = chênh lệch gap khi thêm CBAM.

| Exp                              | Gap    | Mức độ      | $\Delta_{CBAM}$ |
|----------------------------------|--------|-------------|-----------------|
| B: ResNet50 + ASL (ref.)         | 0.1511 | Nhẹ         | —               |
| D: ResNet50 + Focal              | 0.1565 | Nhẹ         | —               |
| A: ResNet50 + BCE                | 0.1625 | Nhẹ         | —               |
| F: EffNet-B0 + ASL (ref.)        | 0.1669 | Nhẹ         | —               |
| E: ResNet50 + <b>CBAM</b> + ASL  | 0.2087 | Trung bình  | +0.058          |
| C: EffNet-B0 + <b>CBAM</b> + ASL | 0.2631 | <b>Nặng</b> | +0.096          |

**Bảng chứng bổ sung.** CBAM làm tăng xu hướng overfitting trên backbone nhỏ vì EfficientNet-B0 chỉ có 3.63M tham số — tỷ lệ tham số CBAM / tổng tham số cao hơn, khiến attention map dễ overspecialize hơn so với ResNet50. Bảng chứng:  $\Delta_{CBAM}(\text{EffNet}) = +0.096 > \Delta_{CBAM}(\text{ResNet}) = +0.058$ .

**Hướng khắc phục:** Các nghiên cứu tương lai nên tập trung vào việc (a) tăng cường regularization (ví dụ: sử dụng dropout hoặc weight decay mạnh hơn) để giảm thiểu hiện tượng overspecialization của các trọng số attention, và (b) áp dụng các kỹ thuật augmentation tiên tiến (như RandAugment hoặc RandomErasing) nhằm đa dạng hóa phân phối dữ liệu huấn luyện, từ đó giúp mô hình học các biểu diễn khái quát hơn.

#### C. Hạn chế 3: Threshold cố định $\theta = 0.5$ không tối ưu với ASL

ASL shift xác suất âm tính:  $p_{\text{shift}} = \max(p - m, 0)$  với  $m = 0.05$ . Điều này kéo xác suất dự đoán xuống thấp hơn so với BCE.

##### Hệ quả:

- Lớp hiếm (*hair drier*): mô hình dự đoán  $p \approx 0.30 - 0.45$ , thấp hơn ngưỡng  $\theta = 0.5$ , nên bị phân loại thành False Negative.
- Lớp phổ biến (*person*):  $p \approx 0.70 - 0.90$ , cho thấy threshold 0.5 hoạt động tốt.

Từ đó, có thể nhận định rằng, Macro-F1 của Exp C (0.6407) thấp hơn Exp A BCE (0.6836) dù mAP của ASL cao hơn BCE về nguyên tắc.

mAP là độ đo không phụ thuộc ngưỡng phân loại (dựa trên diện tích dưới đường cong Precision - Recall), nên ASL vẫn đạt mAP tốt hơn.

Tuy nhiên, F1 tại ngưỡng  $\theta = 0.5$  bị ảnh hưởng bởi sự dịch chuyển phân phối xác suất.

**Hướng khắc phục** có thể thử là hiệu chỉnh ngưỡng riêng cho từng lớp trên tập validation thay vì dùng ngưỡng toàn cục  $\theta=0.5$ . Backbone có capacity lớn hơn cũng sẽ cho xác suất dự đoán tập trung hơn, từ đó giảm nhạy cảm với ngưỡng.

#### D. Phân tích lỗi điển hình

Bảng VIII phân loại các trường hợp dự đoán sai tiêu biểu của Exp C.

Có thể thấy rằng, threshold 0.5 cố định gây FP cho lớp co-occur cao (*person–tie*) và FN cho lớp hiếm (*hair drier*). Kết quả này gợi ý tiềm năng của việc hiệu chỉnh ngưỡng threshold dự đoán theo từng lớp như một hướng cải thiện hệ thống để cân bằng FP/FN trên các lớp có phân phối khác nhau.

Bảng VIII: Phân loại lỗi điển hình của Exp C trên test set.

| Loại lỗi     | Ví dụ                                                  | Nguyên nhân                      | Giải pháp                  |
|--------------|--------------------------------------------------------|----------------------------------|----------------------------|
| FN (bỏ sót)  | <i>hair drier</i> bỏ sót                               | < 150 mẫu train, vật nhỏ, bị che | Oversample, focal mạnh hơn |
| FP (nhầm)    | Predict <i>tie</i> khi không có                        | Co-occur cao <i>person-tie</i>   | Debiasing, neg. sampling   |
| Nhầm lớp     | Nhầm <i>skis</i> ↔ <i>snowboard</i> hình dạng tương tự | Cùng bối cảnh, dạng              | Contrastive loss           |
| Out-of-dist. | Ảnh ban đêm, góc cực                                   | Train chủ yếu ảnh ban ngày       | Strong augmentation        |

## VII. KẾT LUẬN

### A. Tổng kết kết quả

Bài báo đã thực hiện phân tích thực nghiệm có hệ thống về ảnh hưởng của backbone, attention mechanism và loss function đối với bài toán phân loại ảnh đa nhãn trên MS COCO. Kiến trúc EfficientNet-B0 + CBAM + ASL (Exp C) được đánh giá thông qua ablation study gồm 6 kịch bản đối chứng. Kết quả thực nghiệm cho thấy:

- **ASL vượt trội BCE và Focal Loss:** Test mAP tăng +0.0147 (A→B, +2.1%), đặc biệt trên các lớp hiếm nhờ cơ chế triệt tiêu gradient của easy negatives.
- **CBAM làm tăng overfitting khi capacity hoặc dữ liệu còn hạn chế:** Gap tăng +0.058 trên ResNet50 (B→E) và +0.096 trên EfficientNet-B0 (F→C), cho thấy attention module có xu hướng overspecialize trên training set nhỏ thay vì luôn cải thiện khả năng tổng quát hóa.
- **EfficientNet-B0 bị under-capacity cho 80 lớp COCO:** kém ResNet50 0.076 mAP trong cùng điều kiện (F vs. B). Phân tích t-SNE cho thấy hiện tượng chồng lấn đặc trưng ở các lớp hiếm, cung cấp bằng chứng trực quan cho giả thuyết under-capacity trong không gian đặc trưng.
- **Baseline hiệu quả nhất là Exp B (ResNet50 + ASL):** đạt Test mAP 0.7228, Macro-F1 0.6927 với gap 0.1511, đổi lại là chi phí tính toán và thời gian huấn luyện lớn hơn.

### B. Hạn chế và Hướng phát triển

Phân tích thực nghiệm xác định ba hạn chế chính:

- 1) **Under-capacity:** Khoảng cách  $\Delta=0.076$  mAP giữa Exp F và Exp B xác nhận EfficientNet-B0 (3.63M tham số) chưa đủ khả năng phân tách 80 lớp COCO. Các backbone có capacity lớn hơn là hướng cải tiến trực tiếp.
- 2) **Overfit do attention:** Gap 0.2631 lớn gấp  $1.57\times$  so với cùng backbone không có CBAM (0.1669), cho thấy attention module làm tăng xu hướng học đặc trưng riêng của training set. Tăng cường regularization và augmentation đa dạng có tiềm năng giảm thiểu hiện tượng này.
- 3) **Ngưỡng dự đoán chưa tối ưu:** Macro-F1 của Exp C (0.6407) thấp hơn Exp A-BCE (0.6836) dù mAP cao hơn, cho thấy ASL có thể gây dịch chuyển phân phối xác suất dự đoán. Một hướng tiềm năng là kết hợp ASL với cơ chế hiệu chỉnh ngưỡng dự đoán theo từng lớp nhằm cân bằng FP/FN trên các lớp có phân phối khác nhau.

Mã nguồn đầy đủ công khai tại <https://github.com/Thinh59/ECAAL>.

## TÀI LIỆU

- [1] T.-Y. Lin *et al.*, “Microsoft COCO: Common objects in context,” in *Proc. ECCV*, pp. 740–755, 2014.
- [2] M. Tan and Q. V. Le, “EfficientNet: Rethinking model scaling for convolutional neural networks,” in *Proc. ICML*, pp. 6105–6114, 2019.
- [3] J. Wang, Y. Yang, J. Mao, Z. Huang, C. Huang, and W. Xu, “CNN-RNN: A unified framework for multi-label image classification,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, pp. 2285–2294, 2016.
- [4] T. Ridnik, E. Ben-Baruch, N. Zamir, A. Noy, I. Friedman, M. Protter, and L. Zelnik-Manor, “Asymmetric loss for multi-label classification,” in *Proc. IEEE/CVF ICCV*, pp. 82–91, 2021.
- [5] S. Woo, J. Park, J.-Y. Lee, and I. S. Kweon, “CBAM: Convolutional block attention module,” in *Proc. ECCV*, pp. 3–19, 2018.
- [6] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proc. IEEE CVPR*, pp. 770–778, 2016.
- [7] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal loss for dense object detection,” in *Proc. IEEE/CVF ICCV*, pp. 2980–2988, 2017.
- [8] J. Hu, L. Shen, and G. Sun, “Squeeze-and-excitation networks,” in *Proc. IEEE CVPR*, pp. 7132–7141, 2018.
- [9] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.
- [10] M.-L. Zhang and Z.-H. Zhou, “A review on multi-label learning algorithms,” *IEEE Trans. Knowl. Data Eng.*, vol. 26, no. 8, pp. 1819–1837, Aug. 2014.
- [11] L. van der Maaten and G. Hinton, “Visualizing data using t-SNE,” *J. Mach. Learn. Res.*, vol. 9, pp. 2579–2605, 2008.